

Como o detector do TC-330.03A funciona

Este documento descreve, do dado bruto ao alerta, a configuração que está valendo hoje: a que antecipa 6 das 8 falhas com 18,3 h de antecedência e menos de um falso positivo por mês. Cada filtro aparece com o valor que ele tem de verdade no código e com o motivo pelo qual ele existe.

O RESULTADO QUE ESTA CONFIGURAÇÃO ENTREGA

O placar

6 de 8 FALHAS ANTECIPADAS	18,3 h ANTECEDÊNCIA MÉDIA	0,94 FALSOS POSITIVOS POR MÊS	22,0 h POR MÊS EM ALARME FALSO	20 EPISÓDIOS DE ALERTA EM 16 MESES
350,5 DIAS DE OPERAÇÃO AVALIADOS				

A configuração é: PCA como modelo de normalidade, grade de 2 minutos, baseline de 3.000 horas de operação, suavização EWMA de 2 h, limiar no percentil 99,9, persistência de 30 minutos e confirmação por 2 sinais. Em linha de comando, é o rótulo `pca|2min|b3000h|excl0d|alm1.0h|ewma2h|q99.9|sust30min|conf2|min0min`.

O CAMINHO DO DADO

Os nove passos, em ordem

PASSO 1 Ler a série bruta e converter para número

Fonte: o dataset `68b25f9d...` no ClearML, arquivo `sensores_brutos_2025_2026_30s.csv` — 1.396.800 amostras a cada 30 s, de 01/01/2025 a 30/04/2026, com 39 tags. A planilha de alarmes vem no mesmo dataset.

Toda coluna é convertida para número à força. O PI grava texto de status no meio dos valores ("Bad", "Shutdown" e afins), e esse texto vira **vazio**, não zero.

Por que: um status virando zero seria lido pelo modelo como uma queda brusca de temperatura ou pressão — anomalia inventada por erro de leitura.

PASSO 2

Descartar leitura fora da faixa física

Cada família tem uma faixa plausível, e o que cai fora dela vira vazio:

Temperaturas	-15 °C a 900 °C
Pressões e diferenciais	-1,5 a 120
Vibração	0 a 200

Por que: o teto de 900 °C não é arbitrário — no instante do trip os termopares de mancal saltam para o fim de escala (medimos 871 °C). O que passa disso é defeito de instrumento.

PASSO 3

Reamostrar para a grade de 2 minutos

A série de 30 s é agregada pela **mediana** de cada bloco de 2 min, resultando em 349.200 amostras.

Por que: mediana e não média, para um pico isolado de instrumento não contaminar o bloco. A grade de 2 min foi escolhida por custo: o ajuste do autoencoder em 30 s custa 61 s por retreino contra 4,6 s em 2 min, o que inviabilizaria a varredura de configurações.

PASSO 4

Decidir quando a máquina estava operando

Dois níveis, e a diferença entre eles importa:

in_operation	tag RUNNING_A ≥ 0,5
stable	operando e passadas as primeiras 2 h desde a partida

O limiar é 0,5 e não "igual a 1" porque o `RUNNING_A` chega interpolado, e exigir exatamente 1 perderia as transições. Só o que é `stable` entra no treino e recebe pontuação.

Por que: nas primeiras horas depois de ligar, tudo está esquentando e estabilizando. Se isso entrasse no aprendizado do normal, o modelo aprenderia o transiente como normalidade; se entrasse na pontuação, alarmaria a cada partida.

PASSO 5 **Vetar instantes com instrumento travado**

Se algum sensor de uma família fica com desvio-padrão zero por 30 minutos, o score **daquela família** é anulado naquele instante. O veto é por família: um sensor de pressão travado não anula o score de temperatura.

Sensores constantes por natureza ficam fora do teste, por critério auto-calibrado: quem passa de 5% **do tempo** congelado em operação é dispensado. Na prática, isso exclui o `PI_0319` (pressão do gás de partida), que fica parado 18,4% do tempo porque é assim que ele funciona.

Por que: instrumento travado não é anomalia do equipamento, é falha de instrumentação — e antes era contado como anomalia. Sem dispensar o `PI_0319`, o veto apagava 14,5% de todo o tempo útil.

PASSO 6 **Escolher o histórico que treina o modelo de cada mês**

O detector é retreinado no dia 1º de cada mês, 15 vezes entre fev/2025 e abr/2026. Cada retreino usa as **últimas 3.000 horas de operação elegível** — e "elegível" já desconta parada, transiente de partida e as limpezas abaixo.

Janela de treino	3.000 h de operação elegível
Limpeza ao redor de alarme	±1 h de cada uma das 3.757 ativações
Limpeza antes de falha	desligada nesta configuração (0 dias)
Piso de amostra	100 h — abaixo disso o retreino é marcado inválido

Quando não existem 3.000 h de histórico, a janela é truncada e o retreino acaba usando tudo o que existe. Como a série começa em jan/2025, isso acontece em boa parte dos retreinos: a janela pedida de 3.000 h **entrega ~2.400 h em média**.

Por que contar em horas de operação e não em meses: um mês de calendário entrega entre 133,8 h e 691,1 h de operação — variação de 5,17×. Pior, a escassez é ligada às falhas: a correlação entre falhas nos 45 dias anteriores e horas elegíveis nos 30 dias seguintes é -0,61. Contar em meses encolheria o baseline exatamente nos retreinos que vêm depois de um reparo, quando o modelo mais precisa de referência.

Transformar 39 sensores em quatro sinais

Cada sinal responde por um mecanismo, e cada um vira um número entre 0 e "muito alto" a cada 2 minutos.

SINAL	O QUE É	COMO O NÚMERO SAI
temperatura	14 termopares (mancais, exaustão, corpo)	erro de reconstrução do PCA
pressao_oleo	12 pressões e diferenciais (óleo, selagem, gás)	erro de reconstrução do PCA
mancal_spread	TI_0305 menos a mediana dos três mancais irmãos	z robusto contra o próprio baseline
selagem_z	PDIT_0305, o diferencial de selagem, isolado	z robusto contra o próprio baseline

O PCA é ajustado para reter 95% da variância, sobre dados escalados de forma robusta (mediana e amplitude interquartil, para um outlier não definir a escala). O score é o erro médio quadrático entre a leitura e a reconstrução: quanto mais o instante fugir da estrutura aprendida, maior.

Por que existem os dois sinais isolados: abrindo o erro por sensor antes da falha de selagem de 27/02/2025, o PDIT_0305 respondia por 53% do erro — e ainda assim não houve alerta, porque o score da família de pressão é a média sobre 12 sensores e um sensor gritando vira sussurro depois de dividido por 12. Tirar esse sensor da média e tratá-lo em separado resolveu. O mancal_spread segue a mesma lógica: comparar o mancal que costuma falhar com os irmãos remove o efeito de carga, que sobe em todos ao mesmo tempo.

A vibração está em quarentena. As 10 tags TV_* existem e têm 100% de cobertura, mas o nível normal delas sobe ao longo dos trimestres e gera falso positivo crescente. Medimos se elas antecipam as falhas: nas 48 h anteriores ficam no percentil 79–85 de 315 janelas de controle, ou seja, não separam. Ficam disponíveis atrás de uma opção, desligadas.

Comparar cada sinal com o limite daquele mês

Três operações, nesta ordem:

- **Suavizar** — média exponencial com meia-vida de 2 h, aplicada igualmente ao score do treino e ao do mês testado.
- **Comparar** — o limite é o percentil 99,9 do score do próprio baseline daquele mês, já suavizado. Por isso o limite é uma linha em escada: muda a cada retreino.
- **Exigir persistência** — o sinal só é considerado ativo se ficar acima do limite por 30 minutos seguidos.

Por que o limiar é percentil do próprio baseline: assim ele significa a mesma coisa para qualquer modelo e qualquer escala de sensor — p99,9 deixa cerca de 0,1% do tempo de treino acima da linha. E o percentil é calculado sobre o score já suavizado: sem essa correspondência, o limiar não controlaria o falso positivo de fato.

PASSO 9 Emitir o alerta

O alerta é emitido quando **2 dos 4 sinais** estão ativos ao mesmo tempo. Não há exigência de duração mínima do alerta nesta configuração (`min_alert = 0`). Alertas separados por menos de 2 h são o mesmo episódio.

Por que exigir dois sinais: um sinal isolado passa do limite com frequência — só a temperatura fica acima 47% do tempo em alguns meses. Exigir concordância entre mecanismos diferentes é o que torna o alarme raro sem elevar o limiar a ponto de perder a falha.

A RÉGUA

Como o resultado é julgado

Isto não é parte do detector: é o critério de avaliação, e ele precisa estar claro antes de qualquer número ser discutido.

O que conta como falha

Uma falha é uma **parada de 2 h ou mais coincidente com alarme de nível** na janela de 1 h antes a 30 min depois. Trips a menos de 24 h um do outro contam como um único evento físico. Isso dá **8 falhas derivadas de 9 trips** no período.

Por que a conjunção é indispensável: o alarme `TAHH_6240305` sozinho tem 114 ativações na planilha e só 6 coincidem com a máquina caindo — nas outras ele dispara com o equipamento já parado, como eco da parada. E o piso de 2 h existe porque 65 das 135 transições do `RUNNING_A` duram menos de 3 minutos: são quedas de telemetria, não paradas.

As três caixas em que todo alerta cai

Detecção

O alerta começou nas 48 h que antecedem uma falha catalogada.

CONTA COMO ACERTO · 7
EPISÓDIOS

Antes de parada, não contado

Não pegou falha, mas a máquina parou de verdade (≥ 2 h) nas 48 h seguintes ao alerta.

FORA DAS DUAS CONTAS · 2
EPISÓDIOS

Falso positivo

Nada aconteceu depois.

CONTA COMO ERRO · 11 EPISÓDIOS

Uma quarta marcação é informativa, não uma caixa: o episódio que coincide (± 3 h) com um alarme de processo ativo é chamado de "**explicado**". Ele continua contando como falso positivo no número principal, e o número líquido — 0,60/mês contra 0,94 — é publicado ao lado. A janela é de ± 3 h e não mais: com ± 12 h a união das janelas cobriria 47% do tempo em operação e quase qualquer alerta cairia ali por acaso.

Os dois filtros de aprovação

FILTRO	EXIGÊNCIA	MOTIVO
Teto de falso positivo	$\leq 1,0$ episódio/mês	é o compromisso do projeto com quem fica de plantão
Detector vivo	silêncio máximo de 2.000 h de operação e alerta em todos-menos-um dos trimestres	quem não alarma nunca tem falso positivo perfeito; sem este filtro a busca premiava o detector mudo

O limite de silêncio está mal calibrado, e a configuração em uso reprova nele

A configuração desta documentação alarma em 6 dos 6 trimestres e ainda assim falha no filtro, por causa de um único trecho de 2.253 h contra o limite de 2.000 h. O motivo é físico: existe um vão real de cerca de seis meses sem nenhum evento na série (29/04/2025 a 04/11/2025) e, sob teto de 1 falso positivo por mês, o detector *tem* que ficar calado ali. Entre as 868 configurações que respeitam o teto, o menor silêncio possível é 1.578 h e o percentil 1 é 2.194 h — o limite de 2.000 h está no piso do que é fisicamente alcançável, e só 5 das 868 passam. A metade defensável do critério é a dos trimestres; a do limite absoluto precisa ser trocada pelo maior vão entre eventos consecutivos.

TODOS OS PARÂMETROS NUM LUGAR

Tabela de referência

Limpeza e operabilidade		
PARÂMETRO	VALOR	O QUE FAZ
RUNNING_THRESHOLD	0,5	acima disso a máquina conta como operando
STARTUP_EXCLUDE	2 h	descarte após cada partida, no treino e na pontuação
POST_START_SILENCE	0 h (desligado)	silêncio só do alerta após partida; medido em 24 h, não adotado
EXHAUST_GATE	off	marcador de exaustão T5 ≥ 500 °C; implementado e desligado
veto de congelado	30 min · 5%	janela do teste e limite para dispensar sensor constante por natureza
faixa física	temp -15/900 · pressão -1,5/120	fora disso vira vazio

Treino e decisão		
PARÂMETRO	VALOR	O QUE FAZ
modelo	PCA · 95% da variância	modelo de normalidade por família
grade	2 min (mediana)	resolução de trabalho
baseline	3.000 h de operação elegível	histórico que treina cada retreino mensal

PARÂMETRO	VALOR	O QUE FAZ
excluye_alarm_h	1,0 h	limpeza ao redor de cada ativação de alarme
excluye_days	0	limpeza dos dias antes de falha (desligada aqui)
ewma	meia-vida de 2 h	suavização do score
threshold	percentil 99,9	limite, calculado no baseline suavizado do mês
sustain	30 min	tempo acima do limite para o sinal contar
confirm	2 de 4 sinais	concordância exigida para alarmar
min_alert	0 min	duração mínima do alerta emitido

Avaliação

PARÂMETRO	VALOR	O QUE FAZ
MIN_STOP_HOURS	2 h	piso para uma queda contar como parada
STOP_ALARM_BEFORE / AFTER	1 h / 30 min	janela em que o alarme de nível precisa cair para a parada ser falha
EVENT_GAP	24 h	trips mais próximos que isso são um evento só
DETECTION_WINDOW	48 h	janela de crédito antes da falha, e de perdão depois do alerta
EPISODE_GAP	2 h	alertas mais próximos que isso são o mesmo episódio
ALARM_EXPLAIN_WINDOW	±3 h	coincidência com alarme ativo marca o episódio como explicado
max_fp_per_month	1,0	teto de aprovação
SILENCE_LIMIT_H	2.000 h	silêncio máximo tolerado para o detector ser considerado vivo

O RESULTADO, EVENTO POR EVENTO

O que o detector viu


FALHA	MECANISMO	ANTECIPADA?	ANTECEDÊNCIA	HORAS QUE A MÁQUINA OPEROU NAS 48 H ANTERIORES
27/02/2025	selagem	sim	33,2 h	48,0
17/03/2025	mancal	sim	30,7 h	48,0
07/04/2025	mancal	sim	19,5 h	47,6
11/04/2025	mancal	sim	3,8 h	48,0
29/04/2025	mancal	sim	2,5 h	47,8
04/11/2025	óleo	não	—	15,3
09/12/2025	mancal	não	—	47,8
26/02/2026	óleo	sim	19,9 h	48,0

O que a varredura completa diz sobre essas duas

Entre as 10.368 configurações avaliadas em 27/08/2026 — três arquiteturas, duas grades, seis limiares, quatro persistências e todo o resto — **nenhuma** antecipa a falha de 04/11/2025. A de 09/12/2025 é alcançável: 26 configurações chegam a 7 de 8, todas com autoencoder na grade de 30 s e limiar p99,5. Mas o preço é de 5,51 falsos positivos por mês e 99 h/mês em alarme, cinco vezes o teto do projeto. Não é um ponto de operação: é a demonstração de que o sinal daquela falha está enterrado no ruído.

A última coluna é a que separa "o modelo perdeu" de "não havia o que ver". Em 04/11/2025 o compressor operou 15,3 h das 48 h da janela — é limitação de observabilidade. Em 09/12/2025 operou 47,8 h e o detector não viu; nesse caso, porém, **nada** viu: varrendo os 36 sensores em três horizontes (48 h, 7 dias, 14 dias), no nível cru e normalizado por carga, contra 182 a 241 janelas de controle, o desvio mais raro chega ao percentil 87.

Alerta confirmado sobre TI_0305 — acumulativo (acima) contra janela de 3.000 h (abaixo)



O sensor **TI_0305** nos 16 meses. Acima, o baseline acumulativo que rodava antes (5 de 8); abaixo, a janela de 3.000 h desta documentação (6 de 8). Ponto vermelho antecipou falha catalogada, grafite é falso positivo, laranja é alerta antes de parada não contado, faixa cinza é máquina parada, linha laranja tracejada é a falha real.

A ALTERNATIVA EM REDE NEURAL

O autoencoder

O detector descrito até aqui usa PCA. A mesma busca testou uma **rede neural** no lugar dele, sob protocolo idêntico: mesmas famílias de sensores, mesmo baseline de 3.000 h, mesmo retreino mensal, mesmo limiar por percentil, mesma persistência e mesma confirmação por 2 sinais. Só o modelo de normalidade muda.

O que é o autoencoder aqui

Uma rede densa que aprende a **reconstruir a própria entrada**, passando por um gargalo que a obriga a resumir o que é normal. Três camadas ocultas, com o

gargalo em um quarto do número de sensores, ativação ReLU, parada antecipada e no máximo 60 épocas. O score de anomalia é o **erro médio quadrático entre a leitura e a reconstrução**: quando o instante não se parece com o que a rede aprendeu, ela reconstrói mal e o erro sobe.

É o mesmo princípio do PCA — comprimir e reconstruir, e medir o que não reconstrói — na versão não linear. Há também duas variantes testadas: uma mais profunda, com gargalo mais apertado (um sexto dos sensores), e uma mais larga (uma camada com o dobro dos sensores).

O resultado, lado a lado

	PCA (EM USO)	AUTOENCODER
Falhas antecipadas	6 de 8	6 de 8
Antecedência média	18,3 h	12,6 h
Falso positivo	0,94/mês	0,95/mês
Tempo em alarme falso	22,0 h/mês	24,2 h/mês
Trimestres com alerta	6 de 6	6 de 6
Maior silêncio	2.253 h	2.279 h
Grade necessária	2 min	30 s
Limiar	percentil 99,9	percentil 99,995
Limpeza pré-falha	não usa	7 dias antes de cada falha
Exclusão ao redor de alarme	1 h	nenhuma
Custo de um ajuste	~2 s	61 s

VARREDURA COMPLETA DE 10.368 CONFIGURAÇÕES NO CLEARML, CONCLUÍDA EM 27/08/2026 SOB O CÓDIGO ATUAL. AS DUAS LINHAS SÃO AS MELHORES CONFIGURAÇÕES DENTRO DO TETO DE 1 FALSO POSITIVO POR MÊS, CADA UMA NA SUA ARQUITETURA.

Em detecção, empatam — e empatam também na distribuição temporal: os dois alarmam nos 6 trimestres e têm silêncio máximo praticamente igual. A diferença real é a antecedência, 5,7 h a favor do PCA, e o custo: o autoencoder precisa da grade de 30 s, o que faz cada ajuste custar 61 s contra ~2 s.

Duas ressalvas que precisam acompanhar esse número

O 6 de 8 do autoencoder exige três coisas ao mesmo tempo

Não é um resultado robusto a variações da configuração. Ele só aparece com a **grade de 30 s**, o **limiar no percentil 99,995** e a **limpeza dos 7 dias anteriores a cada falha** ligada — e sem a exclusão de uma hora ao redor dos alarmes. Tirando qualquer uma dessas peças ele cai: na grade de 2 minutos, varrendo 360 combinações das três variantes, o teto é 5 de 8. O PCA faz 6 de 8 no seu ponto e continua em 6 de 8 na vizinhança dele.

Ele é muito mais sensível à grade de busca que o PCA

Na varredura de arquiteturas, que fixou os fatores baratos em poucos valores para caber no orçamento de tempo, o autoencoder apareceu com **1 de 8** — a pior arquitetura do conjunto. No refino, com a mesma janela de baseline, chegou a 6 de 8. O 1 de 8 era artefato: a grade grossa não continha o ponto de operação dele. O PCA, no mesmo teste, faz 6 de 8 nas duas varreduras. Para operação, essa robustez conta: um modelo que só funciona num canto estreito do espaço de parâmetros é mais frágil a mudança de regime do equipamento.

Sobre "PCA não é IA"

Vale desfazer a oposição. O que o PCA faz aqui é **aprendizado de máquina**, na modalidade não supervisionada: o modelo não recebe rótulo de falha nenhum — ele aprende sozinho, a cada mês, a estrutura de correlação entre 26 sensores e mede o quanto cada instante se afasta dela. É a técnica clássica de detecção de anomalia em processo industrial, e o autoencoder é a versão em rede neural do *mesmo* princípio: comprimir e reconstruir, e olhar o resíduo.

E o modelo é só uma peça do sistema. O que sustenta o resultado é a máquina em volta dele: **retreino automático mensal** com política de janela móvel, **quatro sinais independentes** que precisam concordar, e uma **busca automática de configuração** que avaliou 60.048 combinações de modelo, limiar, suavização e persistência sob protocolo temporal estrito. Trocar o PCA pelo autoencoder muda uma peça e mantém tudo o mais.

A **recomendação**: se o requisito for rede neural, o autoencoder entrega a mesma detecção — 6 de 8, com a mesma distribuição pelos trimestres — e já está pronto na busca. O preço é antecedência 5,7 h menor, um ponto de operação mais estreito e trinta vezes mais custo de retreino. Nada impede também **rodar os dois em paralelo** e alarmar quando qualquer um deles alarmar: as falhas que cada um pega não são exatamente as mesmas, e essa união ainda não foi medida.

PARA QUEM FOR MEXER

Três coisas que não são óbvias

Limpar o baseline sem recalibrar o limiar piora o resultado

Observado três vezes em 26/08/2026, com o mesmo mecanismo. O limiar é um percentil do score do próprio baseline; quando se removem amostras contaminadas, a cauda do baseline se concentra e o percentil desaba — em 12/2025 o limite de temperatura caiu a 3% do valor anterior ao remover 155 h. O detector fica muito mais sensível e, no mesmo percentil, isso vira falso positivo. Qualquer limpeza precisa vir acompanhada de nova varredura de limiar.

A janela de 3.000 h não entrega 3.000 h

A série começa em jan/2025, então os primeiros retreinos não têm o histórico pedido e a janela é truncada — a média efetiva é ~2.400 h. Parte do ganho desta política vem de retreinos que, na prática, foram acumulativos. Para testar janelas grandes de verdade é preciso partida a quente com 2024.

Oito falhas é pouco para escolher entre modelos parecidos

A diferença entre esta política e a anterior é *um* evento — o de 26/02/2026. Isso sustenta a escolha, mas não sustenta ranking fino entre arquiteturas. Duas configurações que empatam em 6 de 8 devem ser separadas por distribuição temporal do alerta e por antecedência, não pela contagem.

Onde isto vive no código. Toda a lógica está em `scripts/automl_clearml.py`, que é autocontido de propósito: os workers do ClearML recebem só esse arquivo. Os parâmetros de limpeza e avaliação são constantes no topo do arquivo; a operabilidade está em `DataBundle.grid()`; os quatro sinais em `WalkForwardEvaluator.raw_scores()`; a decisão e o placar em `evaluate()`. O desenho das figuras usa `src/cabiunas_pdm/replay.py`, que importa esse mesmo arquivo por caminho para garantir que gráfico e busca usem exatamente o mesmo cálculo — há uma assertão que quebra a execução se os dois divergirem.

Como reproduzir o placar. Rodar o replay com a configuração da primeira seção; ele lê os scores do cache em `data/interim/` quando existem e imprime a linha `[replay] ... → 6/8 eventos | lead 18.3 h | FP 0.94/mês`.