

Detecção de anomalias

Estado do modelo e decisões pendentes

O treino estendido para 2024 resolveu o TC382_03_A: 86,2% de recall na janela completa contra 51,7% do controle, com 17 de 17 incidentes detectados fora da amostra. A caça ao falso positivo fechou duas famílias de solução e abriu uma terceira.

O que falta agora não é modelagem — é escolher um ponto de operação.

17/17

incidentes detectados
fora da amostra (2025)

0,103

falsos alarmes por dia
um a cada 10 dias

–38%

de falso positivo possível
custando 6,9 pp de recall

nada

em produção — bundles
atuais são de junho/v9

Onde o modelo está

O melhor candidato é POR SENSOR, não um modelo só. O treino estendido para junho/2024 promoveu no TC382_03_A e piorou no T5 — cada um fica com sua receita.

SENSOR	RECEITA VENCEDORA	FULL	OOS 2025	BACKCAST 2024	FA/DIA
TC382_03_A	b2024 — treino jun/24→jul/25	86,2%	17/17	21,4%	0,103
TC382_03_A	controle — treino jan→jul/25	51,7%	17/17	21,4%	0,172
T5_AVG_A	controle / v10	100%	1/1 (!)	83,3%	0,082
T5_AVG_A	b2024	81,8%	1/1 (!)	50,0%	0,151

Protocolo honesto: incidentes HI/HIHI com máquina ligada, horizonte de 8 h, recall_raw (sem crédito da cauda do sticky), duty pós-sticky ≤ 0,25. O OOS do T5 tem UM incidente — aquele 100% não sustenta conclusão nenhuma, está na tabela por completude.


O QUE O GANHO DO B2024 NÃO É

O backcast de 2024 ficou idêntico nos dois braços (21,4%). Ou seja: o modelo não aprendeu o regime de 2024. O ganho de 34,5 pp veio do threshold global se reposicionar quando o histórico de treino mudou — é um ganho real e reprodutível, mas pela razão errada, e por isso não transfere para outros sensores.

Ruído de semente neste problema é de ±27 pp. Por isso toda comparação usa um braço de controle re-treinado, nunca o número histórico.

A figura da próxima página mostra os dois braços lado a lado, com os alarmes registrados no DCS numa pista própria e os alertas do modelo classificados em detecção, perda e falso positivo.


Alarmes detectados × alarmes registrados no DCS



Painel 1: temperatura bruta. Pista 'alarme DCS': os 70 eventos HI/HIHI reais (onset→OK) — a verdade de campo. Painéis 3 e 4: o health index de cada braço sob UM único threshold. Verde = incidente detectado (cruzamento bruto em até 8 h antes); vermelho = incidente perdido; laranja = episódio de alerta sem nenhum alarme por perto, o falso positivo. Cinza = equipamento desligado.

Antecedência: o alerta acende antes do alarme

TC382_03_A — zoom nos incidentes OOS (v10, hl=4h, q=0,840): alerta amarelo ativo antes do HI/HIHI (linha vermelha)



A figura anterior comprime 23 meses e esconde o que mais importa operacionalmente: quanto tempo antes o alerta acende. Aqui, três incidentes fora da amostra em detalhe. A linha vermelha é o alarme HI/HIHI do DCS; a faixa amarela é o alerta do modelo já ativo.

Dois dos três dão 8 h de antecedência — o horizonte máximo que a métrica credita. O de 20/10/2025 dá 0,3 h: é detecção, mas praticamente simultânea ao alarme. A mediana de antecedência na janela completa é de 7,4 h.

Falso positivo: três famílias testadas

Um falso positivo aqui é UM EPISÓDIO de alerta sem nenhum alarme do DCS em [início, fim + 8h]. São 71 episódios em 687 dias. Testei três famílias, todas como pós-processamento — nenhuma exige retreinar.

1. Amplitude — encerrada

Histerese e confirmação k-de-N trocam falso positivo por detecção na razão de 1 para 1. A causa foi medida: o pico do score no falso positivo é tão alto quanto no evento real (AUC 0,44, ligeiramente MAIOR no FP). Subir a barra não seleciona nada. O falso positivo não é tremor marginal no limiar — é excursão de amplitude legítima que não se sustenta.

2. Contexto operacional — 6 a 8 vezes melhor de troca

Os falsos positivos acontecem MANOBRANDO; os eventos reais acontecem com a máquina estável e quente. Na janela do disparo, a rampa de carga mediana é de 172 °C/h nos FPs contra 21 °C/h nos eventos reais. Um portão que suprime o disparo durante manobra custa ZERO de antecedência — a rampa já é conhecida no instante do alerta.


REGRA	FP	RECALL	FA/DIA	FP REMOVIDOS POR INCIDENTE PERDIDO
histerese	66	44/58	0,096	0,8
k-de-N (6 h, 90%)	50	32/58	0,073	1,2
rampa < 80 °C/h + T5 ≥ 600 °C	44	46/58	0,064	6,8
só nível T5 ≥ 640 °C	33	45/58	0,048	7,6
ponto atual (sem portão)	71	50/58	0,103	—

POR QUE EU NÃO PROMOVI ISSO SOZINHO

Fixei o critério ANTES de rodar: FA cair 30% perdendo no máximo 5 pp de recall E manter 17/17 no OOS. Nenhum ponto passou — o melhor perde por um único incidente na régua de recall e cai para 16/17 no OOS. Não afrouxei o critério depois de ver o resultado.

Risco físico: as medianas de rampa diferem 8×, mas as caudas se sobrepõem. 7 dos 58 incidentes reais têm rampa acima de 40 °C/h (máximo 222). Falha durante manobra existe, e o portão a apagaria.

A fronteira: quanto de recall custa cada falso alarme evitado



O que a curva diz

A curva de contexto DOMINA a de amplitude em toda a faixa: para a mesma perda de recall, remove muito mais falso positivo.

3. Graduação de confiança

O alerta acende no mesmo instante de hoje; nada é suprimido nem atrasado. Seis horas depois o nível é revisto pela SUSTENTAÇÃO do sinal.

REVISÃO	FP REBAIXADOS	REAIS MANTIDOS
3 h conservadora	26/71 (37%)	25/29 (86%)
6 h recomendada	46/71 (65%)	24/29 (83%)
12 h agressiva	55/71 (77%)	20/29 (69%)

Um evento real rebaixado NÃO é um incidente perdido: o alerta existe e está visível, só num nível menor. É por isso que a graduação vale onde o portão não vale.

As duas decisões e o que está pendente

DECISÃO DE OPERAÇÃO · TIME

Qual ponto de operação o campo quer?

Manter 86,2% de recall com um falso alarme a cada 10 dias, ou aceitar 79,3% com um a cada 16 dias? É escolha de negócio, não técnica: depende de quanto custa uma ida a campo em falso contra o valor de pegar mais um evento. Recomendo decidir antes de gerar o bundle, porque o ponto fica gravado nele.

DECISÃO DE ESCOPO · TIME

Qual candidato vira a referência oficial?

Existem três — v9, v10 e agora o b2024 — e nenhum está deployado. O README aponta v9; a documentação interna preferia v10; o b2024 é o melhor no TC382_03_A e o pior no T5. Isso trava a geração do bundle há semanas. Recomendação: b2024 no TC382_03_A e a receita de controle no T5, assumindo de vez que a configuração é por sensor.

Pendências prontas para executar

- Gerar o bundle de inferência do TC382_03_A/b2024 — hoje ele só existe como task do ClearML, não como artefato de produção.
- Implementar a graduação de confiança no bundle (pós-processamento, sem retreino).

Pendências que dependem de dado da Petrobras

- Re-extração do NGP_A. O export record_2025 está truncado no primeiro dia de cada mês (~1000 registros por tag). Só janeiro e maio são utilizáveis em 2025, o que impede auditar agosto com o árbitro físico de 'equipamento ligado'.
- Séries dos sensores novos nos anos anteriores (já solicitadas). Sem elas, o TI_0305 fica como piloto de 4 incidentes.

RESSALVA DE MÉTODO QUE VALE REPETIR

'Falso positivo' significa 'o DCS não alarmou', não 'não estava acontecendo nada'. Se o modelo pegar uma degradação real que nunca cruzou o setpoint de HI, ela nos penaliza. Foi só olhando curva a curva que confirmamos que os FPs de agosto/2025 eram rampa de descarga.

Reprodutível a partir de sweep_onset_rules_offline.py, sweep_load_gate_offline.py e eval_confidence_grading_offline.py — os três reproduzem o ponto de operação da auditoria antes de comparar e abortam se não bater.