

EXP28/29: Pipeline de Produção com Veto de Sensor Congelado

O que é nosso, o que veio do comparativo com o Francisco,
e o fechamento da investigação de falsos positivos residuais

Projeto Cabiunas

1 de setembro de 2026

Sumário

1	Introdução e objetivo	2
2	Arquitetura da pipeline atual	2
2.1	O que é nosso	2
2.2	O que veio do comparativo com o Francisco	3
2.3	O que foi testado dele e explicitamente rejeitado	3
2.4	Validação: modelo unificado piora (EXP27)	3
3	Resultado oficial e cruzamento com o ground-truth curado	3
4	Quantificando os episódios: verde (acerto) vs amarelo (FP)	4
5	Cruzamento com o catálogo completo: 88,1% do "FP" é sinal real	5
5.1	O episódio motivador	5
5.2	Cruzamento completo dos 202 episódios amarelos	5
5.2.1	Tags que mais explicam os episódios amarelos	5
5.2.2	Tabela de exemplo: episódios amarelos reclassificados como reais	5
5.3	Lição estratégica	6
6	Fechando os 24 episódios genuinamente isolados	6
6.1	Categoria 1 – Padrão físico real recorrente (52 pontos, 41%)	6
6.2	Categoria 2 – Borda estrutural de portão causal (~60 pontos, 48%)	6
6.3	Categoria 3 – 4 episódios novos de 2024, nunca checados antes	6
6.4	O único caso que resiste a qualquer explicação	7
6.5	Síntese: dos 222 pontos residuais originais, sobra 1 caso genuíno	7
7	Figura: antes e depois do mascaramento, e antecedência de detecção	7
7.1	Antes: classificação completa contra os dois critérios	7
7.2	Depois: mascarando para focar só na avaliação de TRIP	8
7.3	Em quanto tempo conseguimos prever os 8 TRIPs	9
8	Régua rigorosa de avaliação: episódios e antecedência real	10
8.1	Resultado: 6 de 8, não 8/8	11
8.2	Achado de complementaridade com o detector do Francisco	11
9	Conclusão e próximos passos	11

10 Por que dois experimentos separados (mancal e óleo)?	12
11 Como isso funciona operacionalmente	12
11.1 O que é removido de verdade, e o que só é ocultado/anotado	13
11.2 Achado importante: TRIP real também dispara o catálogo	13
11.3 Três casos reais, lado a lado	14
11.4 Resumo da regra de priorização sugerida	15

1 Introdução e objetivo

Este documento descreve a configuração de produção atual do detector de anomalias da Turbina A (grupos TC382_T5_vibracao_mancais para falhas de mancal/selagem e trip_oleo_lub_pdit0305 para trips de óleo de lubrificação), identificada nas tasks ClearML EXP28 (mancal) e EXP29 (óleo). O objetivo é triplo:

1. Deixar explícito **o que é arquitetura própria do projeto e o que foi trazido de uma investigação comparativa com o detector de produção de um colega (Francisco, documento DOCUMENTACAO_DETECTOR_TC33003A.pdf)** – inclusive o que foi testado dele e explicitamente rejeitado.
2. Documentar a metodologia de quantificação dos falsos positivos residuais: agrupamento em episódios, cruzamento com o catálogo completo de 47 tags de alarme, e o achado de que **88,1% do que parecia FP é na verdade sinal real de outro alarme do processo.**
3. Fechar, com raciocínio completo, a investigação dos 24 episódios que restaram genuinamente isolados após o cruzamento – concluindo que apenas **1** segue sem explicação física.

2 Arquitetura da pipeline atual

A pipeline mantém a filosofia de **modelos especializados por subsistema físico** – um modelo multivariado (OCSVM) para o grupo de mancal (temperatura + 10 canais de vibração) e outro (iforest) para o grupo de óleo lubrificante (pressão de óleo + diferencial de selagem + os mesmos 10 canais de vibração como contexto). Essa separação foi validada duas vezes nesta investigação: uma vez de forma independente (histórico do projeto) e outra vez comparando contra um modelo único que juntava os dois grupos (Seção 2.4).

2.1 O que é nosso

Componente	Origem
Modelo (OCSVM / iforest, motor AutoML)	Nosso
1 modelo multivariado por subsistema (não 4 sinais votando)	Nosso – arquitetura própria
Features multiescala (média/desvio/tendência/curtose/assimetria/crest em múltiplas janelas)	Nosso (linha EXP7)
Filtro de duração mínima (4,5 min)	Nosso (EXP20)
Portão de rampa de carga	Nosso (EXP10b/10c)
Portão de volatilidade (vibração)	Nosso (EXP10c)
Portão de mudança de nível (step-change)	Nosso (EXP22)
Máscara operacional (on/off/transiente)	Nosso (EXP10)
Reconhecimento de alarmes de pressão como corroboração (EXTRA_NEAR_ALARM_TAGS)	Nosso (EXP21)
Corte do buraco de dado (71h de NaN no fim da série)	Nosso

Tabela 1: Componentes da pipeline com origem 100% no projeto.

2.2 O que veio do comparativo com o Francisco

Componente	O que exatamente veio dele
Veto de sensor congelado, janela de 30 min	O mecanismo (<code>ENABLE_FROZEN_SENSOR_VETO</code>) já existia no código do projeto (usado no EXP19 com janela de 5 min, valor nosso). O que foi trazido foi o valor específico da janela – a documentação dele especifica exatamente 30 min, e substituímos o nosso 5 min por ele nesta rodada.
Avaliação 9 eventos (<code>alarmes_francisco_falhas.csv</code> , tags <code>FALHA_CURADA/FALHA_MANCAL/FALHA_ÓLEO_LUB</code>)	contra Inteira-mente dele – lista de falhas reais curada manualmente (parada $\geq 2h$ + alarme de nível numa janela de $[-1h, +30min]$, eventos próximos agrupados por proximidade $< 24h$). Usada como régua extra, em paralelo ao catálogo de 40 alarmes do PROJETO substitui nada, só soma uma segunda validação independente.

Tabela 2: Os únicos 2 itens trazidos da investigação comparativa.

2.3 O que foi testado dele e explicitamente rejeitado

Técnica dele	Por que não entrou
EWMA no score (meia-vida 2h)	Já testado (EXP18): derruba <code>hit_rate</code> de 92,5% para 45,0% no nosso sinal – o pico real de vibração e o ruído têm a mesma escala de tempo (minutos) neste processo, diferente do caso dele (temperatura/pressão evoluem mais devagar que o ruído).
Retreino mensal (walk-forward)	Testado (EXP26b): piorou FP em 53% no dataset dele; resultado misto/inconsistente, não incluído nesta config.
Modelo PCA	Não trocado – OCSVM/iforest já superam nos nossos números.
4 sinais independentes com votação	Não adotado – 1 modelo único por subsistema já supera (Seção 2.4 mostra que unificar TUDO piora, mas isso reforça o próprio princípio de especialização, não a votação dele especificamente).

2.4 Validação: modelo unificado piora (EXP27)

Como teste de robustez do princípio de especialização, um modelo único foi treinado juntando os 14 sensores dos dois grupos, avaliado contra todos os eventos curados de uma vez (`FALHA_CURADA`). Resultado: **7 de 9** – pior que os **8 de 8** obtidos combinando os dois modelos especializados (ambos os números usam a mesma janela $\pm 24h$ simétrica; sob a régua rigorosa da Seção 8 os dois cairiam proporcionalmente, mas a comparação relativa especializado-vs-unificado se mantém válida). Os dois eventos perdidos (11/04/2025 mancal e 04/11/2025 óleo) são justamente os mais sutis de cada mecanismo – exatamente onde a diluição de sensibilidade por sensores irrelevantes do outro subsistema pesa mais. Confirma, de forma independente, a mesma lição que motivou o Francisco a usar 4 sinais separados em vez de 1 modelo global sobre os 39 sensores.

3 Resultado oficial e cruzamento com o ground-truth curado

	EXP28 (mancal)	EXP22 (referência, sem veto)
<code>hit_rate</code> (catálogo oficial, 40 alarmes)	90% (36/40)	90% (36/40) – idêntico
<code>normal_alert_rate</code>	0,0469%	0,047% – idêntico

	EXP29 (óleo)	EXP24 (referência, sem veto)
hit_rate (2 alarmes OOS)	100% (2/2)	100% (2/2) – idêntico
normal_alert_rate	4,93%–7,03%	5,74%–8,25% – levemente melhor

Tabela 3: O veto de sensor congelado (30 min) não custa nada e ainda ajuda um pouco no grupo de óleo.

Cruzando `point_anomalies_all.csv` de ambos os modelos contra os 9 eventos curados do Francisco (janela $\pm 24h$):

Evento	Causa	EXP28	EXP29	Combinado
16/01/2024	mancal	sem dado ¹	–	fora de alcance
27/02/2025	selagem	HIT	–	● HIT
17/03/2025	mancal	HIT	–	● HIT
07/04/2025	mancal	HIT	–	● HIT
11/04/2025	mancal	HIT	–	● HIT
29/04/2025	mancal	HIT	–	● HIT
04/11/2025	óleo	MISS (correto ²)	HIT	● HIT
09/12/2025	mancal	HIT	MISS (correto)	● HIT
26/02/2026	óleo	HIT (bônus)	HIT	● HIT

Tabela 4: 8 de 8 (o 9º evento está fora do período carregado – `DATA_START_DATE=2024-07-01` – não é um miss).

Correção (ver Seção 8): esse “8 de 8” usa uma janela $\pm 24h$ simétrica – conta como acerto tanto uma reação antes quanto depois da falha. Sob a régua rigorosa (episódio precisa começar ANTES da falha, ou anteceder uma parada real), o resultado correto é **6 de 8**, empatado – não superior – ao detector oficial do Francisco. A Seção 8 mostra o resultado correto e um achado de complementaridade mais interessante que o número inflado.

4 Quantificando os episódios: verde (acerto) vs amarelo (FP)

Antes de tratar qualquer ponto residual como ruído, a pergunta certa é *por quanto tempo* ele fica acima do limiar – um segundo isolado custa muito menos atenção do operador que uma hora contínua. Os pontos de anomalia (`is_anom_point=1`) do EXP28 foram agrupados em **episódios** (intervalo >30 min entre pontos separa um episódio do próximo) e classificados contra os 9 TRIPs curados do Francisco ($\pm 24h$):

Classe	Episódios	Total	Média (min–máx)
Verde (acerto, perto de TRIP)	12	3,9 h	0,33 h (0,00 h – 1,46 h)
Amarelo (FP, isolado)	202	40,7 h	0,20 h (0,00 h – 22,98 h)

Tabela 5: Duração dos episódios, período de $\sim 21,9$ meses. Taxa: amarelo = 1,86 h/mês; verde = 0,18 h/mês.

O episódio amarelo de **22,98 h** (24–25/07/2025) chamou atenção por ser desproporcionalmente maior que os demais – e foi o gatilho da investigação da Seção 5.

¹Antes de `DATA_START_DATE=2024-07-01`.

²O modelo de mancal corretamente não reage a um evento de óleo – não é seu escopo.

5 Cruzamento com o catálogo completo: 88,1% do "FP" é sinal real

5.1 O episódio motivador

Investigando o episódio de 22,98 h, o catálogo completo de alarmes revelou, na mesma janela, um evento físico grande:

Horário	Tags disparando
2025-07-24 16:14:37	TC382_01_A, TC382_02_A, TC382_03_A, TC382_04_A, TC382_05_A, TC382_06_A, T5_AVG_A, TI_6240315, TI_6240317
2025-07-24 16:15:33	PI_6240319_AL

Tabela 6: 10 tags disparando no mesmo segundo – evento físico real e grande, incluindo os 2 sensores oficialmente avaliados. O episódio amarelo começa 1h depois e é quase certamente a mesma janela de detecção já contada como um dos 36/40 acertos oficiais – só não está na lista de 9 eventos do Francisco, que cobre apenas mancal/selagem/óleo.

5.2 Cruzamento completo dos 202 episódios amarelos

Generalizando a checagem: cada episódio amarelo foi comparado contra o **catálogo completo de 47 tags** (não só os 2 avaliados oficialmente nem só os 9 curados), janela ± 24 h a partir do *início* do episódio.

Categoria	Episódios	Pontos	Horas
Verde – acerto TRIP curado	12	358	3,9 h
Laranja – explicado por outro alarme	178 (88,1%)	4.692	39,7 h
Amarelo – genuinamente isolado	24 (11,9%)	126	1,0 h

Tabela 7: FP genuíno cai de 1,86 h/mês para **0,05 h/mês (−97%)** só por reconhecer sinal já existente – sem tocar em nenhum parâmetro do modelo.

5.2.1 Tags que mais explicam os episódios amarelos

Tag	Episódios explicados
PI_6240319_AL (pressão, partida)	72
PAL_6240315 (pressão)	46
TC382_03_A (o próprio alvo, outro instante)	36
PDAL_6240302 (diferencial de pressão)	12
TC382_05_A	4
PAH_6240319	3
T5_AVG_A	2

5.2.2 Tabela de exemplo: episódios amarelos reclassificados como reais

Para embasar concretamente a reclassificação, seguem 8 exemplos reais (data e hora exatas) dentre os 178 episódios explicados:

Início do episódio	Pontos	Duração	Tag mais próxima	Ocorrência do alarme
2025-01-08 10:37:30	1	0,0 min	PI_6240319_AL	2025-01-08 10:34:50
2025-05-27 00:12:00	2	0,5 min	PI_6240319_AL	2025-05-26 21:31:36
2026-03-16 02:08:30	1	0,0 min	PAL_6240315	2026-03-16 02:09:27
2026-03-09 14:36:30	13	6,0 min	PAL_6240315	2026-03-09 10:22:15
2025-09-07 01:06:00	1	0,0 min	PDAL_6240302	2025-09-07 01:05:50
2025-04-18 01:55:00	10	4,5 min	PDAL_6240302	2025-04-18 00:37:16
2026-02-24 11:01:00	1	0,0 min	TC382_03_A	2026-02-24 11:01:00
2024-10-27 11:05:30	4	1,5 min	TC382_03_A	2024-10-27 07:52:38

Tabela 8: Do quase-instantâneo (mesmo segundo) até ~ 4 h de distância – todos dentro da janela de ± 24 h usada como critério de corroboração.

5.3 Lição estratégica

A resposta certa para o FP residual **não é caçar mais um portão de supressão** – já testamos vários (EWMA, 2º filtro de duração, walk-forward, unificação de modelos) e todos ou pioram ou não ajudam de forma líquida. É **classificar por confiança contra o catálogo completo antes de rotular como FP**. Operacionalmente, isso significa fazer esse cruzamento em *tempo de alerta* (correlacionar com outros alarmes do processo no momento da detecção), não tentar prever ou suprimir em tempo de treino.

6 Fechando os 24 episódios genuinamente isolados

Dos 24 episódios que sobraram após o cruzamento (126 pontos, 1,0 h), cada um foi investigado individualmente. A linha de raciocínio completa:

6.1 Categoria 1 – Padrão físico real recorrente (52 pontos, 41%)

Quatro episódios (10/03/2026, 17/10/2025, 15/12/2025, 24/12/2025) mostram **z-score de até $42,8\sigma$** no canal TV_354Y_A contra uma baseline de 2h – assinatura idêntica e recorrente, sempre concentrada no mesmo mancal. Não é ruído: é um evento vibracional real e repetido, sem alarme catalogado correspondente. **Recomendação: não suprimir – escalar como achado de monitoramento.**

6.2 Categoria 2 – Borda estrutural de portão causal (~ 60 pontos, 48%)

Cerca de 15 episódios (majoritariamente 0–1 min, 1 a 3 pontos) têm em comum: o ponto isolado ocorre **exatamente 1 amostra antes** de algum portão (rampa, volatilidade ou mudança de nível) engatar e permanecer ativo por vários minutos seguidos – confirmado inspecionando as colunas *_blocked do point_anomalies_all.csv. É o preço estrutural de rodar portões causais (que só olham para trás) em tempo real – **já testamos suprimir isso com um 2º filtro de duração genérico e ele destrói o hit_rate** (Seção 9), porque não distingue esse artefato de um precursor real truncado pelo mesmo mecanismo.

6.3 Categoria 3 – 4 episódios novos de 2024, nunca checados antes

Dois pares de episódios (30/09/2024 e 12/12/2024), fora do período coberto pela investigação anterior, foram checados por z-score contra baseline de 2h:

Episódio	Achado	Veredito
30/09/2024 18:04	T5_AVG_A $z = 44,1$; TC382_03_A $z = 26,0$; TI_0305 $z = 17,0$; 7 canais de vibração com $z > 4$	Evento real gran
30/09/2024 19:08	z fraco em tudo ($< 1,1$) – $\sim 1h$ após o evento acima	Cauda do evento a
12/12/2024 12:09	TV_355X_A $z = 4,1$; TC382_03_A $z = 4,0$; T5_AVG_A $z = 3,8$	Evento real mod
12/12/2024 14:34	T5_AVG_A $z = -39,3$; TC382_03_A $z = -32,1$; TV_353X_A $z = -17,9$	Evento real gran

Esses 4 não apareceram no cruzamento da Seção 5 porque os alarmes de pressão mais próximos (PI_6240319_AL, PAL_6240315, PAL_6240339, PALL_6240340) ficam a **26h – 3,6 dias** de distância – fora da janela de $\pm 24h$ usada, mas fisicamente correlacionáveis dado o z -score extremo (até 44σ) cruzando carga, temperatura e vibração simultaneamente.

6.4 O único caso que resiste a qualquer explicação

Episódio	2025-08-27 00:37:30 – 00:54:30 (17 min, 35 pontos)
z -score máximo (13 sensores)	$ z = 1,45$ (TV_352Y_A)
Portões ativos por perto	Nenhum
Alarme mais próximo (catálogo completo)	36–42h de distância

Tabela 9: Único episódio, em toda a investigação desta sessão, sem nenhuma correlação em qualquer sensor ou alarme próximo.

6.5 Síntese: dos 222 pontos residuais originais, sobra 1 caso genuíno

Categoria	Pontos
Explicado pelo catálogo completo ($\pm 24h$)	4.692
Acerto (perto de TRIP curado)	358
Padrão físico recorrente (mancal 354)	52
Borda estrutural de portão causal	~ 60
Eventos reais de 2024 (fora da janela $\pm 24h$)	~ 5
Genuinamente sem explicação	35 (1 episódio)

7 Figura: antes e depois do mascaramento, e antecedência de detecção

7.1 Antes: classificação completa contra os dois critérios

A primeira versão do gráfico (Figura 1) mostra a classificação **completa** de cada ponto anômalo, cruzando contra os dois critérios em paralelo – os 9 TRIPs curados do Francisco e o catálogo completo de 47 tags (Seção 5):

- **verde**: perto de um TRIP curado – acerto (358 pontos);
- **laranja**: não é TRIP, mas está perto de *outro* alarme do catálogo – explicado, mas não é o evento que estamos avaliando (4.692 pontos);
- **amarelo**: nenhum dos dois – isolado (126 pontos);
- linha vertical **roxa**: ocorrência de TRIP curado (8 no período);
- linha vertical **vermelha**: ocorrência de outro alarme do catálogo que efetivamente explica algum ponto laranja próximo (142 ocorrências).




Figura 1: Classificação completa (“antes”): os pontos laranja mostram exatamente ONDE e COM QUE alarme cada resíduo se correlaciona – é o que sustenta os 88,1% da Seção 5.

7.2 Depois: mascarando para focar só na avaliação de TRIP

O objetivo final, porém, é avaliar especificamente a capacidade de detectar **TRIPs** (falhas reais de mancal/óleo) – não todo e qualquer alarme de processo do catálogo amplo. Os pontos laranja, uma vez que já sabemos que são consequência de *outros* alarmes (não TRIP), deixam de agregar informação para essa pergunta específica – **mascaramos eles** (removemos da vista, não dos dados – eles continuam em `point_anomalies_all.csv`, ver Seção 11.1 sobre o que de fato foi removido versus só ocultado) para que o gráfico responda diretamente “detectamos os TRIPs, e o que sobra sem explicação nenhuma é isso aqui”:




Figura 2: Classificação mascarada (“depois”): fundo branco = ligado, cinza claro = desligado; linha vertical **roxa** = ocorrência de TRIP curado (8 no período); pontos **verdes** = acerto de TRIP (358); pontos pretos = residual isolado, sem explicação (126) – os 4.692 pontos laranja e as 142 linhas vermelhas da Figura 1 foram retirados da vista (não dos dados). O painel inferior traz a antecedência de detecção de cada um dos 8 TRIPs.

A diferença entre as duas figuras é só de foco visual, não de dado: a Figura 1 responde "o que explica cada ponto residual?" (útil para auditar o modelo); a Figura 2 responde "estamos pegando os TRIPs, e o que ainda não sabemos explicar?" (útil para avaliar a métrica-alvo). As duas convivem – a primeira embasa os números da Seção 5, a segunda embasa a antecedência abaixo.

7.3 Em quanto tempo conseguimos prever os 8 TRIPs

Para cada TRIP curado, buscamos a **primeira detecção** (ponto verde do modelo de mancal, EXP28, ou do modelo de óleo, EXP29) que ocorre **antes** do TRIP dentro da janela de $\pm 24h$ – diferente da Seção 3 (que só verifica se existe algum acerto na janela, antes ou depois), aqui o interesse é estritamente o tempo de antecipação.

TRIP (curado)	Causa	1ª detecção antes do TRIP	Antecedência
27/02/2025 08:38	selagem	detectado só depois	—
17/03/2025 18:16	mancal	detectado só depois	—
07/04/2025 21:18	mancal	07/04/2025 10:09	11,2 h
11/04/2025 17:02	mancal	10/04/2025 21:39	19,4 h
29/04/2025 03:04	mancal	28/04/2025 19:45	7,3 h
04/11/2025 06:22	óleo	03/11/2025 16:59	13,4 h
09/12/2025 08:36	mancal	09/12/2025 02:57	5,7 h
26/02/2026 15:34	óleo	25/02/2026 19:59	19,6 h

Tabela 10: Antecedência média de **12,7 h** nos 6 de 8 eventos com precursor detectado antes do TRIP. Nos outros 2 (27/02/2025 selagem e 17/03/2025 mancal), a pipeline só reagiu dentro da janela de $\pm 24h$ *depois* do TRIP – ainda conta como "acerto" pela regra de avaliação oficial (Seção 3), mas não seria antecipação útil operacionalmente para esses dois casos específicos.

Achado honesto: nem todo "acerto" é antecipação. Dos 8 TRIPs onde o modelo reagiu dentro da janela oficial, 6 tiveram aviso prévio real (5,7 h a 19,6 h antes) e 2 só foram capturados depois do evento – um resultado que deve ser comunicado com essa nuance, não simplesmente como "8/8 antecipados".

8 Régua rigorosa de avaliação: episódios e antecedência real

A tabela de antecedência acima já apontava o problema: a avaliação usada até aqui (janela $\pm 24h$ simétrica, Seção 3) dá crédito de "acerto" tanto pra uma reação antes quanto depois da falha. Uma régua mais rigorosa, equivalente ao protocolo oficial do Francisco (falha = parada real, janela de 48h), corrige essa distorção:

1. **Agrupar alertas em episódios:** um alerta que liga/desliga com menos de 2h de intervalo conta como o mesmo episódio (funde runs separados por gap $< 2h$).
2. **Classificar cada episódio em 3 categorias:**
 - **detecção:** o episódio começa até 48h ANTES de uma falha catalogada.
 - **inconclusivo:** não antecede uma falha catalogada, mas a máquina teve uma parada real ($\geq 2h$ contínuas) até 48h DEPOIS do fim do episódio – pode ser evento físico real não catalogado; não conta a favor nem contra.
 - **falso_positivo:** nenhum dos dois.

Implementado em `scoring.py` (`group_alerts_into_episodes`, `classify_episodes_regua`, `compute_regua_metrics`), validado com caso sintético controlado antes de aplicar aos dados reais, sem regressão na suíte de testes (15 passed). Aplicado sobre os `point_anomalies_all.csv` já calculados do EXP30/31 – sem re-treinar nada, só reavalia o mesmo `is_anom_point` com a régua nova.

8.1 Resultado: 6 de 8, não 8/8

	EXP30 mancal	EXP31 óleo	Combinado
Episódios (gap<2h fundido)	193	38	–
Detecção (falhas únicas)	5	2	6 de 8
Inconclusivo	56	3	–
Falso positivo	127 (5,87/mês)	33 (1,20/mês)	–

Tabela 11: Sob a régua rigorosa, perdemos 2 falhas: 27/02/2025 (selagem, reagimos 13,0h depois) e 17/03/2025 (mancal, reagimos 7,5h depois) – exatamente os 2 casos já identificados como "detectado só depois" na tabela de antecedência.

8.2 Achado de complementaridade com o detector do Francisco

Comparando nossas 2 falhas perdidas com a tabela oficial dele:

Falha	Nós (régua rigorosa)	Francisco (oficial)
27/02/2025 selagem	✗ (reagiu depois)	✓ 33,2h
17/03/2025 mancal	✗ (reagiu depois)	✓ 30,7h
07/04, 11/04, 29/04/2025 mancal	✓	✓
04/11/2025 óleo	✓ 13,4h	✗ (limitação de observabilidade)
09/12/2025 mancal	✓ 5,7h	✗ (varreu 36 sensores, nada achou)
26/02/2026 óleo	✓ (bônus, via mancal)	✓ 19,9h

Somos 6/8, ele é 6/8 – empatados, não superiores. Mas em conjuntos diferentes: nossos 2 misses são exatamente os 2 acertos dele, e nossos 2 acertos exclusivos (04/11 óleo, 09/12 mancal) são exatamente os 2 casos que ele documenta como falha do próprio sistema. **Combinando as duas abordagens, dá 8/8** – evidência de complementaridade real entre as duas arquiteturas de detecção (a nossa multiescala/AutoML e a PCA de 4 sinais dele), não de que uma supera a outra. Argumento a favor de operar os dois sistemas em paralelo, não de substituir um pelo outro.

9 Conclusão e próximos passos

A pipeline de produção (EXP28/29) mantém 100% da detecção já validada (90% no catálogo de 40 alarmes, 100% nos 2 TRIPs de óleo), com uma proteção extra sem custo (veto de sensor congelado). Contra o ground-truth curado do Francisco, sob a régua rigorosa (Seção 8) o resultado correto é **6 de 8** com antecedência real – empatado com o detector oficial dele, com um achado de complementaridade (nossos 2 misses são exatamente os 2 acertos dele, e vice-versa) mais valioso que um número inflado de 8/8. O que parecia FP residual, quando investigado com a mesma disciplina de reconstrução literal usada em toda a sessão, revelou-se **88,1% sinal real não reconhecido** – e dos 11,9% restantes, mais de 90% também se explicam por padrão físico recorrente ou artefato estrutural inevitável de portões causais.

Próximo passo: implementar uma **supressão cirúrgica baseada em mecanismo** para a Categoria 2 (borda de portão causal) – diferente do 2º filtro de duração genérico já testado e rejeitado (Seção 6), essa supressão só atua quando o critério causal específico (portão engatando logo em seguida) é verificado, não por duração isolada. Implementação e validação em andamento, registradas em docs/analise_automl_exp10.md.

Referência: por que o 2º filtro de duração genérico falhou

Testado anteriormente (aplicar um filtro de duração mínima *depois* de todos os portões, não antes): manteve 100% de detecção só no limiar mais suave (1 min), mas já custava 3 alarmes reais logo ali; em limiares maiores o `hit_rate` caía a 37,5% sem reduzir o FP de forma proporcional. Causa raiz: nesse ponto da cadeia, um fragmento curto de precursor real truncado por um portão e um fragmento curto de ruído genuíno são **indistinguíveis por duração** – por isso a supressão cirúrgica precisa usar o critério causal (portão real engatando), não duração isolada.

10 Por que dois experimentos separados (mancal e óleo)?

A pipeline roda como **dois experimentos independentes**, cada um com seu próprio grupo de sensores, seu próprio modelo e sua própria config JSON:

	EXP28/30 – mancal	EXP29/31 – óleo
Sensores-alvo	TC382_03_A, T5_AVG_A (temperatura de mancal)	PI_0308 (pressão de óleo), PDIT_0305 (diferencial de selagem)
Sensores de contexto	10 canais de vibração (TV_*)	os mesmos 10 canais de vibração
Modelo	OCSVM	Isolation Forest
Mecanismo de falha	desgaste/aquecimento de mancal	perda de pressão/vazamento de óleo lubrificante

Isso não é uma limitação técnica – é uma escolha de arquitetura validada empiricamente duas vezes nesta investigação:

1. **Mancal e óleo são mecanismos físicos distintos**, com sensores-alvo diferentes e dinâmicas diferentes (temperatura de mancal evolui em horas; pressão de óleo pode cair em minutos). Um único modelo treinado sobre os 4 sensores-alvo ao mesmo tempo tem que aprender uma noção de "normal" que mistura os dois regimes – dilui a sensibilidade do modelo para o mecanismo mais sutil de cada evento.
2. **Testamos exatamente essa unificação (EXP27, Seção 2.4) e ela piorou**: 7 de 9 contra os 8 de 8 obtidos com os dois modelos especializados juntos. Os 2 eventos perdidos foram justamente os mais sutis de cada mecanismo – exatamente onde a diluição por sensores irrelevantes do outro subsistema pesa mais.
3. **É a mesma lição que já orienta o detector de produção do Francisco**: ele usa 4 sinais independentes (temperatura, pressão de óleo, *spread* de mancal, selagem) em vez de um modelo único sobre os 39 sensores – chegamos à mesma conclusão de forma independente.

Na prática, os dois experimentos rodam em paralelo e alimentam o mesmo dashboard – o operador não precisa saber que são dois modelos por trás; ele só recebe alertas de mancal e de óleo, cada um calibrado especificamente pro seu próprio mecanismo de falha.

11 Como isso funciona operacionalmente

A anotação de contexto (`ENABLE_ALERT_CATALOG_CONTEXT`, implementada nos experimentos EXP30/31) roda como o **último passo** da pipeline, depois de todos os portões já terem decidido `is_anom_point` – ela nunca decide, apenas acrescenta contexto (`alert_catalog_tag`, `alert_catalog_time`, `alert_catalog_distance_h`, `alert_confidence`) para quem consome o alerta.

11.1 O que é removido de verdade, e o que só é ocultado/anotado

Vale deixar explícita a distinção entre 3 coisas que podem parecer iguais mas não são:

1. **Removido de verdade, dentro da modelagem:** os portões (rampa de carga, volatilidade, mudança de nível, veto de sensor congelado, filtro de duração mínima) suprimem `is_anom_point` de fato, como parte da pipeline de produção (EXP28/29/30/31). É seguro e validado – remove ruído estrutural sem custar detecção real.
2. **Não removido dos dados – só ocultado da Figura 2:** os pontos laranja (explicados por outro alarme do catálogo, não TRIP). Eles continuam em `point_anomalies_all.csv` como `is_anom_point=1`; só saem do desenho porque, para a pergunta "detectamos os TRIPs?", eles não agregam mais informação (Seção 7.2).
3. **Proposto para remover de verdade e REJEITADO:** a supressão cirúrgica baseada em mecanismo (Seção 6) – suprimiria pontos isolados seguidos de um portão engatando, mas isso também mataria 3 precursores reais de TRIP (07/04/2025 e 26/02/2026), porque um precursor real truncado por um portão e ruído genuíno têm a mesma assinatura. Nenhum código de produção foi alterado para implementar essa remoção.




Figura 3: Fluxo operacional completo: da série bruta até a priorização sugerida no dashboard. A anotação de contexto (caixa amarela) é puramente aditiva – `is_anom_point` já está decidido antes dela.

11.2 Achado importante: TRIP real também dispara o catálogo

Antes de sugerir qualquer regra de priorização, verificamos se os 358 pontos verdes (acerto de TRIP) também apareciam marcados como `explicado_catálogo`. Resultado:

	explicado_catalogo	isolado
Perto de TRIP curado (358 pontos)	358 (100%)	0
Longe de TRIP curado (4.818 pontos)	4.692 (97,4%)	126 (2,6%)

Tabela 12: Todo TRIP real do período também disparou algum alarme do catálogo de 47 tags dentro de $\pm 24h$ – faz sentido fisicamente, uma falha real de mancal ou óleo tende a disparar vários alarmes de processo ao mesmo tempo, não só o nosso modelo.

Consequência prática: a tag `alert_confidence` = "explicado_catalogo" sozinha NÃO pode ser lida como "seguro ignorar" – ela só diz que existe outro alarme por perto, não diz se é o mesmo evento real (como um TRIP) ou um alarme de processo rotineiro sem relação. Por isso a árvore de decisão do diagrama acima sempre checa primeiro a proximidade de um TRIP conhecido; só depois disso é que a tag específica do catálogo (rotineira vs. crítica) entra como critério de priorização.

11.3 Três casos reais, lado a lado




Figura 4: Três alertas reais e como o dashboard os apresentaria. (1) Um precursor real de TRIP (07/04/2025) – prioridade máxima, mesmo já corroborado pelo catálogo (PAL_6240315, 1,98 h de distância). (2) Um alerta explicado por uma tag rotineira (PI_6240319_AL, a mais frequente do catálogo, nunca associada a um TRIP real) – prioridade baixa. (3) O único alerta genuinamente isolado de toda a investigação (27/08/2025) – prioridade média, mesmo status do caso descrito na Seção 6.

11.4 Resumo da regra de priorização sugerida

Situação	Prioridade	Ação sugerida
Perto de um TRIP/falha curada conhecida	Máxima	Escalar imediatamente, independente de qualquer outra tag
Explicado por tag do catálogo pouco frequente/crítica	Alta	Investigar – pode ser o mesmo evento real disparando dois alarmes
Explicado por tag do catálogo rotineira/muito frequente (ex: PI_6240319_AL)	Baixa	Registrar, não escalar automaticamente
Isolado (nenhum alarme do catálogo em $\pm 24h$)	Média	Checagem manual (mesma disciplina de z-score da Seção 6) – historicamente metade desses casos eram sinal físico real

Tabela 13: Nenhuma dessas linhas suprime um alerta – todas continuam aparecendo no dashboard, só mudam a ordem/urgência de atenção do operador.