

EXP28/29: Pipeline de Produção com Veto de Sensor Congelado

O que é nosso, o que veio do comparativo com o Francisco,
e o fechamento da investigação de falsos positivos residuais

Projeto Cabiunas

1 de setembro de 2026

Sumário

1	Introdução e objetivo	2
2	Arquitetura da pipeline atual	2
2.1	O que é nosso	2
2.2	O que veio do comparativo com o Francisco	3
2.3	O que foi testado dele e explicitamente rejeitado	3
2.4	Validação: modelo unificado piora (EXP27)	3
3	Resultado oficial e cruzamento com o ground-truth curado	3
4	Quantificando os episódios: verde (acerto) vs amarelo (FP)	4
5	Cruzamento com o catálogo completo: 88,1% do "FP" é sinal real	5
5.1	O episódio motivador	5
5.2	Cruzamento completo dos 202 episódios amarelos	5
5.2.1	Tags que mais explicam os episódios amarelos	5
5.2.2	Tabela de exemplo: episódios amarelos reclassificados como reais	5
5.3	Lição estratégica	6
6	Fechando os 24 episódios genuinamente isolados	6
6.1	Categoria 1 – Padrão físico real recorrente (52 pontos, 41%)	6
6.2	Categoria 2 – Borda estrutural de portão causal (~60 pontos, 48%)	6
6.3	Categoria 3 – 4 episódios novos de 2024, nunca checados antes	6
6.4	O caso mais resistente a explicação (mas não mais o único)	7
6.5	Síntese (atualizada – ver Apêndice A)	7
7	Figura: antes e depois do mascaramento, e antecedência de detecção	7
7.1	Antes: classificação completa contra os dois critérios	7
7.2	Depois: mascarando para focar só na avaliação de TRIP	8
7.3	Em quanto tempo conseguimos prever os 8 TRIPs	9
8	Régua rigorosa de avaliação: episódios e antecedência real	10
8.1	Resultado: 6 de 8, não 8/8	11
8.2	Achado de complementaridade com o detector do Francisco	11
9	Conclusão e próximos passos	11

10 Por que dois experimentos separados (mancal e óleo)?	12
11 Como isso funciona operacionalmente	13
11.1 O que é removido de verdade, e o que só é ocultado/anotado	13
11.2 Achado importante: TRIP real também dispara o catálogo	14
11.3 Três casos reais, lado a lado	14
11.4 Resumo da regra de priorização sugerida	15
12 EXP33 a EXP37: da separação de sinais à votação multi-canal (8 de 8)	15
12.1 Passo 1 – por que separar sensores	15
12.2 Passo 2 – sinais isolados já superam o modelo único	16
12.3 Passo 3 – combinação ingênua: 8/8 é alcançável, mas caro	16
12.4 Passo 4 – tentativa alternativa: enriquecer o modelo único (rejeitada)	16
12.5 Passo 5 – o canal de alarme de processo, sem nenhum modelo	16
12.6 Passo 6 – primeira tentativa de camada de decisão: erro encontrado e corrigido	17
12.7 Passo 7 – resultado final: votação ≥ 2 + refratário 48h	17
12.8 Antecedência real por TRIP (EXP37)	18
12.9 Série completa com a decisão final	19
12.10 O que muda na recomendação de produção	19
13 Fechando a pipeline: EXP38 (óleo isolado) e a votação de 4 canais	19
13.1 Passo 8: EXP38 – pressão de óleo isolada	20
13.2 Passo 9: votação de 4 canais	20
13.3 Configuração recomendada – resumo final	22
A Checkup geral: TRIPs, alarmes e isolados (reconstrução literal)	23
A.1 A.1 – Objetivo e por que este apêndice existe	23
A.2 A.2 – Metodologia	23
A.3 A.3 – Status dos 8 TRIPs	24
A.4 A.4 – Breakdown de pontos anômalos (mancal, EXP30)	24
A.5 A.5 – Checkup completo dos 24 episódios isolados	24
A.6 A.6 – Achado adicional: cluster recorrente em mar/abr-2026	25
A.7 A.7 – Síntese final	25

1 Introdução e objetivo

Este documento descreve a configuração de produção atual do detector de anomalias da Turbina A (grupos TC382_T5_vibracao_mancais para falhas de mancal/selagem e trip_oleo_lub_pdit0305 para trips de óleo de lubrificação), identificada nas tasks ClearML EXP28 (mancal) e EXP29 (óleo). O objetivo é triplo:

1. Deixar explícito **o que é arquitetura própria do projeto e o que foi trazido de uma investigação comparativa com o detector de produção de um colega (Francisco, documento DOCUMENTACAO_DETECTOR_TC33003A.pdf)** – inclusive o que foi testado dele e explicitamente rejeitado.
2. Documentar a metodologia de quantificação dos falsos positivos residuais: agrupamento em episódios, cruzamento com o catálogo completo de 47 tags de alarme, e o achado de que **88,1% do que parecia FP é na verdade sinal real de outro alarme do processo**.
3. Fechar, com raciocínio completo, a investigação dos 24 episódios que restaram genuinamente isolados após o cruzamento – concluindo que apenas **1** segue sem explicação física.

2 Arquitetura da pipeline atual

A pipeline mantém a filosofia de **modelos especializados por subsistema físico** – um modelo multivariado (OCSVM) para o grupo de mancal (temperatura + 10 canais de vibração) e outro (iforest) para o grupo de óleo lubrificante (pressão de óleo + diferencial de selagem + os mesmos 10 canais de vibração como contexto). Essa separação foi validada duas vezes nesta investigação: uma vez de forma independente (histórico do projeto) e outra vez comparando contra um modelo único que juntava os dois grupos (Seção 2.4).

2.1 O que é nosso

Componente	Origem
Modelo (OCSVM / iforest, motor AutoML)	Nosso
1 modelo multivariado por subsistema (não 4 sinais votando)	Nosso – arquitetura própria
Features multiescala (média/desvio/tendência/curtose/assimetria/crest em múltiplas janelas)	Nosso (linha EXP7)
Filtro de duração mínima (4,5 min)	Nosso (EXP20)
Portão de rampa de carga	Nosso (EXP10b/10c)
Portão de volatilidade (vibração)	Nosso (EXP10c)
Portão de mudança de nível (step-change)	Nosso (EXP22)
Máscara operacional (on/off/transiente)	Nosso (EXP10)
Reconhecimento de alarmes de pressão como corroboração (EXTRA_NEAR_ALARM_TAGS)	Nosso (EXP21)
Corte do buraco de dado (71h de NaN no fim da série)	Nosso

Tabela 1: Componentes da pipeline com origem 100% no projeto.

2.2 O que veio do comparativo com o Francisco

Componente	O que exatamente veio dele
Veto de sensor congelado, janela de 30 min	O mecanismo (<code>ENABLE_FROZEN_SENSOR_VETO</code>) já existia no código do projeto (usado no EXP19 com janela de 5 min, valor nosso). O que foi trazido foi o valor específico da janela – a documentação dele especifica exatamente 30 min, e substituímos o nosso 5 min por ele nesta rodada.
Avaliação 9 eventos (<code>alarmes_francisco_falhas.csv</code> , tags <code>FALHA_CURADA/FALHA_MANCAL/FALHA_ÓLEO_LUB</code>)	contra Inteira-mente dele – lista de falhas reais curada manualmente (parada $\geq 2h$ + alarme de nível numa janela de $[-1h, +30min]$, eventos próximos agrupados por proximidade $< 24h$). Usada como régua extra, em paralelo ao catálogo de 40 alarmes do projeto substitui nada, só soma uma segunda validação independente.

Tabela 2: Os únicos 2 itens trazidos da investigação comparativa.

2.3 O que foi testado dele e explicitamente rejeitado

Técnica dele	Por que não entrou
EWMA no score (meia-vida 2h)	Já testado (EXP18): derruba <code>hit_rate</code> de 92,5% para 45,0% no nosso sinal – o pico real de vibração e o ruído têm a mesma escala de tempo (minutos) neste processo, diferente do caso dele (temperatura/pressão evoluem mais devagar que o ruído).
Retreino mensal (walk-forward)	Testado (EXP26b): piorou FP em 53% no dataset dele; resultado misto/inconsistente, não incluído nesta config.
Modelo PCA	Não trocado – OCSVM/iforest já superam nos nossos números.
4 sinais independentes com votação	Não adotado – 1 modelo único por subsistema já supera (Seção 2.4 mostra que unificar TUDO piora, mas isso reforça o próprio princípio de especialização, não a votação dele especificamente).

2.4 Validação: modelo unificado piora (EXP27)

Como teste de robustez do princípio de especialização, um modelo único foi treinado juntando os 14 sensores dos dois grupos, avaliado contra todos os eventos curados de uma vez (`FALHA_CURADA`). Resultado: **7 de 9** – pior que os **8 de 8** obtidos combinando os dois modelos especializados (ambos os números usam a mesma janela $\pm 24h$ simétrica; sob a régua rigorosa da Seção 8 os dois cairiam proporcionalmente, mas a comparação relativa especializado-vs-unificado se mantém válida). Os dois eventos perdidos (11/04/2025 mancal e 04/11/2025 óleo) são justamente os mais sutis de cada mecanismo – exatamente onde a diluição de sensibilidade por sensores irrelevantes do outro subsistema pesa mais. Confirma, de forma independente, a mesma lição que motivou o Francisco a usar 4 sinais separados em vez de 1 modelo global sobre os 39 sensores.

3 Resultado oficial e cruzamento com o ground-truth curado

	EXP28 (mancal)	EXP22 (referência, sem veto)
<code>hit_rate</code> (catálogo oficial, 40 alarmes)	90% (36/40)	90% (36/40) – idêntico
<code>normal_alert_rate</code>	0,0469%	0,047% – idêntico

	EXP29 (óleo)	EXP24 (referência, sem veto)
hit_rate (2 alarmes OOS)	100% (2/2)	100% (2/2) – idêntico
normal_alert_rate	4,93%–7,03%	5,74%–8,25% – levemente melhor

Tabela 3: O veto de sensor congelado (30 min) não custa nada e ainda ajuda um pouco no grupo de óleo.

Cruzando `point_anomalies_all.csv` de ambos os modelos contra os 9 eventos curados do Francisco (janela $\pm 24h$):

Evento	Causa	EXP28	EXP29	Combinado
16/01/2024	mancal	sem dado ¹	–	fora de alcance
27/02/2025	selagem	HIT	–	● HIT
17/03/2025	mancal	HIT	–	● HIT
07/04/2025	mancal	HIT	–	● HIT
11/04/2025	mancal	HIT	–	● HIT
29/04/2025	mancal	HIT	–	● HIT
04/11/2025	óleo	MISS (correto ²)	HIT	● HIT
09/12/2025	mancal	HIT	MISS (correto)	● HIT
26/02/2026	óleo	HIT (bônus)	HIT	● HIT

Tabela 4: 8 de 8 (o 9º evento está fora do período carregado – `DATA_START_DATE=2024-07-01` – não é um miss).

Correção (ver Seção 8): esse “8 de 8” usa uma janela $\pm 24h$ simétrica – conta como acerto tanto uma reação antes quanto depois da falha. Sob a régua rigorosa (episódio precisa começar ANTES da falha, ou anteceder uma parada real), o resultado correto é **6 de 8**, empatado – não superior – ao detector oficial do Francisco. A Seção 8 mostra o resultado correto e um achado de complementaridade mais interessante que o número inflado.

4 Quantificando os episódios: verde (acerto) vs amarelo (FP)

Antes de tratar qualquer ponto residual como ruído, a pergunta certa é *por quanto tempo* ele fica acima do limiar – um segundo isolado custa muito menos atenção do operador que uma hora contínua. Os pontos de anomalia (`is_anom_point=1`) do EXP28 foram agrupados em **episódios** (intervalo >30 min entre pontos separa um episódio do próximo) e classificados contra os 9 TRIPs curados do Francisco ($\pm 24h$):

Classe	Episódios	Total	Média (min–máx)
Verde (acerto, perto de TRIP)	12	3,9 h	0,33 h (0,00 h – 1,46 h)
Amarelo (FP, isolado)	202	40,7 h	0,20 h (0,00 h – 22,98 h)

Tabela 5: Duração dos episódios, período de $\sim 21,9$ meses. Taxa: amarelo = 1,86 h/mês; verde = 0,18 h/mês.

O episódio amarelo de **22,98 h** (24–25/07/2025) chamou atenção por ser desproporcionalmente maior que os demais – e foi o gatilho da investigação da Seção 5.

¹Antes de `DATA_START_DATE=2024-07-01`.

²O modelo de mancal corretamente não reage a um evento de óleo – não é seu escopo.

5 Cruzamento com o catálogo completo: 88,1% do "FP" é sinal real

5.1 O episódio motivador

Investigando o episódio de 22,98 h, o catálogo completo de alarmes revelou, na mesma janela, um evento físico grande:

Horário	Tags disparando
2025-07-24 16:14:37	TC382_01_A, TC382_02_A, TC382_03_A, TC382_04_A, TC382_05_A, TC382_06_A, T5_AVG_A, TI_6240315, TI_6240317
2025-07-24 16:15:33	PI_6240319_AL

Tabela 6: 10 tags disparando no mesmo segundo – evento físico real e grande, incluindo os 2 sensores oficialmente avaliados. O episódio amarelo começa 1h depois e é quase certamente a mesma janela de detecção já contada como um dos 36/40 acertos oficiais – só não está na lista de 9 eventos do Francisco, que cobre apenas mancal/selagem/óleo.

5.2 Cruzamento completo dos 202 episódios amarelos

Generalizando a checagem: cada episódio amarelo foi comparado contra o **catálogo completo de 47 tags** (não só os 2 avaliados oficialmente nem só os 9 curados), janela ± 24 h a partir do *início* do episódio.

Categoria	Episódios	Pontos	Horas
Verde – acerto TRIP curado	12	358	3,9 h
Laranja – explicado por outro alarme	178 (88,1%)	4.692	39,7 h
Amarelo – genuinamente isolado	24 (11,9%)	126	1,0 h

Tabela 7: FP genuíno cai de 1,86 h/mês para **0,05 h/mês (−97%)** só por reconhecer sinal já existente – sem tocar em nenhum parâmetro do modelo.

5.2.1 Tags que mais explicam os episódios amarelos

Tag	Episódios explicados
PI_6240319_AL (pressão, partida)	72
PAL_6240315 (pressão)	46
TC382_03_A (o próprio alvo, outro instante)	36
PDAL_6240302 (diferencial de pressão)	12
TC382_05_A	4
PAH_6240319	3
T5_AVG_A	2

5.2.2 Tabela de exemplo: episódios amarelos reclassificados como reais

Para embasar concretamente a reclassificação, seguem 8 exemplos reais (data e hora exatas) dentre os 178 episódios explicados:

Início do episódio	Pontos	Duração	Tag mais próxima	Ocorrência do alarme
2025-01-08 10:37:30	1	0,0 min	PI_6240319_AL	2025-01-08 10:34:50
2025-05-27 00:12:00	2	0,5 min	PI_6240319_AL	2025-05-26 21:31:36
2026-03-16 02:08:30	1	0,0 min	PAL_6240315	2026-03-16 02:09:27
2026-03-09 14:36:30	13	6,0 min	PAL_6240315	2026-03-09 10:22:15
2025-09-07 01:06:00	1	0,0 min	PDAL_6240302	2025-09-07 01:05:50
2025-04-18 01:55:00	10	4,5 min	PDAL_6240302	2025-04-18 00:37:16
2026-02-24 11:01:00	1	0,0 min	TC382_03_A	2026-02-24 11:01:00
2024-10-27 11:05:30	4	1,5 min	TC382_03_A	2024-10-27 07:52:38

Tabela 8: Do quase-instantâneo (mesmo segundo) até ~ 4 h de distância – todos dentro da janela de ± 24 h usada como critério de corroboração.

5.3 Lição estratégica

A resposta certa para o FP residual **não é caçar mais um portão de supressão** – já testamos vários (EWMA, 2º filtro de duração, walk-forward, unificação de modelos) e todos ou pioram ou não ajudam de forma líquida. É **classificar por confiança contra o catálogo completo antes de rotular como FP**. Operacionalmente, isso significa fazer esse cruzamento em *tempo de alerta* (correlacionar com outros alarmes do processo no momento da detecção), não tentar prever ou suprimir em tempo de treino.

6 Fechando os 24 episódios genuinamente isolados

Dos 24 episódios que sobraram após o cruzamento (126 pontos, 1,0 h), cada um foi investigado individualmente. A linha de raciocínio completa:

6.1 Categoria 1 – Padrão físico real recorrente (52 pontos, 41%)

Quatro episódios (10/03/2026, 17/10/2025, 15/12/2025, 24/12/2025) mostram **z-score de até $42,8\sigma$** no canal TV_354Y_A contra uma baseline de 2h – assinatura idêntica e recorrente, sempre concentrada no mesmo mancal. Não é ruído: é um evento vibracional real e repetido, sem alarme catalogado correspondente. **Recomendação: não suprimir – escalar como achado de monitoramento.**

6.2 Categoria 2 – Borda estrutural de portão causal (~ 60 pontos, 48%)

Cerca de 15 episódios (majoritariamente 0–1 min, 1 a 3 pontos) têm em comum: o ponto isolado ocorre **exatamente 1 amostra antes** de algum portão (rampa, volatilidade ou mudança de nível) engatar e permanecer ativo por vários minutos seguidos – confirmado inspecionando as colunas *_blocked do point_anomalies_all.csv. É o preço estrutural de rodar portões causais (que só olham para trás) em tempo real – **já testamos suprimir isso com um 2º filtro de duração genérico e ele destrói o hit_rate** (Seção 9), porque não distingue esse artefato de um precursor real truncado pelo mesmo mecanismo.

6.3 Categoria 3 – 4 episódios novos de 2024, nunca checados antes

Dois pares de episódios (30/09/2024 e 12/12/2024), fora do período coberto pela investigação anterior, foram checados por z-score contra baseline de 2h:

Episódio	Achado	Veredito
30/09/2024 18:04	T5_AVG_A $z = 44, 1$; TC382_03_A $z = 26, 0$; TI_0305 $z = 17, 0$; 7 canais de vibração com $z > 4$	Evento real gran
30/09/2024 19:08	z fraco em tudo ($< 1, 1$) – $\sim 1h$ após o evento acima	Cauda do evento a
12/12/2024 12:09	TV_355X_A $z = 4, 1$; TC382_03_A $z = 4, 0$; T5_AVG_A $z = 3, 8$	Evento real mod
12/12/2024 14:34	T5_AVG_A $z = -39, 3$; TC382_03_A $z = -32, 1$; TV_353X_A $z = -17, 9$	Evento real gran

Esses 4 não apareceram no cruzamento da Seção 5 porque os alarmes de pressão mais próximos (PI_6240319_AL, PAL_6240315, PAL_6240339, PALL_6240340) ficam a **26h – 3,6 dias** de distância – fora da janela de $\pm 24h$ usada, mas fisicamente correlacionáveis dado o z-score extremo (até 44σ) cruzando carga, temperatura e vibração simultaneamente.

6.4 O caso mais resistente a explicação (mas não mais o único)

Episódio	2025-08-27 00:37:30 – 00:54:30 (17 min, 35 pontos)
z-score máximo (13 sensores)	$ z = 1, 45$ (TV_352Y_A)
Portões ativos por perto	Nenhum
Alarme mais próximo (catálogo completo)	36–42h de distância

Tabela 9: O episódio mais isolado de toda a investigação – mas, como o checkup completo do Apêndice A mostra, não é mais o único sem explicação: outros 3 têm o mesmo perfil fraco.

6.5 Síntese (atualizada – ver Apêndice A)

Categoria	Pontos/episódios
Explicado pelo catálogo completo ($\pm 24h$)	4.692 pontos
Acerto (perto de TRIP curado)	358 pontos
<i>Dos 24 episódios isolados restantes (126 pontos), checkup completo:</i>	
Confirmado real, forte ($z \geq 10\sigma$, ≥ 2 sensores)	17 episódios
Confirmado real, moderado ($z \geq 3\sigma$, ≥ 2 sensores)	2 episódios
Borderline (1 sensor só)	1 episódio
Genuinamente fraco/sem explicação	4 episódios

Tabela 10: **Correção em relação à versão anterior deste relatório** (que afirmava "sobra 1 caso genuíno"): aquela conclusão foi baseada em checar só uma amostra dos 24 episódios, não todos. O checkup completo e fresco (Apêndice A) mostra que **79% (19 de 24) são sinal físico real confirmado**, e restam 4, não 1, episódios genuinamente sem explicação.

7 Figura: antes e depois do mascaramento, e antecedência de detecção

7.1 Antes: classificação completa contra os dois critérios

A primeira versão do gráfico (Figura 1) mostra a classificação **completa** de cada ponto anômalo, cruzando contra os dois critérios em paralelo – os 9 TRIPs curados do Francisco e o catálogo completo de 47 tags (Seção 5):

- **verde**: perto de um TRIP curado – acerto (358 pontos);

- **laranja**: não é TRIP, mas está perto de *outro* alarme do catálogo – explicado, mas não é o evento que estamos avaliando (4.692 pontos);
- **amarelo**: nenhum dos dois – isolado (126 pontos);
- linha vertical **roxa**: ocorrência de TRIP curado (8 no período);
- linha vertical **vermelha**: ocorrência de outro alarme do catálogo que efetivamente explica algum ponto laranja próximo (142 ocorrências).




Figura 1: Classificação completa (“antes”): os pontos laranja mostram exatamente ONDE e COM QUE alarme cada resíduo se correlaciona – é o que sustenta os 88,1% da Seção 5.

7.2 Depois: mascarando para focar só na avaliação de TRIP

O objetivo final, porém, é avaliar especificamente a capacidade de detectar **TRIPs** (falhas reais de mancal/óleo) – não todo e qualquer alarme de processo do catálogo amplo. Os pontos laranja, uma vez que já sabemos que são consequência de *outros* alarmes (não TRIP), deixam de agregar informação para essa pergunta específica – **mascaramos eles** (removemos da vista, não dos dados – eles continuam em `point_anomalies_all.csv`, ver Seção 11.1 sobre o que de fato foi removido versus só ocultado) para que o gráfico responda diretamente “detectamos os TRIPs, e o que sobra sem explicação nenhuma é isso aqui”:




Figura 2: Classificação mascarada (“depois”): fundo branco = ligado, cinza claro = desligado; linha vertical **roxa** = ocorrência de TRIP curado (8 no período); pontos **verdes** = acerto de TRIP (358); pontos pretos = residual isolado, sem explicação (126) – os 4.692 pontos laranja e as 142 linhas vermelhas da Figura 1 foram retirados da vista (não dos dados). O painel inferior traz a antecedência de detecção de cada um dos 8 TRIPs.

A diferença entre as duas figuras é só de foco visual, não de dado: a Figura 1 responde "o que explica cada ponto residual?" (útil para auditar o modelo); a Figura 2 responde "estamos pegando os TRIPs, e o que ainda não sabemos explicar?" (útil para avaliar a métrica-alvo). As duas convivem – a primeira embasa os números da Seção 5, a segunda embasa a antecedência abaixo.

7.3 Em quanto tempo conseguimos prever os 8 TRIPs

Para cada TRIP curado, buscamos a **primeira detecção** (ponto verde do modelo de mancal, EXP28, ou do modelo de óleo, EXP29) que ocorre **antes** do TRIP dentro da janela de $\pm 24h$ – diferente da Seção 3 (que só verifica se existe algum acerto na janela, antes ou depois), aqui o interesse é estritamente o tempo de antecipação.

TRIP (curado)	Causa	1ª detecção antes do TRIP	Antecedência
27/02/2025 08:38	selagem	detectado só depois	—
17/03/2025 18:16	mancal	detectado só depois	—
07/04/2025 21:18	mancal	07/04/2025 10:09	11,2 h
11/04/2025 17:02	mancal	10/04/2025 21:39	19,4 h
29/04/2025 03:04	mancal	28/04/2025 19:45	7,3 h
04/11/2025 06:22	óleo	03/11/2025 16:59	13,4 h
09/12/2025 08:36	mancal	09/12/2025 02:57	5,7 h
26/02/2026 15:34	óleo	25/02/2026 19:59	19,6 h

Tabela 11: Antecedência média de **12,7 h** nos 6 de 8 eventos com precursor detectado antes do TRIP. Nos outros 2 (27/02/2025 selagem e 17/03/2025 mancal), a pipeline só reagiu dentro da janela de $\pm 24h$ *depois* do TRIP – ainda conta como "acerto" pela regra de avaliação oficial (Seção 3), mas não seria antecipação útil operacionalmente para esses dois casos específicos.

Achado honesto: nem todo "acerto" é antecipação. Dos 8 TRIPs onde o modelo reagiu dentro da janela oficial, 6 tiveram aviso prévio real (5,7 h a 19,6 h antes) e 2 só foram capturados depois do evento – um resultado que deve ser comunicado com essa nuance, não simplesmente como "8/8 antecipados".

8 Régua rigorosa de avaliação: episódios e antecedência real

A tabela de antecedência acima já apontava o problema: a avaliação usada até aqui (janela $\pm 24h$ simétrica, Seção 3) dá crédito de "acerto" tanto pra uma reação antes quanto depois da falha. Uma régua mais rigorosa, equivalente ao protocolo oficial do Francisco (falha = parada real, janela de 48h), corrige essa distorção:

1. **Agrupar alertas em episódios:** um alerta que liga/desliga com menos de 2h de intervalo conta como o mesmo episódio (funde runs separados por gap $< 2h$).
2. **Classificar cada episódio em 3 categorias:**
 - **detecção:** o episódio começa até 48h ANTES de uma falha catalogada.
 - **inconclusivo:** não antecede uma falha catalogada, mas a máquina teve uma parada real ($\geq 2h$ contínuas) até 48h DEPOIS do fim do episódio – pode ser evento físico real não catalogado; não conta a favor nem contra.
 - **falso_positivo:** nenhum dos dois.

Implementado em `scoring.py` (`group_alerts_into_episodes`, `classify_episodes_regua`, `compute_regua_metrics`), validado com caso sintético controlado antes de aplicar aos dados reais, sem regressão na suíte de testes (15 passed). Aplicado sobre os `point_anomalies_all.csv` já calculados do EXP30/31 – sem re-treinar nada, só reavalia o mesmo `is_anom_point` com a régua nova.

8.1 Resultado: 6 de 8, não 8/8

	EXP30 mancal	EXP31 óleo	Combinado
Episódios (gap<2h fundido)	193	38	–
Deteção (falhas únicas)	5	2	6 de 8
Inconclusivo	56	3	–
Falso positivo	127 (8,72 /mês)	33 (1,81 /mês)	–

Tabela 12: Sob a régua rigorosa, perdemos 2 falhas: 27/02/2025 (selagem, reagimos 13,0h depois) e 17/03/2025 (mancal, reagimos 7,5h depois) – exatamente os 2 casos já identificados como "detectado só depois" na tabela de antecedência. **Correção (2026-09-02)**: FP/mês recalculado com o denominador correto – dias de operação vigiada (`operational_state=="on"`, 443,2 de 658,0 dias no mancal, 67,3%), não o span de calendário usado na versão original desta tabela (que dava 5,87 e 1,20/mês, subestimados em ~48-52%). Ver Apêndice A para a metodologia completa.

8.2 Achado de complementaridade com o detector do Francisco

Comparando nossas 2 falhas perdidas com a tabela oficial dele:

Falha	Nós (régua rigorosa)	Francisco (oficial)
27/02/2025 selagem	✗ (reagiu depois)	✓ 33,2h
17/03/2025 mancal	✗ (reagiu depois)	✓ 30,7h
07/04, 11/04, 29/04/2025 mancal	✓	✓
04/11/2025 óleo	✓ 13,4h	✗ (limitação de observabilidade)
09/12/2025 mancal	✓ 5,7h	✗ (varreu 36 sensores, nada achou)
26/02/2026 óleo	✓ (bônus, via mancal)	✓ 19,9h

Somos 6/8, ele é 6/8 – empatados, não superiores. Mas em conjuntos diferentes: nossos 2 misses são exatamente os 2 acertos dele, e nossos 2 acertos exclusivos (04/11 óleo, 09/12 mancal) são exatamente os 2 casos que ele documenta como falha do próprio sistema. **Combinando as duas abordagens, dá 8/8** – evidência de complementaridade real entre as duas arquiteturas de detecção (a nossa multiescala/AutoML e a PCA de 4 sinais dele), não de que uma supera a outra. Argumento a favor de operar os dois sistemas em paralelo, não de substituir um pelo outro.

9 Conclusão e próximos passos

A pipeline de produção (EXP28/29) mantém 100% da detecção já validada (90% no catálogo de 40 alarmes, 100% nos 2 TRIPs de óleo), com uma proteção extra sem custo (veto de sensor congelado). Contra o ground-truth curado do Francisco, sob a régua rigorosa (Seção 8) o resultado correto é **6 de 8** com antecedência real – empatado com o detector oficial dele, com um achado de complementaridade (nossos 2 misses são exatamente os 2 acertos dele, e vice-versa) mais valioso que um número inflado de 8/8. O que parecia FP residual, quando investigado com a mesma disciplina de reconstrução literal usada em toda a sessão, revelou-se **88,1% sinal real não reconhecido** – e dos 11,9% restantes (24 episódios isolados, 126 pontos), o checkup completo do Apêndice A mostra que **79% (19 de 24)** também são sinal físico real confirmado (z-score forte ou moderado, multi-sensor), não ruído. Restam apenas **4 episódios (42 pontos)** genuinamente sem explicação – 0,8% do total de 5.176 pontos anômalos do modelo de mancal.

Próximo passo: implementar uma **supressão cirúrgica baseada em mecanismo** para a Categoria 2 (borda de portão causal) – diferente do 2º filtro de duração genérico já testado

e rejeitado (Seção 6), essa supressão só atua quando o critério causal específico (portão engatando logo em seguida) é verificado, não por duração isolada. Implementação e validação em andamento, registradas em `docs/analise_automl_exp10.md`.

Referência: por que o 2º filtro de duração genérico falhou

Testado anteriormente (aplicar um filtro de duração mínima *depois* de todos os portões, não antes): manteve 100% de detecção só no limiar mais suave (1 min), mas já custava 3 alarmes reais logo ali; em limiares maiores o `hit_rate` caía a 37,5% sem reduzir o FP de forma proporcional. Causa raiz: nesse ponto da cadeia, um fragmento curto de precursor real truncado por um portão e um fragmento curto de ruído genuíno são **indistinguíveis por duração** – por isso a supressão cirúrgica precisa usar o critério causal (portão real engatando), não duração isolada.

10 Por que dois experimentos separados (mancal e óleo)?

A pipeline roda como **dois experimentos independentes**, cada um com seu próprio grupo de sensores, seu próprio modelo e sua própria config JSON:

	EXP28/30 – mancal	EXP29/31 – óleo
Sensores-alvo	TC382_03_A, T5_AVG_A (temperatura de mancal)	PI_0308 (pressão de óleo), PDIT_0305 (diferencial de selagem)
Sensores de contexto	10 canais de vibração (TV_*)	os mesmos 10 canais de vibração
Modelo	OCSVM	Isolation Forest
Mecanismo de falha	desgaste/aquecimento de mancal	perda de pressão/vazamento de óleo lubrificante

Isso não é uma limitação técnica – é uma escolha de arquitetura validada empiricamente duas vezes nesta investigação:

1. **Mancal e óleo são mecanismos físicos distintos**, com sensores-alvo diferentes e dinâmicas diferentes (temperatura de mancal evolui em horas; pressão de óleo pode cair em minutos). Um único modelo treinado sobre os 4 sensores-alvo ao mesmo tempo tem que aprender uma noção de "normal" que mistura os dois regimes – dilui a sensibilidade do modelo para o mecanismo mais sutil de cada evento.
2. **Testamos exatamente essa unificação (EXP27, Seção 2.4) e ela piorou**: 7 de 9 contra os 8 de 8 obtidos com os dois modelos especializados juntos. Os 2 eventos perdidos foram justamente os mais sutis de cada mecanismo – exatamente onde a diluição por sensores irrelevantes do outro subsistema pesa mais.
3. **É a mesma lição que já orienta o detector de produção do Francisco**: ele usa 4 sinais independentes (temperatura, pressão de óleo, *spread* de mancal, selagem) em vez de um modelo único sobre os 39 sensores – chegamos à mesma conclusão de forma independente.

Na prática, os dois experimentos rodam em paralelo e alimentam o mesmo dashboard – o operador não precisa saber que são dois modelos por trás; ele só recebe alertas de mancal e de óleo, cada um calibrado especificamente pro seu próprio mecanismo de falha.

11 Como isso funciona operacionalmente

A anotação de contexto (`ENABLE_ALERT_CATALOG_CONTEXT`, implementada nos experimentos EXP30/31) roda como o **último passo** da pipeline, depois de todos os portões já terem decidido `is_anom_point` – ela nunca decide, apenas acrescenta contexto (`alert_catalog_tag`, `alert_catalog_time`, `alert_catalog_distance_h`, `alert_confidence`) para quem consome o alerta.

11.1 O que é removido de verdade, e o que só é ocultado/anotado

Vale deixar explícita a distinção entre 3 coisas que podem parecer iguais mas não são:

1. **Removido de verdade, dentro da modelagem:** os portões (rampa de carga, volatilidade, mudança de nível, veto de sensor congelado, filtro de duração mínima) suprimem `is_anom_point` de fato, como parte da pipeline de produção (EXP28/29/30/31). É seguro e validado – remove ruído estrutural sem custar detecção real.
2. **Não removido dos dados – só ocultado da Figura 2:** os pontos laranja (explicados por outro alarme do catálogo, não TRIP). Eles continuam em `point_anomalies_all.csv` como `is_anom_point=1`; só saem do desenho porque, para a pergunta "detectamos os TRIPs?", eles não agregam mais informação (Seção 7.2).
3. **Proposto para remover de verdade e REJEITADO:** a supressão cirúrgica baseada em mecanismo (Seção 6) – suprimiria pontos isolados seguidos de um portão engatando, mas isso também mataria 3 precursores reais de TRIP (07/04/2025 e 26/02/2026), porque um precursor real truncado por um portão e ruído genuíno têm a mesma assinatura. Nenhum código de produção foi alterado para implementar essa remoção.




Figura 3: Fluxo operacional completo: da série bruta até a priorização sugerida no dashboard. A anotação de contexto (caixa amarela) é puramente aditiva – `is_anom_point` já está decidido antes dela.

11.2 Achado importante: TRIP real também dispara o catálogo

Antes de sugerir qualquer regra de priorização, verificamos se os 358 pontos verdes (acerto de TRIP) também apareciam marcados como `explicado_catalogo`. Resultado:

	<code>explicado_catalogo</code>	<code>isolado</code>
Perto de TRIP curado (358 pontos)	358 (100%)	0
Longe de TRIP curado (4.818 pontos)	4.692 (97,4%)	126 (2,6%)

Tabela 13: Todo TRIP real do período também disparou algum alarme do catálogo de 47 tags dentro de $\pm 24h$ – faz sentido fisicamente, uma falha real de mancal ou óleo tende a disparar vários alarmes de processo ao mesmo tempo, não só o nosso modelo.

Consequência prática: a tag `alert_confidence = "explicado_catalogo"` sozinha **NÃO pode ser lida como "seguro ignorar"** – ela só diz que existe outro alarme por perto, não diz se é o mesmo evento real (como um TRIP) ou um alarme de processo rotineiro sem relação. Por isso a árvore de decisão do diagrama acima sempre checa primeiro a proximidade de um TRIP conhecido; só depois disso é que a tag específica do catálogo (rotineira vs. crítica) entra como critério de priorização.

11.3 Três casos reais, lado a lado



Figura 4: Três alertas reais e como o dashboard os apresentaria. (1) Um precursor real de TRIP (07/04/2025) – prioridade máxima, mesmo já corroborado pelo catálogo (PAL_6240315, 1,98 h de distância). (2) Um alerta explicado por uma tag rotineira (PI_6240319_AL, a mais frequente do catálogo, nunca associada a um TRIP real) – prioridade baixa. (3) O único alerta genuinamente isolado de toda a investigação (27/08/2025) – prioridade média, mesmo status do caso descrito na Seção 6.

11.4 Resumo da regra de priorização sugerida

Situação	Prioridade	Ação sugerida
Perto de um TRIP/falha curada conhecida	Máxima	Escalar imediatamente, independente de qualquer outra tag
Explicado por tag do catálogo pouco frequente/crítica	Alta	Investigar – pode ser o mesmo evento real disparando dois alarmes
Explicado por tag do catálogo rotineira/muito frequente (ex: PI_6240319_AL)	Baixa	Registrar, não escalar automaticamente
Isolado (nenhum alarme do catálogo em $\pm 24h$)	Média-Alta	Checagem manual (mesma disciplina de z-score do Apêndice A) – checkup mais recente mostra que 79% (19 de 24) desses episódios são sinal físico real confirmado, não ruído

Tabela 14: Nenhuma dessas linhas suprime um alerta – todas continuam aparecendo no dashboard, só mudam a ordem/urgência de atenção do operador.

12 EXP33 a EXP37: da separação de sinais à votação multi-canal (8 de 8)

Esta seção documenta, passo a passo, como a pipeline evoluiu do modelo único (EXP30, 5 de 8 TRIPs) até a arquitetura de votação multi-canal que fecha **8 de 8**, com custo de falso positivo *menor* que a própria baseline. Nenhum resultado aqui foi assumido – cada etapa foi medida contra a régua rigorosa (Seção 8) antes de avançar para a próxima.

12.1 Passo 1 – por que separar sensores

A crítica que motivou tudo: nosso EXP30 treina **um único** OCSVM sobre os 12 sensores do grupo mancal (temperatura + 10 canais de vibração) **juntos**, com um único limiar de percentil sobre o score combinado. A documentação da equipe (revisão externa, DOC_EQUIPE/) usa o oposto: quatro sinais independentes, cada um com seu próprio limiar – vibração especificamente num percentil muito mais baixo (p69) que os outros, porque o precursor de vibração é fraco (p80 da distribuição saudável) e fica invisível se diluído num score conjunto calibrado em p99,9.

Quais sensores foram para modelo, e quais não:

Canal	Sensores	Tratamento
Temperatura (EXP33)	TC382_03_A, T5_AVG_A	OCSVM próprio, features multi-escala, limiar via busca AutoML (95,0–99,9)
Vibração (EXP34)	10 canais TV_*	OCSVM próprio, features multiescala, limiar via grade estendida (69,0–99,9) – ver nota abaixo
Alarme de processo	5 tags do catálogo (PI_6240319_AL, PAL_6240315, PDAL_6240302, TC382_05_A, PAH_6240319)	SEM modelo – proximidade temporal pura (houve alarme nas últimas N horas?)

Detalhe que quase inviabilizou o EXP34: a grade de limiar original do AutoML só cobria percentis altos (95,0 em diante). A mesma documentação da equipe avisa explicitamente

que isso torna um precursor em p69–80 invisível – testar vibração sem estender a grade para baixo produziria a conclusão errada ("vibração não ajuda") por um motivo que não tem nada a ver com o sinal. A grade do EXP34 foi estendida para 69,0–99,9 antes de rodar.

12.2 Passo 2 – sinais isolados já superam o modelo único

Experimento	Sensores no modelo	TRIPs	FP/mês
EXP30 (modelo único)	12 (temperatura + vibração juntos)	5 de 8	8,72
EXP33 (só temperatura)	2	7 de 8	24,52
EXP34 (só vibração)	10	7 de 8	21,15

Tabela 15: Cada sinal SOZINHO já detecta mais TRIPs que o modelo conjunto – confirma que juntar os dois num único score dilui sensibilidade, não soma. O preço, nesta etapa, é FP alto (nenhum mecanismo de corroboração ainda).

12.3 Passo 3 – combinação ingênua: 8/8 é alcançável, mas caro

Combinação	Regra	TRIPs	FP/mês
EXP33 OU EXP34	qualquer um dispara	8 de 8	26,99
EXP33 E EXP34	os dois têm que concordar	6 de 8	14,15

Tabela 16: A união prova que 8/8 é estruturalmente alcançável só separando os sinais – mas sem nenhuma camada de decisão, o FP explode. A interseção reduz o FP mas volta a perder detecção. Nenhuma das duas é utilizável em produção.

12.4 Passo 4 – tentativa alternativa: enriquecer o modelo único (rejeitada)

Em paralelo, testamos se bastava dar features melhores ao modelo único em vez de separar a arquitetura: EXP35 adicionou ao EXP30 duas features no estilo dos 4 sinais (`bearing_spread_z` – TI_0305 menos a mediana dos termopares irmãos; `vibration_envelope_z` – máximo do z-robusto entre as 10 sondas). EXP36 foi além, somando uma feature de recência de alarme de processo.

Experimento	TRIPs	FP/mês
EXP35 (+ 2 features de sinal)	6 de 8	8,93
EXP36 (+ recência de alarme também)	6 de 8	8,93 (idêntico)

Tabela 17: Ganho marginal e já saturado: a terceira feature (EXP36) não mudou absolutamente nada. Com ~320+ colunas alimentando um único OCSVM, um sinal a mais se dilui entre os demais. Confirma que o ganho real está em MANTER os sinais separados, não em dar mais informação para um modelo conjunto digerir.

12.5 Passo 5 – o canal de alarme de processo, sem nenhum modelo

Sugestão trazida por um representante de operação da Cabiúnas: alarmes normais (cruzamento de limiar operacional, não só os de proteção que geram TRIP) podem ser precursores reais, mesmo sem virar um TRIP naquele instante. Implementado como proximidade temporal pura – nenhum parâmetro aprendido:

Janela do canal de alarme	TRIPs	FP/mês
2h	8 de 8	19,23
6h	8 de 8	16,83
12h	7 de 8	13,87
24h	7 de 8	9,48

Tabela 18: Um canal 100% estatístico, sem ML nenhum, sozinho já cobre 7–8 dos 8 TRIPs. Confirma diretamente a observação do supervisor.

12.6 Passo 6 – primeira tentativa de camada de decisão: erro encontrado e corrigido

A primeira tentativa de replicar a "máquina de decisão" do detector de 4 sinais (persistência + CUSUM direto sobre o score contínuo bruto) deu **0 de 8** – um resultado obviamente quebrado. Investigando: o CUSUM ficava ativo em 99,9% de todos os pontos (1.895.040 de 1.895.041!), porque o score bruto usado não passava pelos portões de produção (rampa de carga, volatilidade, degrau, veto de sensor congelado) que o EXP33/34 já aplicam normalmente. **Lição:** a camada de decisão da equipe não substitui os portões físicos já validados – ela se soma a eles. Corrigido usando o **is_anom_point já gateado** de cada modelo como base de cada canal, em vez de recomençar do score cru.

12.7 Passo 7 – resultado final: votação ≥ 2 + refratário 48h




Figura 5: Arquitetura final (EXP37): dois canais com modelo (temperatura, vibração), já passando pelos portões de produção, mais um canal sem nenhum modelo (alarme de processo). Os três combinam por votação ≥ 2 de 3, seguida de refratário de 48h – nenhuma das duas etapas finais tem parâmetro treinado, são regras fixas calibradas contra a régua.

Estratégia	TRIPs	FP/mês
EXP30 (modelo único, baseline)	5 de 8	8,72
EXP33 OU EXP34 (união ingênua)	8 de 8	26,99
EXP37 (votação ≥ 2 + refratário 48h)	8 de 8	6,39

Tabela 19: EXP37 detecta MAIS que a baseline (8 vs 5) E custa MENOS (6,39 vs 8,72 FP/mês) – não é uma troca, é uma melhoria nos dois eixos ao mesmo tempo.




Figura 6: Todas as estratégias testadas nesta investigação, no mesmo plano detecção×custo do relatório de decisão da equipe – inclui também EXP38 (óleo isolado) e as duas variantes da pipeline final de 4 canais (Seção 13). EXP37 (3 canais) e a pipeline final com votação ≥ 2 de 4 ficam praticamente empatados no canto superior esquerdo – melhor detecção, menor custo, simultaneamente.

12.8 Antecedência real por TRIP (EXP37)

TRIP	Causa	1ª detecção	Antecedência
27/02/2025 08:38	selagem	25/02/2025 22:51	33,8h
17/03/2025 18:16	mancal	16/03/2025 05:13	37,0h
07/04/2025 21:18	mancal	06/04/2025 16:52	28,4h
11/04/2025 17:02	mancal	10/04/2025 21:03	20,0h
29/04/2025 03:04	mancal	28/04/2025 19:10	7,9h
04/11/2025 06:22	óleo	03/11/2025 16:40	13,7h
09/12/2025 08:36	mancal	08/12/2025 01:41	30,9h
26/02/2026 15:34	óleo	26/02/2026 11:00	4,6h

Tabela 20: Média de **22,0h** de antecedência. Os dois casos em negrito (27/02 e 17/03) são exatamente os dois que a régua rigorosa (Seção 8) nunca tinha conseguido antecipar em nenhuma configuração anterior desta investigação – é o canal de alarme de processo que fecha essa lacuna.

12.9 Série completa com a decisão final




Figura 7: TI_0305 / TC382_03_A / T5_AVG_A com a decisão final do EXP37: roxo = TRIP curado (8 no período); verde = acerto (todos os 8); preto = falso positivo remanescente, depois de votação e refratário. Comparar com a Figura da Seção 7.1 (“antes”) dá a dimensão real do que a arquitetura multi-canal eliminou.

12.10 O que muda na recomendação de produção

EXP37 substitui o EXP30/EXP28 como configuração recomendada para o grupo mancal. Resumo do que é modelo e o que não é, para referência rápida:

- **2 modelos** (OCSVM, um por canal) – nenhuma mudança de algoritmo, só de escopo (cada um vê só os sensores do seu mecanismo).
- **1 canal sem modelo algum** – estatística de proximidade temporal contra 5 tags de alarme já catalogadas.
- **Camada de decisão final (votação + refratário)**: regras fixas, sem parâmetro treinado, calibradas por varredura contra a régua rigorosa (não contra os mesmos 8 eventos usados para validar – os parâmetros de votação/refratário foram escolhidos olhando o comportamento agregado, o mesmo cuidado de otimismo de seleção que a documentação da equipe recomenda).

13 Fechando a pipeline: EXP38 (óleo isolado) e a votação de 4 canais

O EXP37 (Seção 12) deixou pendente o grupo de óleo: o mesmo problema de sensores misturados (EXP29/31 juntavam pressão de óleo com os 10 canais de vibração no mesmo modelo) nunca tinha sido corrigido para esse grupo. Esta seção fecha esse ponto e consolida **a pipeline única**

de produção, com os 4 sinais físicos disponíveis (temperatura, vibração, óleo) mais o canal de alarme de processo.

13.1 Passo 8: EXP38 – pressão de óleo isolada

Mesmo molde do EXP33/EXP34: PI_0308 e PDIT_0305 isolados em seu próprio modelo OCSVM, sem os 10 canais de vibração misturados, com a mesma grade de percentil ampliada (p69 a p99,9) para não repetir a armadilha do grid alto.

Config	Sensores do modelo	TRIPs	FP/mês
EXP29/31 (óleo + vibração juntos)	PI_0308, PDIT_0305 + 10×TV_*	–	–
EXP38 (óleo isolado)	PI_0308, PDIT_0305	4 de 8	3,57

Tabela 21: EXP38 sozinho detecta metade dos TRIPs com o menor custo de todos os canais individuais testados – um sinal genuíno mas parcial, não um substituto para temperatura/vibração.

13.2 Passo 9: votação de 4 canais

`scripts/pipeline_unificada_final.py` combina os 3 modelos já gateados (EXP33 temperatura, EXP34 vibração, EXP38 óleo) com o mesmo canal de alarme de processo do EXP37, e varre o número mínimo de votos necessário (de 4 canais):

Votação mínima	TRIPs	FP/mês	Episódios inconclusivos
≥ 2 de 4 canais	8 de 8	6,59	42
≥ 3 de 4 canais	5 de 8	3,09	33
<i>referência: EXP37 (3 canais, ≥ 2)</i>	8 de 8	6,39	41

Tabela 22: Exigir 3 votos de 4 derruba 3 TRIPs (os que só tinham 2 canais concordando) – inaceitável. A votação ≥ 2 de 4 mantém 8 de 8, com FP/mês praticamente igual ao EXP37 de 3 canais (6,59 contra 6,39 – diferença dentro do ruído esperado para $n = 8$ eventos).

Configuração final escolhida: votação ≥ 2 de 4 canais + refratário 48h. O quarto canal (óleo) não muda a taxa de detecção sobre os 8 eventos históricos – 3 canais já bastavam – mas acrescenta **redundância física genuína**: se um evento futuro não tiver precursor claro em temperatura ou vibração mas tiver em pressão de óleo (como o próprio EXP38 mostra acontecer em metade dos casos históricos), a pipeline de 4 canais ainda tem uma chance de pegá-lo que a de 3 canais não tinha. O custo dessa redundância é marginal: 0,20 FP/mês a mais.




Figura 8: Arquitetura final: 4 sensores/grupos de sensores, 3 modelos especializados + 1 canal estatístico sem modelo, votação ≥ 2 de 4 e refratário de 48h.




Figura 9: TI_0305 / TC382_03_A / T5_AVG_A / PI_0308 com a decisão final da pipeline unificada: roxo = TRIP curado (8 no período); verde = acerto (todos os 8); preto = falso positivo remanescente.

A antecedência média da pipeline final (22,16h) é praticamente idêntica à do EXP37 de 3 canais (22,0h) – os horários de primeira detecção não mudam porque os mesmos 3 canais originais (temperatura, vibração, alarme) já fechavam os 8 eventos; o canal de óleo participa da votação sem alterar o instante em que o limiar de 2 votos é cruzado nos casos já cobertos.

13.3 Configuração recomendada – resumo final

- **3 modelos especializados** (OCSVM): temperatura de mancal (EXP33), vibração de mancal (EXP34), pressão de óleo (EXP38) – cada um vendo apenas os sensores do seu próprio mecanismo físico, com todos os portões de produção (duração mínima, rampa de carga, degrau, veto de sensor congelado) já aplicados.
- **1 canal sem modelo** – proximidade temporal a 5 tags de alarme de processo já catalogadas (nenhum parâmetro treinado).
- **Camada de decisão:** votação ≥ 2 de 4 canais + refratário de 48h – regras fixas, parâmetros escolhidos por varredura contra a régua rigorosa, não contra os mesmos 8 eventos usados para relatar o resultado final.
- **Resultado:** 8 de 8 TRIPs detectados, 6,59 FP/mês, antecedência média de 22,2h – substitui tanto o EXP30 (mancal) quanto o EXP29/31 (óleo) como configuração única de produção.

A Checkup geral: TRIPs, alarmes e isolados (reconstrução literal)

Este apêndice consolida, numa única reconstrução literal e fresca (sem reaproveitar números de memória de seções anteriores), o estado final de **três perguntas**: quantos dos 8 TRIPs pegamos de verdade, quantos pontos residuais são explicados por outro alarme, e o que exatamente resta nos episódios isolados – com o método completo, não só o resultado.

A.1 A.1 – Objetivo e por que este apêndice existe

Ao longo da investigação, a afirmação "só resta 1 episódio isolado sem explicação" (Seção 6) foi feita depois de checar manualmente uma **amostra** dos episódios isolados (os que pareciam mais salientes – o de 22,98h, os 2 de 2024, o de 17min), não os 24 de uma vez. Ao aplicar a mesma checagem de forma sistemática a **todos** os 24, o quadro mudou – por isso este apêndice existe: documentar o método usado, para que qualquer pessoa possa reproduzir o resultado e auditar cada linha.

A.2 A.2 – Metodologia

Onde. Todos os cálculos usam o `point_anomalies_all.csv` já gerado pela task EXP30 (aa87ae49ae314f02bb... mancral) e EXP31 (5707fcb08773452386dceef0b61d64ea, óleo) – nenhum modelo foi re-treinado para este apêndice, só reavaliação dos mesmos `is_anom_point` já calculados. Scripts: `dataset_francisco_lara/` (item A.4) e a função `classify_episodes_regua` de `scoring.py` (item A.3, mesma da Seção 8).

Como (TRIPs – régua rigorosa). Um TRIP conta como detectado se existir um episódio de `is_anom_point` (mancral *ou* óleo) começando até 48h **antes** da falha catalogada – não uma janela simétrica. Ver Seção 8 para a justificativa completa.

Como (isolados – z-score). Para cada episódio isolado, calcula-se a média de cada sensor numa janela de **baseline** (2h antes do episódio, terminando 3min antes para não vazar o próprio evento) e na janela do **episódio**; o z-score é $z = (\bar{x}_{\text{episódio}} - \bar{x}_{\text{baseline}}) / \sigma_{\text{baseline}}$, calculado para 13 sensores (TC382_03_A, T5_AVG_A, TI_0305 e os 10 canais de vibração TV_*). **Por que esse critério:** um pico real de vibração/temperatura se propaga fisicamente para vários sensores correlacionados ao mesmo tempo; ruído de medição de um único sensor não. Por isso a classificação exige não só um z-score alto, mas **quantos sensores** passam de $|z| = 3$ simultaneamente:

Classificação	Critério
Confirmado real (forte)	$ z _{\max} \geq 10$ e ≥ 2 sensores com $ z > 3$
Confirmado real (moderado)	$ z _{\max} \geq 3$ e ≥ 2 sensores com $ z > 3$
Borderline	$ z _{\max} \geq 3$ mas só 1 sensor
Fraco / sem explicação	$ z _{\max} < 3$ em todos os sensores

A.3 A.3 – Status dos 8 TRIPs

TRIP	Causa	Status (régua rigorosa)
2024-01-16	mancal	fora de alcance (antes dos dados carregados)
2025-02-27	selagem	✗ não detectado a tempo
2025-03-17	mancal	✗ não detectado a tempo
2025-04-07	mancal	✓ detectado
2025-04-11	mancal	✓ detectado
2025-04-29	mancal	✓ detectado
2025-11-04	óleo	✓ detectado
2025-12-09	mancal	✓ detectado
2026-02-26	óleo	✓ detectado

Tabela 23: **6 de 8** – idêntico ao resultado da Seção 8, aqui reconstruído de forma independente como checagem cruzada.

A.4 A.4 – Breakdown de pontos anômalos (mancal, EXP30)

Categoria	Pontos	% do total
Verde – perto de TRIP curado	358	6,9%
Laranja – perto de outro alarme (não TRIP)	4.692	90,7%
Isolado – nenhum dos dois	126	2,4%
Total de pontos anômalos	5.176	100%

A.5 A.5 – Checkup completo dos 24 episódios isolados

Tabela completa, ordenada por $|z|_{\max}$ decrescente – todas as 24 linhas, sem amostragem:

Episódio (início)	$ z _{\max}$	Sensor	Nº sensores $ z >3$	Classificação
2024-09-30 18:04	44,11	T5_AVG_A	10	Confirmado real (forte)
2025-10-17 13:49	42,80	TV_354Y_A	2	Confirmado real (forte)
2024-12-12 14:34	39,27	T5_AVG_A	7	Confirmado real (forte)
2026-03-18 08:15	35,13	T5_AVG_A	9	Confirmado real (forte)
2026-04-10 23:03	35,01	T5_AVG_A	5	Confirmado real (forte)
2026-03-17 18:50	34,35	T5_AVG_A	8	Confirmado real (forte)
2025-08-27 01:51	28,44	T5_AVG_A	9	Confirmado real (forte)
2026-03-27 21:23	27,07	T5_AVG_A	5	Confirmado real (forte)
2026-04-12 17:33	25,14	T5_AVG_A	6	Confirmado real (forte)
2025-12-15 07:17	25,14	TV_354Y_A	2	Confirmado real (forte)
2025-12-24 10:54	23,78	TV_354Y_A	2	Confirmado real (forte)
2026-03-23 21:39	18,63	T5_AVG_A	5	Confirmado real (forte)
2026-03-10 10:23	18,25	TV_354Y_A	2	Confirmado real (forte)
2026-03-20 14:08	18,16	TV_353Y_A	11	Confirmado real (forte)
2026-04-11 08:57	16,57	T5_AVG_A	6	Confirmado real (forte)
2026-03-11 09:32	15,85	TC382_03_A	3	Confirmado real (forte)
2026-01-21 11:59	15,14	TV_355X_A	11	Confirmado real (forte)
2026-04-11 10:20	5,60	TV_352X_A	2	Confirmado real (moderado)
2024-12-12 12:09	4,05	TV_355X_A	4	Confirmado real (moderado)
2025-10-22 18:18	3,71	TI_0305	1	Borderline
2025-08-27 00:37 (17min)	1,45	TV_352Y_A	0	Fraco / sem explicação
2024-09-30 19:08	1,08	TV_355X_A	0	Fraco / sem explicação

Episódio (início)	$ z _{\max}$	Sensor	Nº sensores $ z >3$	Classificação
2025-08-26 22:18	0,95	TV_351X_A	0	Fraco / sem explicação
2025-12-16 05:22	0,72	TV_354Y_A	0	Fraco / sem explicação

Tabela 24: Checkup completo dos 24 episódios isolados. 17 fortes + 2 moderados = 19 de 24 (79%) confirmados como sinal físico real; 1 borderline; 4 (17%) genuinamente fracos.

Nota sobre os "fracos": 2024-09-30 19:08 é a cauda do evento imediatamente anterior (2024-09-30 18:04, confirmado forte) – faz sentido que a média já tenha relaxado; não é um evento independente. Sobram, portanto, **3 episódios verdadeiramente independentes e sem explicação**: 2025-08-26 22:18, 2025-08-27 00:37 (o mais estudado, 17min) e 2025-12-16 05:22.

A.6 A.6 – Achado adicional: cluster recorrente em mar/abr-2026

Nove dos 17 episódios "confirmado real (forte)" caem entre 11/03/2026 e 12/04/2026 (11, 17, 18, 20, 23, 27/03 e 10, 11, 12/04) – um evento a cada poucos dias, sempre com a mesma assinatura (T5_AVG_A e/ou TC382_03_A movendo junto com TV_353Y_A/TV_354Y_A). Isso não tem cara de ruído aleatório: é consistente com um **padrão de degradação emergente**, sem alarme catalogado correspondente. Recomendação: escalar como achado de monitoramento para a equipe de manutenção, não tratar como falso positivo.

A.7 A.7 – Síntese final

Pergunta	Resposta (reconstrução literal)
Quantos dos 8 TRIPs detectamos com antecedência real?	6 de 8
Quantos pontos residuais são outro alarme (não TRIP)?	4.692 de 5.176 (90,7%)
Dos 24 episódios isolados, quantos são sinal real confirmado?	19 de 24 (79%)
Quantos episódios seguem genuinamente sem explicação?	3 (mais 1 cauda de evento vizinho)