

Documentação Operacional da Pipeline de Detecção de Anomalias

Turbina A – Cabiúnas

Equipe de Modelagem

Setembro de 2026

Resumo

Este documento descreve, de forma operacional e reproduzível, a pipeline final de detecção de anomalias adotada como configuração de produção: como os três modelos especializados são montados e configurados, como o treinamento é conduzido, o que acontece depois do treinamento (portões de produção, canalização binária, votação, filtro de duração mínima, refratário) e o resultado final sobre o histórico de TRIPs disponível. Todas as figuras e tabelas foram geradas a partir do retreino completo dos três modelos (03/09/2026) e do estudo dos falsos positivos residuais (04/09/2026), que resultou na adição do filtro de duração mínima de 45 minutos na votação combinada.

Sumário

1	Visão geral	1
2	Como a pipeline é montada	2
2.1	Separação de sinais por canal	2
2.2	Configuração de treinamento	2
2.3	Resultado do treinamento (calibração por AutoML)	3
3	O que é feito depois do treinamento	4
4	Estudo dos falsos positivos e filtro de duração mínima	6
4.1	Efeito visual do filtro: mecanismo e antes/depois na série completa	6
4.2	Teto prático confirmado	8
5	Resultado final	9
6	Auditoria dos 42 FP remanescentes: sinal físico ou ruído?	10
6.1	Passo 1 – seleção dos episódios	10
6.2	Passo 2 – checkup de sinal físico (z-score contra baseline)	11
6.3	Passo 3 – segunda evidência: corroboração por outro alarme de processo	11
6.4	Passo 4 – visualização na série completa	12
6.5	Conclusão da auditoria	13
7	Reprodução operacional	13

1 Visão geral

A pipeline combina **3 modelos especializados** (um por mecanismo físico: temperatura de mancal, vibração de mancal, pressão de óleo) com **1 canal estatístico sem modelo** (proximidade temporal a alarmes de processo já catalogados), cujas saídas binárias são combinadas por

uma camada de decisão de regras fixas (votação e refratário). A Figura 1 mostra a arquitetura completa, ponta a ponta.




Figura 1: Arquitetura end-to-end da pipeline operacional: 4 canais (3 modelos + 1 estatístico), portões de produção, votação e refratário.

2 Como a pipeline é montada

2.1 Separação de sinais por canal

Cada canal modelado vê apenas os sensores do seu próprio mecanismo físico – essa separação (em vez de um único modelo recebendo todos os sinais juntos) é o que permite que cada modelo seja sensível ao seu próprio regime de anomalia, sem diluição por variação normal de outros mecanismos.

Canal	Sensores usados	Sensor alvo
1 – Temperatura	TC382_03_A, T5_AVG_A	TC382_03_A
2 – Vibração	10 canais TV_351X/Y_A ... TV_355X/Y_A	TV_351X_A
3 – Óleo	PI_0308, PDIT_0305	PI_0308
4 – Alarme de processo	5 tags de catálogo (sem sensor contínuo)	–

Tabela 1: Separação de sensores por canal. Nenhum canal modelado compartilha sensores com outro.

2.2 Configuração de treinamento

Os três canais modelados usam o mesmo algoritmo (*One-Class SVM*), a mesma janela de dados e o mesmo procedimento de calibração por AutoML (busca de limiar de anomalia e debounce por grade, validação fora da amostra). O que muda entre eles é apenas o escopo de sensores e, em alguns casos, quais portões de produção fazem sentido fisicamente para aquele mecanismo.

Parâmetro	Temperatura	Vibração	Óleo
Modelo	OCSVM	OCSVM	OCSVM
ν (nu)	0,05	0,05	0,05
γ (gamma)	scale	scale	scale
Máx. amostras de treino	50.000	50.000	50.000
Grade de percentil (limiar)	95 – 99,9	69 – 99,9	69 – 99,9
Grade de debounce (min)	1, 4, 12	1, 4, 12	1, 4, 12
Janela de dados	01/07/2024 – 20/04/2026		
Split fora-da-amostra	a partir de 01/07/2025		
Filtro de duração mínima	4,5 min	4,5 min	4,5 min
Veto de sensor congelado	30 min	30 min	30 min
Portão de degrau (T5_AVG_A)	sim	sim	não
Portão de rampa de carga (T5_AVG_A)	sim	sim	não
Portão de volatilidade	não	não	não

Tabela 2: Configuração de treinamento por canal. A grade de percentil de temperatura é mais restrita porque o sinal já vive em percentis altos; vibração e óleo usam uma grade ampliada (desde p69) para não descartar precursores fracos que vivem em percentis mais baixos.

O canal de alarme de processo não tem parâmetro treinado: é uma verificação direta de proximidade temporal (“houve um alarme de uma das 5 tags catalogadas nas últimas 24h?”), contra o catálogo `alarmes_selecionados_turbina_a.csv`, tags `PI_6240319_AL`, `PAL_6240315`, `PDAL_6240302`, `TC382_05_A`, `PAH_6240319`.

2.3 Resultado do treinamento (calibração por AutoML)

Para cada canal, a etapa de AutoML varre a grade de percentil de limiar e debounce, escolhe a combinação com melhor pontuação composta (taxa de detecção contra alarmes de referência, penalizada por falso alarme) e valida fora da amostra.

Métrica de calibração	Temperatura	Vibração	Óleo
Limiar escolhido (percentil)	p97,5	p95,0	p99,9
Valor do limiar (erro OCSVM)	10,50	0,176	29,67
Debounce escolhido	1 min	4 min	12 min
Nº de combinações testadas	15	27	27
Taxa de detecção (val. interna)	92,5%	87,5%	100%
Taxa de alarme em período normal	0,68%	10,06%	0,27%
Pontos normais usados no ajuste	386.492	386.492	574.951

Tabela 3: Resultado da calibração AutoML por canal, retreino de 03/09/2026. Essas métricas são internas ao próprio canal (contra seus alarmes de referência), antes da votação final – não confundir com o resultado da régua rigorosa apresentado na Seção 5.




Figura 2: Canal 1 (temperatura) – série com anomalias marcadas ao final do treinamento e calibração.




Figura 3: Canal 2 (vibração) – série com anomalias marcadas ao final do treinamento e calibração.




Figura 4: Canal 3 (óleo) – série com anomalias marcadas ao final do treinamento e calibração.

3 O que é feito depois do treinamento

O modelo treinado de cada canal produz um **score contínuo** de anomalia (erro de reconstrução/distância à fronteira do OCSVM). Esse score passa por uma sequência de etapas antes de virar o “voto” binário do canal:

1. **Limiar calibrado:** o score é comparado ao limiar escolhido pelo AutoML (Tabela acima) – acima do limiar por pelo menos o tempo de debounce, o ponto é candidato a anomalia.
2. **Portões de produção:** cada candidato passa por filtro de duração mínima (4,5 min), veto de sensor congelado, e, quando aplicável ao mecanismo (temperatura e vibração), portão de degrau e de rampa de carga – isso suprime falsos alarmes causados por transientes operacionais normais (partida, parada, mudança de carga), não por anomalia real.

3. **Canal binário:** o que sobra depois dos portões é o canal binário (0/1) daquele mecanismo – é isso que entra na votação.
4. **Votação:** os 4 canais binários (3 modelados + 1 estatístico) são somados ponto a ponto; a decisão bruta é “ativa” quando **pelo menos 2 dos 4** concordam no mesmo instante.
5. **Filtro de duração mínima (45 min):** aplicado sobre a votação combinada – descarta episódios de concordância *pontual* entre canais (coincidências de segundos a poucos minutos) que não representam um evento físico sustentado. Ver justificativa e varredura de segurança na Seção 4.
6. **Refratário:** uma vez que a decisão dispara, novas ativações do mesmo evento são suprimidas por 48h – isso evita que um único evento físico prolongado gere múltiplos alarmes repetidos.

A Figura 5 ilustra essa sequência sobre uma janela real (o TRIP de 04/11/2025): no Passo 1 cada canal acende de forma independente e em instantes diferentes; no Passo 2 a soma de votos cruza o limiar de 2 pouco antes do TRIP; no Passo 3 o filtro de duração mínima mantém apenas o trecho sustentado da votação; no Passo 4 a decisão final dispara uma única vez (verde) e fica suprimida pelo refratário até o TRIP acontecer (linha roxa).




Figura 5: Passo a passo da camada de decisão pós-treino, sobre uma janela real de TRIP.

4 Estudo dos falsos positivos e filtro de duração mínima

Antes de aceitar qualquer mudança para reduzir falso positivo, os 96 episódios de FP da configuração anterior (votação 2 + refratário, sem filtro de duração) foram caracterizados pela combinação de canais que os disparou:

Combinação de canais	Nº de episódios	Duração mediana
Temperatura + Alarme	27	~30s
Vibração + Alarme	26	~12min
Temperatura + Vibração	22	~45s
Temperatura + Vibração + Alarme	12	~1,4h
Óleo + Alarme	6	~45min
Temp.+Vib.+Óleo+Alarme	2	~1,9h
Vibração + Óleo + Alarme	1	1,2h

Tabela 4: Caracterização dos 96 FP por combinação de canais (config. sem filtro de duração). Mais da metade (49 de 96) tem duração mediana abaixo de 1 minuto – coincidência pontual entre canais já individualmente filtrados, não sinal sustentado.

Isso motivou testar um filtro de duração mínima na votação combinada (análogo ao já usado em cada canal individualmente), varrendo o limiar de duração contra a régua rigorosa **antes** de adotar qualquer valor:

Duração mín.	TRIPs	FP/mês	Observação
0 min (sem filtro)	8/8	6,59	configuração anterior
14–15 min	7/8	4,3	zona de fronteira instável (ver texto)
16 a 52 min	8/8	4,19 a 2,68	platô seguro, verificado ponto a ponto
55 min	7/8	2,54	quebra permanente começa aqui
58–60 min	5/8	2,4–2,5	3 TRIPs perdidos
45 min (escolhido)	8/8	2,88	margem de 10min do início da quebra

Tabela 5: Varredura de duração mínima na votação combinada, 04/09/2026. A zona instável em 14–15min corresponde ao TRIP de 11/04/2025, que já era conhecido como caso de fronteira (detectado com apenas 2 votos, a 0,9h de um religamento da máquina) – volta a 8/8 logo acima, e o valor final (45min) fica com folga de ambos os lados.

Decisão: filtro de duração mínima de 45 minutos, aplicado à votação combinada antes do refratário. Reduz FP/mês de 6,59 para **2,88 (-56%)** e episódios inconclusivos de 42 para 25, sem perder nenhum dos 8 TRIPs – com margem de segurança verificada, não apenas extrapolada, dos dois lados do limiar escolhido.

Uma ideia alternativa avaliada e **rejeitada** nesta mesma investigação foi suprimir alarmes nas primeiras 6h após a máquina religar (prática usada por outros pesquisadores no mesmo contexto): 20 dos 96 FP caíam nessa janela, mas 2 dos 8 TRIPs reais também disparavam dentro dela (a 0h e a 0,9h de um religamento) – uma supressão cega os teria eliminado junto. O filtro de duração mínima resolve o mesmo tipo de ruído sem esse efeito colateral, porque ataca a característica real do ruído (duração) em vez de uma correlação temporal aproximada (proximidade a um religamento).

4.1 Efeito visual do filtro: mecanismo e antes/depois na série completa

A Figura 6 mostra o mecanismo em um exemplo real e isolado (14/08/2025): temperatura e vibração cruzam seus limiares ao mesmo tempo por menos de 1 minuto – sem o filtro, esse

instante seria um alarme (curva vermelha); com o filtro de 45min, a coincidência nunca chega a se sustentar e o resultado fica em zero (curva verde). Não há dados de outros canais nem eventos próximos nesta janela – é uma coincidência pontual isolada, exatamente o tipo de ruído que o filtro foi desenhado para eliminar.

O que o filtro de duração mínima elimina -- mecanismo em um exemplo real (14/08/2025)




Figura 6: Mecanismo do filtro de duração mínima em um exemplo real e isolado: a votação bruta (vermelho) dispara por menos de 1 minuto; o filtro de 45min descarta essa coincidência (verde, permanece em zero).

A Figura 7 mostra o mesmo efeito sobre a série inteira (não apenas um exemplo): em laranja, todos os pontos que seriam classificados como anomalia *antes* do filtro e que o filtro de 45min elimina; em preto, os que sobrevivem (falso positivo remanescente); em verde, os 8 acertos de TRIP; em roxo, as ocorrências reais de TRIP. O volume de laranja domina visualmente sobre o preto em quase todos os episódios – é a mesma redução de 56% (6,59 para 2,88 FP/mês) vista ponto a ponto ao longo dos ~22 meses de dados.




Figura 7: Série bruta completa (TI_0305, TC382_03_A, T5_AVG_A, PI_0308) com os pontos que o filtro de 45min elimina (laranja, $n=29.250$ pontos) sobrepostos aos que permanecem como falso positivo (preto) e aos 8 acertos de TRIP (verde). As linhas verticais roxas marcam as ocorrências reais de TRIP.

4.2 Teto prático confirmado

Antes de fechar esta configuração como definitiva, mais três alavancas de baixo custo foram testadas – todas sem sucesso adicional, o que confirma que 2,88 FP/mês é o teto prático desta arquitetura:

- **Filtro de duração por canal individual** (em vez de só na votação combinada): resultado quase idêntico, redundante – os dois filtros capturam o mesmo mecanismo de ruído, não são efeitos aditivos.
- **Grade de AutoML mais fina** (153 combinações por canal, era 15–27): melhorou a calibração *isolada* de vibração e óleo (taxa de alarme normal menor), mas a pipeline completa caiu de **8/8 para 4/8 TRIPs** com essas novas calibrações – revertido. Lição: o AutoML por canal otimiza uma métrica local (contra a própria referência de alarme), não o resultado do conjunto contra a régua rigorosa.
- **Duração do refratário** (24h a 120h, com o filtro de 45min já fixado): 48h já é o ótimo – 60h já derruba 2 TRIPs para uma redução marginal de FP.

Os 42 FP que restam também mudaram de natureza: não são mais coincidências pontuais (isso o filtro de 45min já eliminou), e sim episódios sustentados (mediana 1,2h, até 9,65h),

distribuídos uniformemente ao longo de ~ 17 meses – estatisticamente mais parecidos com os episódios isolados do checkup geral (79% confirmados como sinal físico real) do que com ruído de amostragem. Reduzir mais exigiria um 5º canal com informação nova ou auditoria individual desses episódios – não mais ajuste de parâmetro.

5 Resultado final

O resultado abaixo é do **retreino completo** dos 3 modelos (03/09/2026), avaliado contra a régua rigorosa: episódios com fusão de intervalo menor que 2h; detecção = alarme em até 48h antes de um TRIP catalogado; inconclusivo = seguido de parada real (≥ 2 h) em até 48h; senão, falso positivo. O denominador de FP/mês é o tempo efetivamente monitorado (estado operacional “ligado”), não o intervalo de calendário.

Métrica	Valor
TRIPs catalogados no período	8
TRIPs detectados	8 (100%)
Falsos positivos por mês	2,88
Episódios inconclusivos	25
Antecedência média	23,8 h

Tabela 6: Resultado final da pipeline operacional, régua rigorosa, com o filtro de duração mínima de 45min (Seção 4).

TRIP	1ª detecção	Antecedência
27/02/2025 08:38	25/02/2025 22:51	33,8 h
17/03/2025 18:16	16/03/2025 11:04	31,2 h
07/04/2025 21:18	06/04/2025 02:05	43,2 h
11/04/2025 17:02	10/04/2025 21:15	19,8 h
29/04/2025 03:04	27/04/2025 14:22	36,7 h
04/11/2025 06:22	03/11/2025 16:40	13,7 h
09/12/2025 08:36	09/12/2025 00:15	8,4 h
26/02/2026 15:34	26/02/2026 11:48	3,8 h

Tabela 7: Antecedência real por TRIP, pipeline final com filtro de duração mínima (média 23,8h).




Figura 8: Série bruta (TI_0305, TC382_03_A, T5_AVG_A, PI_0308) com a decisão final da pipeline (já com o filtro de duração mínima de 45min): linhas verticais roxas = TRIPs reais; pontos verdes = acerto (8 de 8); pontos pretos = falso positivo remanescente (42 episódios, eram 96 antes do filtro); faixas cinza = turbina desligada.

6 Auditoria dos 42 FP remanescentes: sinal físico ou ruído?

A Seção 4 deixou uma pergunta em aberto: os 42 falsos positivos que sobram depois do filtro de 45min são ruído do modelo, ou são eventos físicos reais que simplesmente não escalaram para um TRIP catalogado? A resposta importa porque muda o que fazer a seguir – se for ruído, ainda há o que suprimir com segurança; se for sinal real, suprimir mais seria apagar informação que o operador provavelmente quer ver. Esta seção documenta a auditoria feita para responder isso, passo a passo, com duas linhas de evidência independentes.

6.1 Passo 1 – seleção dos episódios

Os 42 episódios classificados como **falso_positivo** pela régua rigorosa (Seção 5) foram listados com seus instantes exatos de início e fim. Ao contrário dos episódios curtos do checkup anterior (Apêndice A do relatório de investigação, quase pontuais), estes têm duração real: de 48 minutos a 9,65 horas – consequência direta do filtro de 45min, que só deixa passar concordâncias sustentadas.

6.2 Passo 2 – checkup de sinal físico (z-score contra baseline)

Para cada episódio, comparou-se o comportamento dos sensores durante a janela do episódio contra um **baseline de 2 horas imediatamente antes** (terminando 3 minutos antes do início, para não contaminar o baseline com o próprio início do evento). O conjunto de sensores checados inclui todo o grupo de mancal (temperatura e os 10 canais de vibração) mais os dois sensores de óleo – mais amplo que os sensores do modelo que efetivamente disparou o alarme, para não deixar passar despercebido um sinal em outro sensor correlato.

Um cuidado metodológico que mudou o resultado: a primeira tentativa comparou a *média* de todo o episódio contra o baseline. Como esses episódios podem durar horas, um pico breve real no meio de uma janela longa fica diluído pela média – e o resultado saiu artificialmente baixo (21,4% “confirmado”). Corrigido para usar o **pico máximo pontual** dentro do episódio (o critério correto, coerente com como o próprio modelo de anomalia reage a picos, não a médias), o resultado mudou para:

Classificação	% dos 42
Confirmado real (forte: $ z \geq 10$ e ≥ 2 sensores)	26,2% (11)
Confirmado real (moderado: $ z \geq 3$ e ≥ 2 sensores)	35,7% (15)
Borderline (só 1 sensor com $ z \geq 3$)	28,6% (12)
Fraco / sem explicação física	9,5% (4)

Tabela 8: Checkup individual dos 42 FP – pico de z-score dentro do episódio contra baseline de 2h. **61,9% confirmados reais** (forte+moderado), consistente com os 79% já encontrados nos 24 episódios isolados do relatório de investigação.

Apenas 4 episódios não mostram nenhuma explicação física em nenhum sensor checado – únicos candidatos honestos a ruído puro: 2025-01-14_17h57, 2025-01-24_12h42, 2025-02-21_03h27 e 2026-03-09_12h07.

6.3 Passo 3 – segunda evidência: corroboração por outro alarme de processo

Sinal físico no próprio sensor é uma evidência; uma segunda e independente é verificar se **outro alarme do processo**, já catalogado pela planta, ocorreu perto do mesmo instante – ou seja, se o próprio sistema de alarmes da Cabiúnas também percebeu algo ali, por um caminho diferente do nosso modelo.

Usou-se o catálogo completo (47 tags, 3.757 ocorrências ativas no período), **excluindo os 5 tags já usados no canal de alarme da própria pipeline** (para não contar a mesma evidência duas vezes) e uma janela de $\pm 2h$.

Controle negativo obrigatório: uma taxa alta de “explicado por outro alarme” só é evidência real se for muito maior do que a taxa que apareceria em instantes aleatórios – do contrário, é só reflexo de um catálogo denso (mesmo cuidado já aplicado nesta investigação para o enriquecimento por catálogo, Seção 2 do relatório de investigação). Comparou-se a taxa nos 42 FP contra 5.000 instantes aleatórios do período monitorado:

Grupo	Taxa (outro alarme em $\pm 2h$)
42 FP (pós-filtro 45min)	23,8% (10 de 42)
Baseline aleatório (5.000 amostras)	3,4%
Enriquecimento	6,9×

Tabela 9: Corroboração por outro alarme de processo, com controle negativo. Um enriquecimento de $6,9\times$ é forte – bem acima de $1,0\times$ (que indicaria catálogo denso demais para discriminar) – não é artefato.




Figura 9: Esquerda: taxa de corroboração por outro alarme nos 42 FP vs. baseline aleatório (controle negativo). Direita: quais tags do catálogo explicam os 10 episódios corroborados – concentradas em alarmes do próprio sensor de temperatura de mancal (TC382_03_A, T5_AVG_A).

6.4 Passo 4 – visualização na série completa

A Figura 10 mostra as duas evidências sobrepostas na série bruta inteira: os 10 FP corroborados por outro alarme aparecem em azul, com uma linha pontilhada fina marcando o instante exato desse outro alarme (não é TRIP – é um alarme de processo diferente, catalogado pela planta); os 32 FP sem essa corroboração específica continuam em preto (a maioria deles ainda tem sinal físico próprio confirmado pelo Passo 2, só não bateu com outro alarme do catálogo em $\pm 2h$).




Figura 10: Série bruta completa com a auditoria dos 42 FP: roxo = TRIP real; verde = acerto; preto = FP sem corroboração por outro alarme; azul = FP corroborado; linhas pontilhadas azuis finas = instante exato do outro alarme de processo que explica cada FP corroborado.

6.5 Conclusão da auditoria

Combinando as duas linhas de evidência independentes – 90,5% dos 42 FP com sinal físico próprio (confirmado ou borderline) e 23,8% também corroborados por outro alarme de processo já catalogado – fica difícil defender que os FP remanescentes sejam ruído do modelo. São, na maioria, **eventos físicos reais que a própria planta às vezes também registra**, mas que não escalaram para um TRIP catalogado desta vez. **Recomendação: não suprimir mais** – 2,88 FP/mês é um teto honesto, não apenas técnico. Os 4 episódios sem nenhuma explicação (Passo 2) são os únicos candidatos legítimos a uma investigação futura mais específica.

7 Reprodução operacional

Todo o resultado deste documento é reproduzível a partir do repositório, sem passos manuais além de submeter os jobs de treinamento:

- **Configs de treino:** configs/calibracao_v4_eq/test_grupo_exp33_mancal_temperatura_isolada.js, test_grupo_exp34_mancal_vibracao_isolada.json, test_grupo_exp38_oleo_pressao_isolada.json
- **Treino:** PYTHONPATH=. python src/main.py -config <config>.json para cada um dos 3 canais (envia para a fila remota do ClearML).

- **Decisão final:** `PYTHONPATH=. python scripts/pipeline_unificada_final.py` – baixa os 3 `point_anomalies_all.csv` já treinados, monta o canal de alarme, aplica votação e refratário, e escreve o resultado final em `runs_pipeline_unificada_final/`.
- **Retreino completo confirmado em 03/09/2026:** os três modelos foram retreinados do zero (novas tasks no ClearML) e o resultado final (antes do filtro de duração mínima) foi idêntico – 8/8 TRIPs, 6,59 FP/mês, mesmos instantes de detecção – confirmando que a pipeline é reproduzível ponta a ponta.
- **Filtro de duração mínima adicionado em 04/09/2026** (Seção 4): 45 minutos aplicados à votação combinada, via `apply_min_duration_filter` (já existente em `src/cnn1d_ae/scoring.py`, antes usado só por canal) – reduz FP/mês para 2,88 mantendo 8/8.