

Documentação Operacional da Pipeline de Detecção de Anomalias

Turbina A – Cabiúnas

Equipe de Modelagem

Setembro de 2026

Resumo

Este documento descreve, de forma operacional e reproduzível, a pipeline final de detecção de anomalias adotada como configuração de produção: como os três modelos especializados são montados e configurados, como o treinamento é conduzido, o que acontece depois do treinamento (portões de produção, canalização binária, votação, refratário) e o resultado final sobre o histórico de TRIPs disponível. Todas as figuras e tabelas foram geradas nesta rodada, a partir do retreino completo dos três modelos em 03/09/2026.

Sumário

1	Visão geral	1
2	Como a pipeline é montada	2
2.1	Separação de sinais por canal	2
2.2	Configuração de treinamento	2
2.3	Resultado do treinamento (calibração por AutoML)	3
3	O que é feito depois do treinamento	4
4	Resultado final	5
5	Reprodução operacional	7

1 Visão geral

A pipeline combina **3 modelos especializados** (um por mecanismo físico: temperatura de mancal, vibração de mancal, pressão de óleo) com **1 canal estatístico sem modelo** (proximidade temporal a alarmes de processo já catalogados), cujas saídas binárias são combinadas por uma camada de decisão de regras fixas (votação e refratário). A Figura 1 mostra a arquitetura completa, ponta a ponta.




Figura 1: Arquitetura end-to-end da pipeline operacional: 4 canais (3 modelos + 1 estatístico), portões de produção, votação e refratário.

2 Como a pipeline é montada

2.1 Separação de sinais por canal

Cada canal modelado vê apenas os sensores do seu próprio mecanismo físico – essa separação (em vez de um único modelo recebendo todos os sinais juntos) é o que permite que cada modelo seja sensível ao seu próprio regime de anomalia, sem diluição por variação normal de outros mecanismos.

Canal	Sensores usados	Sensor alvo
1 – Temperatura	TC382_03_A, T5_AVG_A	TC382_03_A
2 – Vibração	10 canais TV_351X/Y_A ... TV_355X/Y_A	TV_351X_A
3 – Óleo	PI_0308, PDIT_0305	PI_0308
4 – Alarme de processo	5 tags de catálogo (sem sensor contínuo)	–

Tabela 1: Separação de sensores por canal. Nenhum canal modelado compartilha sensores com outro.

2.2 Configuração de treinamento

Os três canais modelados usam o mesmo algoritmo (*One-Class SVM*), a mesma janela de dados e o mesmo procedimento de calibração por AutoML (busca de limiar de anomalia e debounce por grade, validação fora da amostra). O que muda entre eles é apenas o escopo de sensores e, em alguns casos, quais portões de produção fazem sentido fisicamente para aquele mecanismo.

Parâmetro	Temperatura	Vibração	Óleo
Modelo	OCSVM	OCSVM	OCSVM
ν (nu)	0,05	0,05	0,05
γ (gamma)	scale	scale	scale
Máx. amostras de treino	50.000	50.000	50.000
Grade de percentil (limiar)	95 – 99,9	69 – 99,9	69 – 99,9
Grade de debounce (min)	1, 4, 12	1, 4, 12	1, 4, 12
Janela de dados	01/07/2024 – 20/04/2026		
Split fora-da-amostra	a partir de 01/07/2025		
Filtro de duração mínima	4,5 min	4,5 min	4,5 min
Veto de sensor congelado	30 min	30 min	30 min
Portão de degrau (T5_AVG_A)	sim	sim	não
Portão de rampa de carga (T5_AVG_A)	sim	sim	não
Portão de volatilidade	não	não	não

Tabela 2: Configuração de treinamento por canal. A grade de percentil de temperatura é mais restrita porque o sinal já vive em percentis altos; vibração e óleo usam uma grade ampliada (desde p69) para não descartar precursores fracos que vivem em percentis mais baixos.

O canal de alarme de processo não tem parâmetro treinado: é uma verificação direta de proximidade temporal (“houve um alarme de uma das 5 tags catalogadas nas últimas 24h?”), contra o catálogo `alarmes_selecionados_turbina_a.csv`, tags `PI_6240319_AL`, `PAL_6240315`, `PDAL_6240302`, `TC382_05_A`, `PAH_6240319`.

2.3 Resultado do treinamento (calibração por AutoML)

Para cada canal, a etapa de AutoML varre a grade de percentil de limiar e debounce, escolhe a combinação com melhor pontuação composta (taxa de detecção contra alarmes de referência, penalizada por falso alarme) e valida fora da amostra.

Métrica de calibração	Temperatura	Vibração	Óleo
Limiar escolhido (percentil)	p97,5	p95,0	p99,9
Valor do limiar (erro OCSVM)	10,50	0,176	29,67
Debounce escolhido	1 min	4 min	12 min
Nº de combinações testadas	15	27	27
Taxa de detecção (val. interna)	92,5%	87,5%	100%
Taxa de alarme em período normal	0,68%	10,06%	0,27%
Pontos normais usados no ajuste	386.492	386.492	574.951

Tabela 3: Resultado da calibração AutoML por canal, retreino de 03/09/2026. Essas métricas são internas ao próprio canal (contra seus alarmes de referência), antes da votação final – não confundir com o resultado da régua rigorosa apresentado na Seção 4.




Figura 2: Canal 1 (temperatura) – série com anomalias marcadas ao final do treinamento e calibração.




Figura 3: Canal 2 (vibração) – série com anomalias marcadas ao final do treinamento e calibração.




Figura 4: Canal 3 (óleo) – série com anomalias marcadas ao final do treinamento e calibração.

3 O que é feito depois do treinamento

O modelo treinado de cada canal produz um **score contínuo** de anomalia (erro de reconstrução/distância à fronteira do OCSVM). Esse score passa por uma sequência de etapas antes de virar o “voto” binário do canal:

1. **Limiar calibrado:** o score é comparado ao limiar escolhido pelo AutoML (Tabela acima) – acima do limiar por pelo menos o tempo de debounce, o ponto é candidato a anomalia.
2. **Portões de produção:** cada candidato passa por filtro de duração mínima (4,5 min), veto de sensor congelado, e, quando aplicável ao mecanismo (temperatura e vibração), portão de degrau e de rampa de carga – isso suprime falsos alarmes causados por transientes operacionais normais (partida, parada, mudança de carga), não por anomalia real.

3. **Canal binário:** o que sobra depois dos portões é o canal binário (0/1) daquele mecanismo – é isso que entra na votação.
4. **Votação:** os 4 canais binários (3 modelados + 1 estatístico) são somados ponto a ponto; a decisão bruta é “ativa” quando **pelo menos 2 dos 4** concordam no mesmo instante.
5. **Refratário:** uma vez que a decisão dispara, novas ativações do mesmo evento são suprimidas por 48h – isso evita que um único evento físico prolongado gere múltiplos alarmes repetidos.

A Figura 5 ilustra essa sequência sobre uma janela real (o TRIP de 04/11/2025): no Passo 1 cada canal acende de forma independente e em instantes diferentes; no Passo 2 a soma de votos cruza o limiar de 2 pouco antes do TRIP; no Passo 3 a decisão final dispara uma única vez (verde) e fica suprimida pelo refratário até o TRIP acontecer (linha roxa).




Figura 5: Passo a passo da camada de decisão pós-treino, sobre uma janela real de TRIP.

4 Resultado final

O resultado abaixo é do **retreino completo** dos 3 modelos (03/09/2026), avaliado contra a régua rigorosa: episódios com fusão de intervalo menor que 2h; detecção = alarme em até 48h antes de um TRIP catalogado; inconclusivo = seguido de parada real (≥ 2 h) em até 48h; senão, falso positivo. O denominador de FP/mês é o tempo efetivamente monitorado (estado operacional “ligado”), não o intervalo de calendário.

Métrica	Valor
TRIPs catalogados no período	8
TRIPs detectados	8 (100%)
Falsos positivos por mês	6,59
Episódios inconclusivos	42
Antecedência média	22,2 h

Tabela 4: Resultado final da pipeline operacional, régua rigorosa.

TRIP	1ª detecção	Antecedência
27/02/2025 08:38	25/02/2025 22:28	34,2 h
17/03/2025 18:16	16/03/2025 05:13	37,1 h
07/04/2025 21:18	06/04/2025 16:52	28,4 h
11/04/2025 17:02	10/04/2025 21:04	20,0 h
29/04/2025 03:04	28/04/2025 19:11	7,9 h
04/11/2025 06:22	03/11/2025 16:05	14,3 h
09/12/2025 08:36	08/12/2025 01:42	30,9 h
26/02/2026 15:34	26/02/2026 11:01	4,6 h

Tabela 5: Antecedência real por TRIP, pipeline final (média 22,2h).




Figura 6: Série bruta (TI_0305, TC382_03_A, T5_AVG_A, PI_0308) com a decisão final da pipeline: linhas verticais roxas = TRIPs reais; pontos verdes = acerto (8 de 8); pontos pretos = falso positivo remanescente; faixas cinza = turbina desligada.

5 Reprodução operacional

Todo o resultado deste documento é reproduzível a partir do repositório, sem passos manuais além de submeter os jobs de treinamento:

- **Configs de treino:** configs/calibracao_v4_eq/test_grupo_exp33_mancal_temperatura_isolada.js, test_grupo_exp34_mancal_vibracao_isolada.json, test_grupo_exp38_oleo_pressao_isolada.json
- **Treino:** PYTHONPATH=. python src/main.py -config <config>.json para cada um dos 3 canais (envia para a fila remota do ClearML).
- **Decisão final:** PYTHONPATH=. python scripts/pipeline_unificada_final.py – baixa os 3 point_anomalies_all.csv já treinados, monta o canal de alarme, aplica votação e refratário, e escreve o resultado final em runs_pipeline_unificada_final/.
- **Retreino completo confirmado em 03/09/2026:** os três modelos foram retreinados do zero (novas tasks no ClearML) e o resultado final foi idêntico ao deste documento – 8/8 TRIPs, 6,59 FP/mês, mesmos instantes de detecção – confirmando que a pipeline é reproduzível ponta a ponta.