

Redução de Falso Alerta no Candidato EXP7 Item 1+2

Do diagnóstico por episódios às três correções que cortaram
o falso alerta em ~82% sem perder nenhuma detecção real

Pipeline `cnn1d_ae` / AutoML — projeto TesteMLCab

Agosto de 2026

Resumo

Partindo do candidato de referência EXP7 item 1+2 (`ocsvm`, multiescala + textura — 92,5% de `hit_rate`, 1,94% de falso alerta), este relatório documenta como investigamos e reduzimos o falso alerta em ~82% (para 0,35%) **sem perder nenhuma das 32 detecções reais**. O método: fragmentar a série de anomalias em episódios contínuos, cruzar cada um com os dados brutos (temperatura, vibração) e com o catálogo completo de 47 tags de alarme, em vez de confiar só na métrica agregada. Isso revelou que o falso alerta não é ruído difuso: 65,3% dele vem de um único desligamento real de 3,5 dias que a máscara operacional não reconhecia (`RUNNING_A` ficava preso em ~1 enquanto a temperatura caía a nível ambiente), e mais 25% vem de rampas de carga legítimas (variação real de dezenas de graus/hora, sem alarme, sem falha). Três correções cirúrgicas, todas na camada de pós-processamento (nenhuma toca no modelo de anomalia em si), resolveram a maior parte disso: um segundo critério de “desligado” baseado no piso físico do próprio sensor-alvo; um portão de rampa (já existente no pipeline CNN1D-AE, mas nunca portado para o AutoML) ajustado por simulação offline até o ponto de custo zero; e um portão de volatilidade novo, que só existe porque a primeira tentativa (reaproveitar o portão de rampa para a vibração) não funcionou e a investigação de por que não funcionou apontou o mecanismo certo. Documentamos também um caminho testado e descartado — aumentar o `debounce` — com a evidência de por que não funciona.

Sumário

1	Ponto de partida	2
2	Metodologia	2
2.1	Como um ponto vira (ou deixa de virar) anomalia: o pipeline completo	2
2.2	Diagnóstico: fragmentar em vez de agregar	6
3	Achado 1: desligamento real que a máscara não via	7
3.1	O episódio	7
3.2	Confirmação: não é artefato de dado	8
3.3	Correção: segundo critério de “off” independente	8
3.4	Resultado (EXP10)	8
4	Um caminho testado e descartado: <code>debounce</code>	8
5	Achado 2: rampas de carga reais	10
5.1	Investigação dos 10 maiores episódios residuais	10
5.2	A correção já existia — só não estava conectada	10
5.3	Ajuste: por que a janela curta importa	11
5.4	Resultado (EXP10b)	11

6	Achado 3: volatilidade que persiste, não que sobe	11
6.1	Tentativa 1: reaproveitar o portão de rampa (falhou)	11
6.2	Tentativa 2: limiar direto no nível (funcionou)	12
6.3	Resultado (EXP10c)	12
7	Resultado consolidado	13
7.1	A jornada completa: da detecção ao falso alerta	13
7.2	A série completa, ao longo dos 4 experimentos	14
8	O que ainda resta	17
9	O que foi inovador aqui	17

1 Ponto de partida

O candidato de referência da série EXP5–EXP9 é o `ocsvm` (percentil 99,9, `debounce=1`) sobre o grupo `TC382_T5_vibracao_mancais_multiescala` (`TC382_03_A` + `T5_AVG_A` + 10 canais de vibração de mancal, com features multi-escala e de textura — EXP7 itens 1+2). Avaliado no período out-of-sample de 2025-07-01 a 2026-04-30, contra os 32 alarmes reais de `TC382_03_A/T5_AVG_A` desse período (excluindo os 8 alarmes `UNDER`, já identificados como falha de sensor/comunicação em relatório anterior):

Métrica	Valor
hit_rate (40 alarmes, com <code>UNDER</code>)	92,5% (37/40)
Detecção (32 alarmes reais)	100% (32/32)
Antecedência real (preditivo)	90,6% (29/32)
Falso alerta (<code>normal_alert_rate</code>)	1,94%

Tabela 1: Candidato de partida deste relatório. Detalhe completo em `docs/analise_automl_exp7.md`.

Detecção já estava no teto do que EXP9 (features correlacionadas, grade de hiperparâmetro) conseguiu melhorar — ambas as frentes deram resultado negativo (documentado em conversa anterior). Sobrava então uma pergunta diferente: **o 1,94% de falso alerta é ruído aleatório, ou tem estrutura que dá pra explorar?**

2 Metodologia

2.1 Como um ponto vira (ou deixa de virar) anomalia: o pipeline completo

Antes de entrar no método de diagnóstico, vale deixar explícito o caminho que um instante de 30s percorre até virar (ou não) um ponto de `is_anom_point=1`. Todas as correções deste relatório entram nesse caminho como filtros adicionais — nenhuma delas muda o modelo `ocsvm` em si.

- Score do modelo.** O `ocsvm` (treinado só com dados “normais”, fora de janela de alarme e em estado “on”) calcula uma função de decisão para cada ponto de todo o período; pontos cuja função de decisão ultrapassa o percentil 99,9 dessa mesma função no conjunto de treino viram `anomaly_flags=1` brutos.
- Debounce.** `anomaly_flags` passa por `map_seq_to_point_anomalies`, que exige `debounce` pontos brutos consecutivos antes de marcar `is_anom_point=1` (regra “all_of_window”). O candidato usa `debounce=1` — ou seja, nesta etapa `is_anom_point` é literalmente igual ao sinal bruto do modelo (ver Seção 4 para por que não subimos esse valor).

3. **Máscara operacional** (`build_operational_state`, Seção 3) — zera `is_anom_point` fora do estado “on”.
4. **Portão de rampa** (`apply_load_gate`, Seção 5) — zera `is_anom_point` durante uma manobra de carga rápida.
5. **Portão de volatilidade** (`apply_volatility_gate`, Seção 6) — zera `is_anom_point` quando a vibração está anormalmente instável.
6. **Avaliação.** `hit_rate` conta um alarme como detectado se existir *qualquer* `is_anom_point=1` dentro de ± 24 h dele; `normal_alert_rate` (o “falso alerta” deste relatório) é a fração de `is_anom_point=1` entre os pontos em estado “on” que ficam *fora* de qualquer uma dessas janelas de ± 24 h.

As etapas 3–5 são independentes entre si (cada uma só zera pontos, nunca adiciona) — a ordem entre elas não importa para o resultado final, só para o que aparece em qual coluna de diagnóstico (`operational_state`, `load_gate_blocked`, `volatility_gate_blocked`) no CSV de saída.

Máscara operacional: dois critérios independentes de “off”

`build_operational_state` recebe uma série de referência (`OPERATIONAL_REF_SENSOR`, aqui `RUNNING_A`) e marca “off” todo ponto onde essa série fica $\leq \text{OFF_ABS_THRESHOLD}$ (0,5). A partir da Seção 3, ela também aceita uma **segunda série independente** (`secondary_series/secondary_off_abs_threshold`) — o próprio sensor-alvo do grupo, com piso 150°C — unida por OR ao critério original antes de qualquer outra lógica rodar. A partir daí:

- cada corrida contínua de pontos “off” vira `off_curto` ($< \text{OFF_LONG_MIN_HOURS}=4$ h) ou `off_longo` (≥ 4 h);
- as bordas de cada transição on/off ganham `TRANSIENT_PADDING_MINUTES=60`min de margem, marcada `transiente`;
- independentemente disso, qualquer salto ponto-a-ponto acima do percentil 99 (`TRANSIENT_DIFF_QUANTILE`) da série de referência também vira `transiente`.

Só o estado `on` é pontuado e usado no treino — é por isso que essa máscara também define o que conta como dado “normal” para o `ocsvm` aprender, não só o que é excluído da avaliação.

Como a máscara operacional funciona, ponto a ponto (19-24/08/2025)

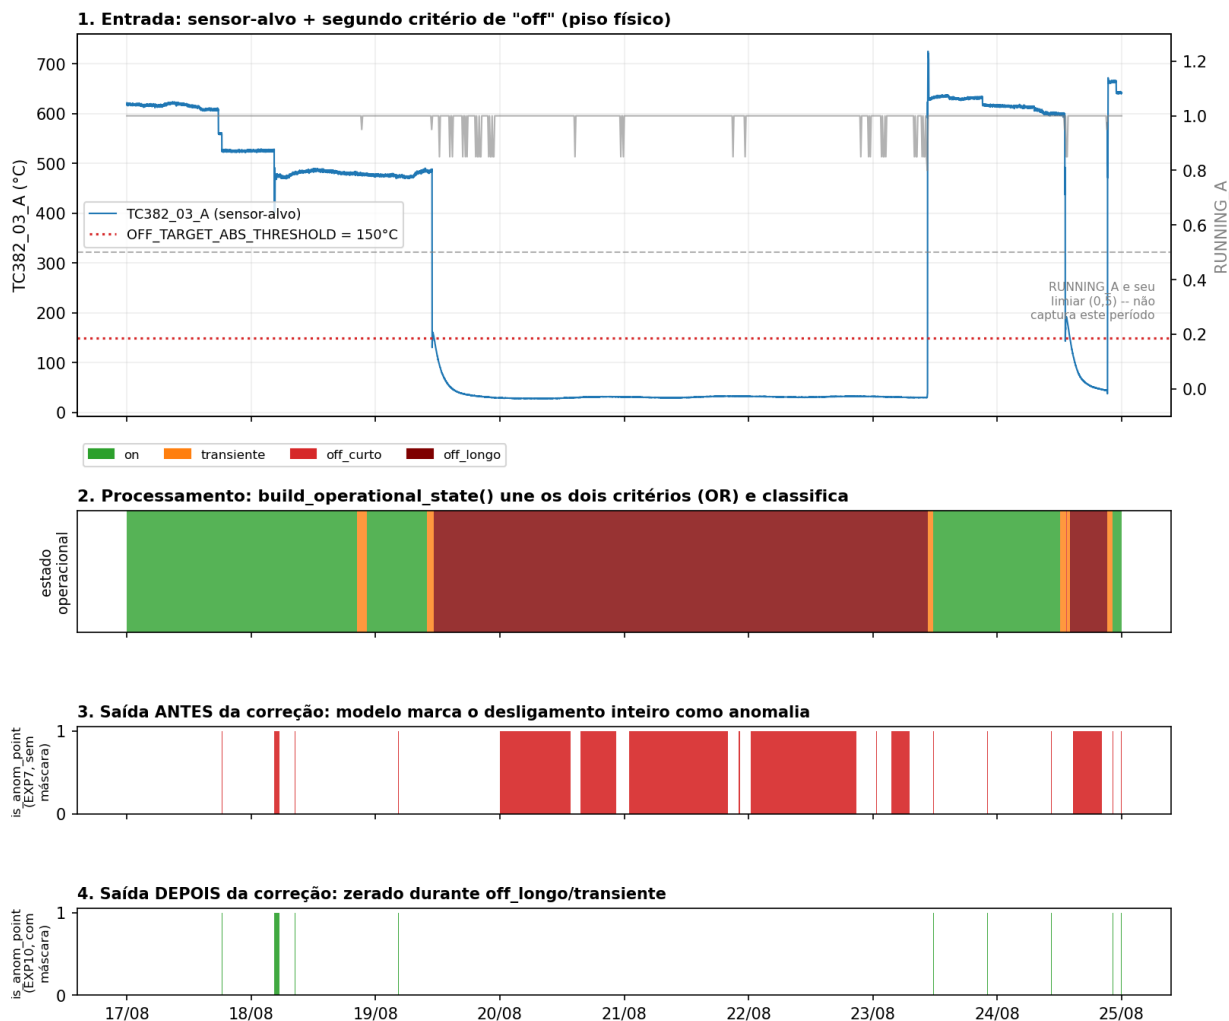


Figura 1: A máscara operacional em ação, no episódio real do Achado 1. **1:** o sensor-alvo cruza o piso de 150°C enquanto `RUNNING_A` (cinza) permanece perto de 1 – o critério antigo sozinho nunca dispararia aqui. **2:** os dois critérios unidos por OR classificam quase 3,5 dias como `off_longo` (vinho). **3:** sem a máscara, o modelo marca o desligamento inteiro como anomalia (EXP7). **4:** com a máscara, esses pontos são zerados (EXP10) – só sobra o que acontece fora do período off.

Portão de rampa: taxa de variação suavizada de um proxy

`apply_load_gate` (via `compute_load_ramp_gate`) toma uma série-proxy (`LOAD_GATE_SENSOR`, aqui `T5_AVG_A`), suaviza com EWMA de meia-vida `LOAD_GATE_RAMP_HALFLIFE_MINUTES` (causal — só olha o passado), deriva no tempo para obter uma rampa em unidades/hora, e toma o máximo trailing dessa rampa numa janela de `LOAD_GATE_WINDOW_MINUTES`. Bloqueia `is_anom_point` quando esse máximo ultrapassa `LOAD_GATE_RAMP_MAX`.

Como o portão de rampa funciona, ponto a ponto (29/01/2026)

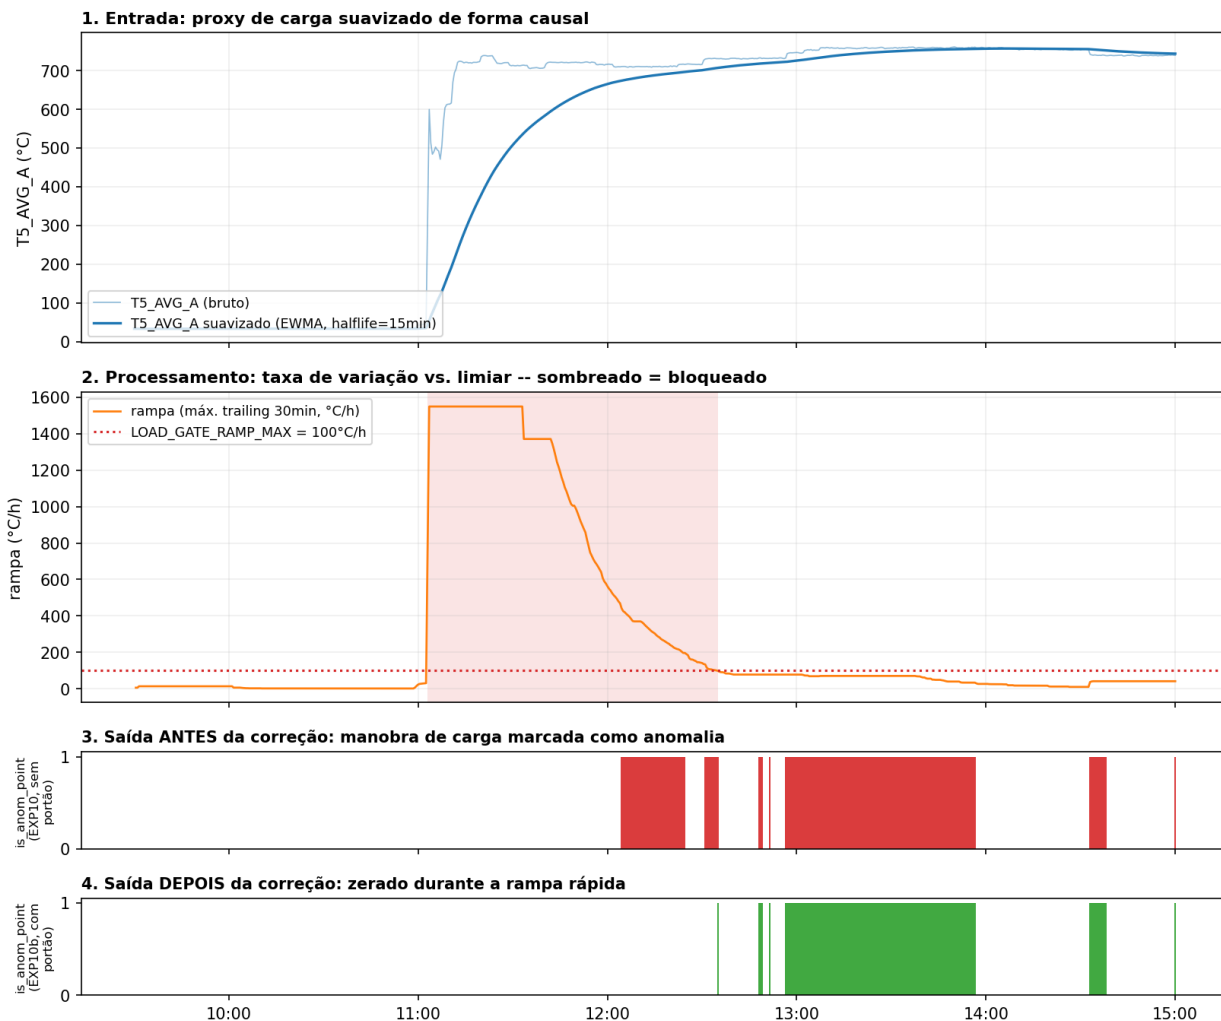


Figura 2: O portão de rampa em ação, num episódio real de manobra de carga (29/01/2026). **1:** T5_AVG_A sobe $\sim 600^{\circ}\text{C}$ em minutos; a curva suavizada (EWMA) segue com atraso controlado. **2:** a rampa calculada dispara a mais de 1500°C/h , muito acima do limiar de 100 – a área sombreada mostra exatamente onde o portão fica ativo. **3:** sem o portão, o modelo marca a manobra (e outros dois episódios não relacionados, fora da área sombreada) como anomalia (EXP10). **4:** com o portão, só o episódio *dentro* da rampa some – os outros dois, sem rampa acentuada, continuam marcados (EXP10b), mostrando que o filtro é seletivo, não um corte cego de horário.

Portão de volatilidade: nível de um índice multivariado

`apply_volatility_gate` (via `compute_volatility_index`, Seção 6) toma um conjunto de sensores (`VOLATILITY_GATE_SENSORS`, aqui os 10 canais de vibração), calcula o desvio-padrão móvel causal de cada um numa janela de `VOLATILITY_GATE_WINDOW_MINUTES` e reduz pela média entre canais a cada instante. Bloqueia `is_anom_point` quando esse índice ultrapassa `VOLATILITY_GATE_THRESHOLD` — diferente do portão de rampa, aqui o critério é o *nível* do índice, não sua taxa de variação (ver Seção 6 para o porquê dessa escolha).

Como o portão de volatilidade funciona, ponto a ponto (31/08/2025)




Figura 3: O portão de volatilidade em ação, no mesmo episódio de 31/08/2025 já visto na Figura 8. **1:** quatro dos 10 canais de vibração (o painel completo usa os 10) – TV_352Y_A salta de patamar por volta das 09:10. **2:** o índice de volatilidade (média do desvio-padrão móvel dos 10 canais) cruza o limiar de 0,39 logo depois e fica acima por ~1h20. **3:** sem o portão, o episódio inteiro é marcado como anomalia (EXP10b). **4:** com o portão, a maior parte some – só sobram frações residuais bem nas bordas, exatamente onde o índice cruza o limiar (o modelo já havia reagido um pouco antes/depois do instante exato em que o índice passa a linha), evidência de que o mecanismo está reagindo ponto a ponto, não arredondando por episódio inteiro.

2.2 Diagnóstico: fragmentar em vez de agregar

A ideia central deste trabalho, difere do que fizemos até aqui: em vez de olhar só o `normal_alert_rate` agregado, **fragmentamos a série de `is_anom_point` em episódios contínuos** (agrupando pontos anômalos consecutivos com $\text{gap} \leq 5$ min) e cruzamos cada episódio com:

- (a) os dados brutos de TC382_03_A/T5_AVG_A e dos 10 canais de vibração, no período do episódio e ao redor;
- (b) o catálogo completo de alarmes (47 tags, não só os 2 sensores avaliados) — pra checar se o episódio coincide com *algum* evento real registrado em outro lugar da planta;
- (c) o estado operacional (`RUNNING_A`) computado pela máscara existente.

Essa abordagem revelou uma estrutura que a métrica agregada escondia: dos 12.782 pontos de falso alerta no período OOS, **72,5% se concentram em apenas 10 episódios** de 295 no total. Não é ruído espalhado — é um número pequeno de causas concretas e investigáveis.




Figura 4: Decomposição dos 12.782 pontos de falso alerta por causa raiz, depois de investigar os episódios individualmente.

3 Achado 1: desligamento real que a máscara não via

3.1 O episódio

Os 5 maiores episódios (61,5% de todo o falso alerta) caem todos entre 19 e 24 de agosto de 2025. Ao puxar a série bruta: TC382_03_A despenca de $\sim 478^{\circ}\text{C}$ para $\sim 28\text{--}32^{\circ}\text{C}$ (nível ambiente) e fica lá por **3,5 dias**. Fisicamente incompatível com operação — faixa normal é $\sim 600\text{--}800^{\circ}\text{C}$.

O problema: `RUNNING_A` (o sensor de referência da máscara operacional) fica em $\sim 0,96\text{--}1,0$ o tempo todo durante esse período. A máscara original só olha `RUNNING_A` $\leq 0,5$ pra decidir “desligado” — então esse desligamento inteiro nunca era excluído da avaliação, e o modelo (corretamente!) marcando temperatura fora de qualquer faixa treinada como anomalia virava, na nossa métrica, “falso” alerta.




Figura 5: TC382_03_A cai a nível ambiente por 3,5 dias enquanto RUNNING_A permanece ~ 1 . A área sombreada é o período que a máscara original classificava como “on”.

3.2 Confirmação: não é artefato de dado

Cruzando com o catálogo completo de 47 tags: PI_6240319_AL (falha de partida a gás) dispara em 19/08 e novamente em 23/08; PAL_6240315 (pressão baixa de gás combustível) dispara em 23/08 — exatamente nas bordas do período. Desligamento e religamento reais, documentados, não uma falha de sensor.

3.3 Correção: segundo critério de “off” independente

`build_operational_state` (`scoring.py`) ganhou um parâmetro opcional `secondary_series/secondary_off_a` — o próprio sensor-alvo do grupo (TC382_03_A) caindo abaixo de um piso físico (150°C — bem abaixo de qualquer operação normal, com folga sobre os $\sim 28\text{--}32^{\circ}\text{C}$ do desligamento confirmado) **também** conta como “off”, unido (OR) ao critério de RUNNING_A antes da classificação `off_curto/off_longo/transiente` — reusando toda a lógica de detecção de corrida contínua já existente, sem duplicar código. Novo campo de config: `OFF_TARGET_ABS_THRESHOLD`.

Por que isso é a correção certa e não um ajuste ad-hoc: o critério original (RUNNING_A) e o novo (piso físico do alvo) são *independentes* — um poderia falhar sem o outro falhar junto. Unir os dois com OR é estritamente mais seguro que qualquer um sozinho, sem introduzir nenhuma suposição nova sobre o que é “normal”.

3.4 Resultado (EXP10)

Métrica	EXP7 item1+2	EXP10 (+ máscara corrigida)
hit_rate (40 alarmes)	92,5% (37/40)	92,5% (37/40)
Falso alerta	1,94%	0,67%

Tabela 2: Zero mudança de detecção, falso alerta cai quase 3x. Seed-sweep (5 sementes) confirma estabilidade: desvio-padrão de 0,019pp.

4 Um caminho testado e descartado: debounce

Antes de investigar o restante do falso alerta em detalhe, testamos a alavanca mais óbvia: aumentar o **debounce** (exigir mais pontos anômalos consecutivos antes de disparar o alerta). Como o

candidato usa `debounce=1`, o `is_anom_point` já cacheado é o sinal bruto — deu pra simular toda a grade offline, sem re-rodar remoto.




Figura 6: Até `debounce=10` o ganho de FP é pequeno (1,94%→1,66%) e já custa 3 casos preditivos. Além disso, o modelo começa a perder alarmes reais inteiros.

Por que não funciona: os episódios de falso alerta residual têm mediana de 6 pontos/2,5 minutos de duração — quase idêntico à duração dos episódios mais curtos que ainda assim precedem um alarme real (25º percentil = 6 min). Debounce não consegue separar os dois porque as distribuições de duração se sobrepõem.




Figura 7: Duração dos episódios de falso alerta residual (vermelho) vs. duração do episódio que gera a 1ª detecção antes de cada alarme real (verde). Sobreposição forte nas durações curtas.

Esse é um achado negativo documentado por completude, consistente com a lição já registrada

no EXP7: mexer em limiar/debounce agressivamente sempre trocou detecção real por FP de forma desfavorável.

5 Achado 2: rampas de carga reais

5.1 Investigação dos 10 maiores episódios residuais

Com o desligamento de agosto resolvido, sobravam 4.441 pontos de falso alerta em 287 episódios. Uma primeira caracterização estatística já apontava a direção: **o nível de TC382_03_A é igual** entre pontos de falso alerta e pontos normais (não é viés de faixa), mas a **variabilidade local é 5–9x maior** (desvio-padrão de 1h: 5,37 vs. 1,09 nos pontos normais; vibração $\sim 2,5x$ mais volátil).

Investigando os 10 maiores episódios individualmente (dados brutos, não só estatística agregada): **8 de 10** mostram o mesmo padrão — TC382_03_A/T5_AVG_A subindo ou caindo dezenas de graus em cerca de 1 hora, com o desvio-padrão da vibração triplicando ou sextuplicando durante o episódio. Sem alarme, sem falha — manobra de carga real.




Figura 8: Exemplo (26/08/2025): queda e recuperação de $\sim 60^\circ\text{C}$ em $\sim 1\text{h}30$, com desvio-padrão de vibração subindo de $\sim 0,17$ para $\sim 1,35$ (8x) e permanecendo elevado por boa parte do episódio — o padrão que motiva o portão de volatilidade da Seção 6.

5.2 A correção já existia — só não estava conectada

O pipeline CNN1D-AE (pipeline.py) já tinha um “portão de rampa de carga” (ENABLE_LOAD_GATE/apply_load_gate) que suprime `is_anom_point` quando a rampa (derivada suavizada) de um sensor-proxy de carga ultrapassa um limite, de forma causal (nunca olha o futuro). Mecanismo certo para exatamente esse padrão — mas **nunca tinha sido portado para o pipeline AutoML**, que é o que usamos desde o EXP5.

5.3 Ajuste: por que a janela curta importa

A primeira tentativa, com os parâmetros default do CNN1D-AE (`halflife=120min`, janela `trailing=360min`), **custou detecção real** — bloqueava até 6 dos 29 casos preditivos, porque uma rampa de temperatura de falha genuína tem a mesma assinatura de taxa de variação que uma rampa de carga legítima; uma janela de memória longa não distingue as duas. Reduzindo a janela (`halflife=15min`, `trailing=30min`) e testando o limiar `ramp_max` por simulação offline:




Figura 9: Com janela curta, `ramp_max=100°C/h` é o ponto exato de custo zero: último valor que preserva os 29/29 casos preditivos.

5.4 Resultado (EXP10b)

Métrica	EXP7 item1+2	EXP10	EXP10b (+ portão de rampa)
hit_rate (40 alarmes)	92,5% (37/40)	92,5% (37/40)	92,5% (37/40)
Falso alerta	1,94%	0,67%	0,48%

Tabela 3: Novamente zero mudança de detecção. Seed-sweep confirma estabilidade (desvio-padrão de 0,016pp).

6 Achado 3: volatilidade que persiste, não que sobe

O portão de rampa (Seção 5) reagiu bem à parte das rampas de carga que se manifestam como uma variação clara de *nível* em `T5_AVG_A`. Mas ele não foi desenhado pensando na vibração — e o padrão que já tínhamos visto na Figura 8 (Seção 5) é diferente: o desvio-padrão da vibração *sobe* durante a manobra, mas também *permanece* elevado por 1–2h, não é só um pico passageiro na subida.

6.1 Tentativa 1: reaproveitar o portão de rampa (falhou)

A primeira tentativa foi a mais óbvia: alimentar `apply_load_gate` com um índice de volatilidade de vibração (desvio-padrão móvel médio entre os 10 canais) no lugar do proxy de temperatura, mantendo o mesmo mecanismo de taxa de variação. O resultado foi decepcionante — o ponto de

custo zero ($\text{thr}=8$, preservando 29/29 preditivos) reduzia o FP de 0,480% para apenas 0,477%, e qualquer limiar que desse um ganho real custava 2 casos preditivos em praticamente toda a faixa testada (painel esquerdo da Figura 10).

Por quê: taxa de variação mede o quão rápido algo está mudando *agora*, e tanto o início de uma rampa de carga real quanto o início de uma escalada genuína de falha aceleram a volatilidade de forma parecida — o mesmo problema de assinatura compartilhada que já tinha custado detecção na primeira tentativa do portão de rampa (Seção 5), agora reaparecendo por um motivo relacionado mas distinto: a métrica escolhida (derivada) não é a que separa os dois casos.

6.2 Tentativa 2: limiar direto no nível (funcionou)

Reformulando pra medir o que a Figura 8 realmente mostrava — não a taxa de subida, mas o *nível* sustentado — implementamos `compute_volatility_index/apply_volatility_gate` (`scoring.py`): desvio-padrão móvel causal (`VOLATILITY_GATE_WINDOW_MINUTES=60min`) de cada um dos 10 canais de vibração, reduzido pela média entre canais a cada instante, bloqueando `is_anom_point` sempre que esse índice ultrapassa um limiar fixo (não uma taxa). Testado por simulação offline sobre o já corrigido pelo EXP10b:




Figura 10: Painel esquerdo: taxa de variação do índice de volatilidade — o ponto de custo zero mal reduz o FP. Painel direito: limiar direto no nível do mesmo índice — `threshold=0,39` preserva 29/29 preditivos com queda real de FP (27% relativo).

6.3 Resultado (EXP10c)

Métrica	EXP7 item1+2	EXP10	EXP10b	EXP10c (+ portão de volatilidade)
hit_rate (40 alarmes)	92,5% (37/40)	92,5% (37/40)	92,5% (37/40)	92,5% (37/40)
Falso alerta	1,94%	0,67%	0,48%	0,35%

Tabela 4: Quarta confirmação seguida de custo zero de detecção. Seed-sweep: desvio-padrão de 0,011pp.

7 Resultado consolidado




Figura 11: Falso alerta cai ~82% (1,94%→0,35%) ao longo das três correções, com hit_rate idêntico (92,5%, 37/40) em todas as etapas.

7.1 A jornada completa: da detecção ao falso alerta

O relatório do EXP7 multiescala ([relatorio_exp7_multiescala.pdf](#)) mostrava a evolução de **Preditivo/Reativo/Sem detecção** ao longo de EXP6 → item 1 → item 1+2 – a fase em que a *detecção* melhorou. Este relatório continua exatamente dali, mas numa fase diferente: da EXP7 item 1+2 em diante, a detecção já não muda mais (os mesmos 29 preditivos, 8 reativos, 3 sem detecção se repetem idênticos em EXP10, EXP10b e EXP10c) – o que evolui é só o falso alerta. A Figura 12 junta as duas fases num único gráfico, deixando visível a virada: as barras (detecção) sobem entre as duas primeiras colunas e depois ficam paradas; a linha (falso alerta) seguiu praticamente estável entre as duas primeiras e despenca na terceira.




Figura 12: Evolução completa: EXP7 item 1 → item 1+2 (ganho de detecção, achado do relatório anterior) → EXP10c (ganho de falso alerta, achado deste relatório). Barras = alarmes por categoria (eixo esquerdo); linha tracejada = falso alerta (eixo direito). As barras verde/laranja/vermelha ficam *idênticas* entre item 1+2 e EXP10c – prova visual de que as três correções de FP não mexeram em nenhuma detecção, só na linha preta.

7.2 A série completa, ao longo dos 4 experimentos

A comparação agregada acima resume o resultado, mas vale ver a própria série de detecção – não só o número final. A Figura 13 mostra a contagem diária de pontos marcados como anômalos ao longo de todo o período OOS (2025-07 a 2026-04), uma linha por experimento (EXP7 → EXP10 → EXP10b → EXP10c), com a janela de ± 24 h ao redor de cada um dos 40 alarmes sombreada em cinza (a mesma janela que `normal_alert_rate` exclui do cálculo de falso alerta). O que sobra *fora* da faixa cinza é, por definição, falso alerta.

Evolução da série de detecção ao longo dos 4 experimentos, período OOS completo (2025-07 a 2026-04)




Figura 13: Pontos anômalos por dia em cada um dos 4 experimentos, mesma escala vertical. A linha 1 (EXP7) tem o bloco maciço de 20–22/08 (desligamento mal rotulado); a linha 2 (EXP10) já o elimina por completo, confirmando que a correção age exatamente onde devia. Das linhas 2 a 4, os picos residuais fora da faixa cinza (fim de agosto, início de outubro, alguns dias em fevereiro/março/abril) encolhem progressivamente – efeito cumulativo do portão de rampa e depois do portão de volatilidade. Os picos *dentro* da faixa cinza (detecção de alarme real) ficam idênticos nas 4 linhas, como esperado – nenhuma das correções toca a detecção.

Em detalhe, comparando só a primeira e a última etapa lado a lado:




Figura 14: Pontos anômalos por dia, período OOS completo, EXP7 item1+2 vs. EXP10c (as três correções). Os picos dentro da faixa cinza (perto de um alarme, sólida = HI/HIHI, pontilhada = UNDER) são detecção, não falso alerta, e por isso ficam praticamente idênticos entre os painéis. O bloco vermelho maciço de 20–22/08 (o desligamento mal rotulado) desaparece completamente no painel de baixo, e os picos residuais fora da faixa cinza (fim de agosto, início de outubro) ficam visivelmente menores – efeito combinado dos portões de rampa e de volatilidade.

Dois pontos que a Figura 14 deixa explícitos:

- O pico isolado logo após “Ago/25” (na verdade 24–25/07) fica **idêntico** nos dois painéis porque cai dentro da janela de um alarme UNDER – já não contava como falso alerta em nenhum dos dois candidatos, então não era esperado que mudasse. Serve de contraste: nem todo pico grande é falso alerta, e nem todo falso alerta é um pico pequeno.
- Os picos que ainda sobram *fora* de qualquer faixa cinza no painel de baixo (poucos dias entre outubro e abril) são o resíduo de 0,35% não endereçado por nenhuma das três correções – majoritariamente falha de sensor pontual e correlação com outro alarme fora do escopo de 2 sensores (ver Seção 8).

Um zoom no trecho de 15/08 a 10/09/2025 (que cobre o desligamento e a maior parte das rampas de carga investigadas) deixa a comparação ainda mais direta:

Zoom (15/08 a 10/09/2025): cada traço é um instante marcado como anômalo — faixa cinza = janela de alarme (não é FP)

ANTES — EXP7 item 1+2



DEPOIS — EXP10c




Figura 15: Cada traço vertical é um instante de 30s marcado como anômalo, EXP7 item1+2 vs. EXP10c. O bloco sólido de 19–23/08 (desligamento) desaparece por completo; o traçado que sobra já é visivelmente mais esparsa que o intermediário do EXP10b (comparar com a versão anterior deste relatório) – efeito do portão de volatilidade sobre os episódios de rampa que o portão de rampa sozinho não zerava totalmente.

O novo candidato de referência da série EXP5–EXP10: `ocsvm` (percentil 99,9, `debounce=1`) sobre multiescala + textura + máscara operacional corrigida (`OFF_TARGET_ABS_THRESHOLD`) + portão de rampa (`ENABLE_LOAD_GATE`, janela curta) + portão de volatilidade (`ENABLE_VOLATILITY_GATE`). Nenhuma das três correções tocou no modelo de anomalia em si — todas atuam inteiramente na camada de pós-processamento/avaliação, sobre problemas de rotulagem e de contexto operacional, não sobre o que o `ocsvm` aprendeu.

8 O que ainda resta

Os 0,35% de falso alerta remanescente não têm mais um único bloco dominante como no início – o mapa de causas original (Seção 2) tinha duas fatias ainda não endereçadas por nenhuma das três correções:

- **Contaminação por dropout de sensor** (~2,1% do FP original): um dropout breve ($-40, x$) contamina a feature de tendência de 24h por até 24h depois, mesmo com o dado já normal de volta. Nenhuma das três correções deste relatório mira esse mecanismo especificamente.
- **Correlacionado com outro alarme real fora de escopo** (~9,7%): picos que coincidem com alarmes de pressão/partida a gás (`PAL_6240315`, `PI_6240319_AL`) do mesmo equipamento – não é erro do modelo, é eco de um evento real que nossa avaliação de 2 sensores não credita. Resolver isso é uma decisão de metodologia de avaliação (ampliar a janela de exclusão pra outras categorias de alarme do catálogo), não um fix de modelo.

9 O que foi inovador aqui

- **Método:** até este relatório, toda a série EXP5–EXP9 avaliava candidatos pela métrica agregada (`hit_rate/normal_alert_rate`) ou, no máximo, pelo breakdown preditivo/reativo/sem-detecção por alarme. Fragmentar a *série de falso alerta* em episódios contínuos e investigar

cada um contra dado bruto + catálogo completo é uma unidade de análise nova, que revelou estrutura (72,5% em 10 episódios) onde a métrica agregada só mostrava um número.

- **Achado 1:** o falso alerta majoritário não era um problema do detector — era um problema de rotulagem operacional que mascarava um evento real. A correção (segundo critério de off, independente, unido por OR) generaliza para qualquer grupo/sensor-alvo futuro sem precisar reajustar `RUNNING_A`.
- **Achado 2:** reaproveitamos um mecanismo que já existia no código (portão de rampa) mas nunca tinha sido conectado ao pipeline que efetivamente usamos. A parte nova não foi a ideia — foi (a) perceber que o padrão nos dados pedia exatamente essa ferramenta, e (b) descobrir, por simulação offline sistemática, que os parâmetros default do outro pipeline custavam detecção real, e recalibrar a janela de memória até o ponto de custo zero.
- **Achado 3:** a inovação real aqui não foi a primeira ideia (reaproveitar o portão de rampa pra vibração) — foi **diagnosticar por que ela falhou** (taxa de variação não distingue rampa real de rampa de falha) e voltar pra evidência bruta (Figura 8) pra perceber que o padrão físico certo era *nível sustentado*, não *taxa de subida* — e só então escrever um mecanismo novo (`compute_volatility_index`) desenhado especificamente pra isso. Uma tentativa que não funciona, investigada até o fim, apontou o caminho certo em vez de ser só descartada.
- **Disciplina:** as três correções foram validadas por simulação offline *antes* de qualquer submissão remota (reaproveitando o `is_anom_point` já cacheado em `debounce=1`), e por teste de fumaça sintético ponta-a-ponta antes do commit — o mesmo padrão de rigor usado em toda a série EXP5–EXP9, aplicado agora à camada de pós-processamento. Nas três vezes, o resultado em produção bateu a simulação offline com menos de 0,01pp de diferença.
- **Resultado:** −82% de falso alerta (1,94%→0,35%) em quatro passos incrementais, custo zero de detecção em cada um deles, confirmado em produção (task remota) a cada etapa.