

Detecção de Anomalias em Cabiúnas via AutoML

Da vibração de mancais ao falso alerta residual:
a jornada completa EXP6 — EXP10c

Pipeline `cnn1d_ae` / AutoML — projeto TesteMLCab

Agosto de 2026

Resumo

Este relatório consolida, num único documento e numa única linha de raciocínio, toda a série de experimentos que vai do primeiro modelo multivariado com vibração de mancais (**EXP6**) até o detector final com falso alerta reduzido em 82% (**EXP10c**). A jornada tem duas fases nitidamente diferentes. Na **primeira fase (EXP6 → EXP7, itens 1–3)**, o objetivo é *cobertura*: sair de 65% de antecedência real (26/40 alarmes) para 72,5% (29/40) – e, olhando só os alarmes fisicamente reais (excluindo falhas de sensor disfarçadas de alarme), 90,6% (29/32) – às custas de mais falso alerta (0,06%→1,94%). Na **segunda fase (EXP10 → EXP10c)**, o objetivo se inverte: sem tocar no modelo nem perder nenhum alarme já detectado, cortar o falso alerta residual de 1,94% para 0,35% (queda de 82%) atacando três causas estruturais distintas, uma de cada vez. Cada etapa é apresentada com o mesmo roteiro: onde paramos, o que mudou (com esquema visual do mecanismo), a configuração usada, e o resultado – tanto do ponto de vista agregado (contexto geral) quanto do sensor-alvo especificamente (casos individuais, antes e depois).

Sumário

Glossário de termos técnicos	3
I Fundamentos: a pipeline e o ponto de partida (EXP6)	5
1 Objetivo do EXP6	5
2 Dados e janela temporal	5
3 Como a pipeline foi montada	6
4 Achado pré-resultado: a máscara operacional não cobria o treino	6
5 Configuração da rodada	7
6 Quem venceu a rodada	7
7 Resultado obtido	9
II EXP7: fechando os pontos fracos do EXP6	11
8 Visão geral e plano de ataque	11

9	Item 1 — Features multi-escala	11
9.1	Onde paramos	11
9.2	O que muda: quatro janelas em vez de uma	11
9.3	Configuração de treinamento	12
9.4	Resultado: mais cobertura, mais falso alerta	12
9.5	Desvio: o candidato de baixo FP que parecia bom mas não era	13
10	Item 2 — Textura do sinal (kurtosis, skewness, crest factor)	14
10.1	Onde paramos	14
10.2	O que muda: forma do sinal, não só nível	14
10.3	Configuração de treinamento	14
10.4	Resultado: ganho limpo em todos os eixos ao mesmo tempo	15
10.5	Gráficos do que acertamos e do que não acertamos	15
11	Item 3 — Detecção de mudança de regime (CUSUM + z-score local)	16
11.1	Onde paramos	16
11.2	O que muda: linha de base local em vez de limiar global	16
11.3	Configuração de treinamento	17
11.4	Resultado: nenhum ganho adicional	17
12	Aprofundamento: qualidade dos alarmes	18
12.1	Os 40 alarmes não são homogêneos	18
12.2	UNDER é falha de sensor, não evento físico	19
12.3	Métricas corrigidas: o que de fato conta como alarme real	20
12.4	Os 3 alarmes reativos remanescentes	21
III	EXP10: do candidato final de temperatura ao falso alerta residual	23
13	Ponto de partida	23
14	Achado 1 (EXP10): desligamento real que a máscara não via	23
15	Achado 2 (EXP10b): rampas de carga reais	25
16	Achado 3 (EXP10c): volatilidade que persiste, não que sobe	28
17	Resultado consolidado: o sensor-alvo, antes e depois	29
IV	Conclusão: a escada completa	33
18	A jornada em uma figura	33
19	Contexto geral vs. sensor-alvo	33
20	Onde isso deixa o detector	34

Glossário de termos técnicos

Termos usados ao longo de todo o relatório, com significado estável em todas as seções – consulte esta lista sempre que um termo técnico aparecer sem explicação no meio do texto.

Avaliação e métricas

OOS (*out-of-sample*)

Período de dados que o modelo **nunca viu** durante o treino/ajuste. É a única forma honesta de medir se o modelo generaliza: avaliar no mesmo período usado para treinar (*in-sample*) pode dar números ótimos só porque o modelo memorizou aquele trecho específico, sem aprender um padrão real – isso de fato aconteceu numa etapa anterior desta série (`docs/analise_automl_exp5.md`, EXP5-v3: dense com 78–82% de acerto in-sample despencou para 53–65% assim que validado OOS). Neste relatório, o corte OOS é sempre **2025-07-01**: tudo antes é treino, tudo depois é avaliação.

threshold Limiar de erro de reconstrução (ou score de anomalia) acima do qual um ponto é classificado como anômalo. É definido como um **percentil** da distribuição desse erro *no conjunto de treino* – ex.: “percentil 99,9” significa que o threshold é o valor que deixa 99,9% dos pontos de treino abaixo dele, então só o 0,1% mais extremo do próprio treino já seria marcado como anômalo se ocorresse de novo.

debounce Número de pontos **consecutivos** que precisam ultrapassar o threshold para a anomalia “contar” como detecção, em vez de ruído momentâneo de um único ponto isolado. **debounce=1** aceita qualquer ponto isolado; **debounce=6** exige 6 pontos seguidos acima do threshold.

hit_rate Fração dos alarmes reais (na avaliação OOS) que tiveram pelo menos um ponto anômalo detectado dentro de uma janela ao redor do horário do alarme ($\pm 24h$ neste relatório). **Não distingue** detecção antes do alarme (preditivo) de detecção só depois (reativo) – só mede “detectou ou não” dentro da janela.

normal_alert_rate (FP, falso alerta/falso positivo)

Fração de pontos em operação normal (longe de qualquer alarme real) que o modelo marcou como anômalos. É o “custo” do detector – quanto maior, mais alertas sem necessidade o operador teria que checar.

composite_score / balanced_score

Nota única que combina **hit_rate** e **normal_alert_rate** num só número, usada para rankear automaticamente milhares de combinações de modelo/percentil/debounce. Penaliza falso alerta ao quadrado, mas — como qualquer score agregado — pode enganar: um candidato pode vencer no score e ainda assim ser pior na prática (ver Seção 9.5).

seed-sweep (variância de semente)

Reajuste do mesmo modelo vencedor várias vezes, mudando só a semente aleatória (*random seed*), para checar se o resultado é estável ou se foi sorte de uma inicialização específica.

Modelos

dense Autoencoder denso (rede neural): aprende a reconstruir o vetor de entrada; erro de reconstrução alto = mais anômalo.

ocsvm (One-Class SVM)

Aprende a fronteira da região “normal” no espaço de features; a distância até essa fronteira é o score de anomalia.

iforest (Isolation Forest)

Ensemble de árvores de decisão que isola pontos aleatoriamente; pontos anômalos são isolados com menos cortes (mais fáceis de separar do resto) que pontos normais.

Engenharia de features

roll_med / roll_std / trend_w / delta_1

Média móvel, desvio padrão móvel, e a diferença entre o valor atual e o valor de *w* passos atrás (tendência) – todos calculados numa janela de tempo específica.

kurtosis / skewness / crest factor

Estatísticas de *forma* da distribuição do sinal numa janela: kurtosis mede o quão “pontaguda”/pesada é a cauda (picos esporádicos); skewness mede assimetria; crest factor é o valor de pico dividido pelo RMS. Ver esquema da Seção 10.

CUSUM / z-score local (localz)

Mecanismos que comparam o comportamento *recente* do sinal com sua própria linha de base histórica (24h), em vez de um limiar fixo global – pegam um drift lento que nunca chega a cruzar um threshold global. Ver esquema da Seção 11.

Estado operacional e portões (gates)

RUNNING_A / operational_state

Sensor de referência que indica se a turbina está operando, classificado em "on" (operando normalmente), "off_curto"/"off_longo" (parada) e "transiente" (mudança de estado em andamento). Pontos fora de "on" são excluídos tanto do treino quanto da avaliação.

Portão de rampa / portão de volatilidade (load gate / volatility gate)

Mecanismos de pós-processamento que suprimem alarmes durante manobras operacionais legítimas (mudança de carga), sem alterar o modelo nem o threshold – ver Parte III.

Condições de alarme

HI / HIHI Alarme de valor alto / muito alto (ex.: temperatura acima do normal).

UNDER Alarme de valor abaixo do esperado – no EXP7, descobrimos que essa condição específica é, na prática, sempre falha de sensor/comunicação, não queda física real (Seção 12).

Parte I

Fundamentos: a pipeline e o ponto de partida (EXP6)

1 Objetivo do EXP6

A ideia central de toda a série de experimentos deste relatório é usar os sinais de **vibração dos 5 mancais** da turbina como preditores antecipados de falha dos sensores de temperatura TC382_03_A e T5_AVG_A. A hipótese física: uma degradação mecânica no mancal (vibração anormal) pode preceder, em horas, a manifestação térmica que hoje dispara o alarme – a vibração funcionaria como sinal de alerta precoce, antes da temperatura em si sair da faixa normal.

O EXP6 treina um único modelo multivariado que recebe TC382_03_A + T5_AVG_A + os 10 canais de vibração como entrada, mas é avaliado *apenas* pela sua capacidade de antecipar os alarmes reais desses dois sensores de temperatura – a vibração entra só como informação de contexto/apoio (campo `eval_sensors`, criado neste experimento).

2 Dados e janela temporal

Dataset ClearML Cabiunas full 2024-2026 30s (TesteMLCab, ID a97ba56ba14840fbb1125c2a82f883c9), usado em *todos* os experimentos deste relatório (EXP6 até EXP10c):

- `sensores_full_2024_2026_30s.csv`: 2024-01-01 a 2026-04-30, resolução de 30s (~2,45 milhões de linhas), 39 colunas de sensor.
- `alarmes_selecionados_turbina_a.csv`: 2022-01-04 a 2026-04-18, 47 tags, 3.757 alarmes onset, sem duplicação de linha.
- **Vibração**: 10 canais TV_35[1-5][X|Y]_A (5 mancais × radial X/Y) – disponíveis pela primeira vez nesta fonte de dados.

Janela usada em todos os experimentos: treino/fit de 2024-07-01 a 2025-06-30 (12 meses); avaliação out-of-sample (OOS) de 2025-07-01 a 2026-04-30 (~10 meses, 40 alarmes reais de TC382_03_A/T5_AVG_A) – dados e alarmes que o modelo nunca viu no ajuste.




Figura 1: Série bruta de TC382_03_A, jul/2024 a abr/2026. Sombra cinza = parada prolongada; linha preta vertical = início do período OOS; linhas verdes tracejadas = alarmes reais no período OOS; pontos vermelhos = anomalias detectadas pelo modelo final do EXP6.

3 Como a pipeline foi montada

A pipeline AutoML (`src/cnn1d_ae/automl_pipeline.py`) opera **ponto a ponto**: cada instante de tempo é uma amostra de treino independente, sem janelamento temporal – diferente do autoencoder CNN-1D sequencial usado na linha de produção paralela do projeto. Passo a passo, da entrada bruta até a decisão final:

1. **Recorte temporal** (`DATA_START_DATE`): a série completa é cortada para o intervalo de interesse antes de qualquer outro processamento.
2. **Normalização do arquivo de alarmes**: mantém só as linhas de *onset* (`Status` iniciando em `ACT`) – o arquivo traz pares `onset/clear` para o mesmo evento, e só o `onset` é algo que faz sentido tentar prever com antecedência.
3. **Construção do dataframe do grupo multivariado**: as colunas dos sensores do grupo são unidas por timestamp, com interpolação de gaps curtos e `ffill/bfill` nas bordas.
4. **Features derivadas** (`ENABLE_DERIVED_FEATURES`): para cada sensor, média móvel, desvio móvel e diferença ponto a ponto numa janela de tempo – a granularidade dessa etapa é exatamente o que os itens 1 e 2 do EXP7 (Parte II) vão expandir.
5. **Estado operacional** (`OPERATIONAL_REF_SENSOR`): deriva quando a turbina está `on/off_longo/off_curto/transiente` a partir de um sensor de referência de operação (`RUNNING_A` neste dataset).
6. **Exclusão do conjunto de treino**: um ponto é excluído do treino se estiver perto de um alarme real ($\pm \text{EXCLUDE_MINUTES_AROUND_ALARM}$), num gap longo de dado, ou **fora do estado "on"** – ver o achado da Seção 4, que corrige exatamente este ponto.
7. **Clip de outliers e split temporal OOS**: como já descrito – só dados anteriores ao corte OOS entram no ajuste do modelo.
8. **Normalização z-score**: estatísticas calculadas somente sobre o conjunto de treino, aplicadas a toda a série.
9. **Ajuste do modelo**: três famílias testadas em paralelo – **dense** (autoencoder Keras), **ocsvm** (One-Class SVM, kernel RBF) e **iforest** (Isolation Forest).
10. **Grid de threshold/debounce**: para cada modelo já treinado, varre-se um conjunto de percentis de threshold (sobre o erro de reconstrução/score de anomalia do treino) $\times$ valores de debounce (pontos consecutivos exigidos para contar como detecção).
11. **Avaliação por trial**: `hit_rate` (fração de alarmes OOS com pelo menos um ponto anômalo dentro de $\pm 24\text{h}$), `normal_alert_rate` (fração de pontos normais marcados como anômalos) e o `composite_score`:

$$\text{balanced_score} = \text{hit_rate} - \text{fp_penalty} \cdot \text{normal_alert_rate}^2$$

12. **eval_sensors**: sensores que entram só como *feature* (a vibração, aqui) não contam alarme próprio no `hit_rate` – a avaliação fica restrita a `["TC382_03_A", "T5_AVG_A"]`.

4 Achado pré-resultado: a máscara operacional não cobria o treino

Antes de aceitar qualquer resultado, verificamos se as máscaras cobriam de fato o *treino*, não só a *avaliação*. Encontramos um problema real: o estado operacional só zerava anomalias na hora de **pontuar** – nunca excluía os períodos desligados do próprio **conjunto de treino**. O modelo

era ajustado numa mistura de dois regimes muito diferentes (turbina operando, $\sim 500\text{--}800^\circ\text{C}$, vs. parada, $\sim 25\text{--}40^\circ\text{C}$).

Antes da correção: `hit_rate=97,5%` mas `normal_alert_rate=10,3%` – o modelo aprendia sobretudo a detectar a transição liga/desliga, não anomalias sutis em operação. A correção resolveu de graça outro problema: 99,9% do platô de sensor “morto” em $-40,51^\circ\text{C}$ de `TC382_03_A` coincide com `RUNNING_A==0` – excluir “não-on” do treino remove esse artefato sem mexer no threshold de outlier separadamente.

Correção: o cálculo do estado operacional foi movido para *antes* da construção do conjunto de treino; `state != "on"` passou a ser mais um critério de exclusão do treino, junto com proximidade de alarme e gaps longos. Todos os resultados a partir daqui já refletem essa correção – e ela é o *precursor direto* da máscara operacional que será estendida no EXP10 (Parte III).

5 Configuração da rodada

Parâmetro	Valor
Grupo	TC382_T5_vibracao_mancais
Sensores (features)	TC382_03_A, T5_AVG_A + 10 canais TV_
<code>eval_sensors</code>	TC382_03_A, T5_AVG_A
Janela de fit / avaliação OOS	2024-07 a 2025-06 / 2025-07 a 2026-04
<code>OPERATIONAL_REF_SENSOR</code>	<code>RUNNING_A</code> (<code>OFF_ABS_THRESHOLD=0.5</code>)
<code>ENABLE_DERIVED_FEATURES</code>	<code>true</code> (janela única, 6 min)
Grid	7 percentis $\times$ 6 debounces $\times$ 3 modelos = 126 trials

Tabela 1: Configuração completa (`test_grupo_exp6_vibracao.json`).

6 Quem venceu a rodada

Modelo	Percentil / debounce	<code>hit_rate</code>	<code>normal_alert_rate</code>	anomalias/dia	<code>composite_score</code>
ocsvm (vencedor oficial)	97,0 / 1	97,5% (39/40)	26,15%	730,6	0,946
dense	99,5 / 3	82,5% (33/40)	12,92%	376,4	0,931
iforest	99,9 / 6	75,0% (30/40)	0,06%	3,2	0,917

Tabela 2: Melhor trial de cada modelo, dos 126 do grid completo.

O vencedor pelo `composite_score` (ocsvm, 0,946) tem falso alerta **436 vezes maior** que o iforest (0,917) – sinal de que a penalidade de FP não impede essa escolha quando o `hit_rate` sobe muito. Confirmado visualmente: o `ocsvm` marca quase toda a faixa operacional como anômala, sem discriminar nada.




Figura 2: Trade-off detecção × falso alerta para os 126 trials. O **iforest** escolhido (estrela) está no canto ideal (alta detecção, baixíssimo FP); o **ocsvm** vencedor pelo score (X) tem FP muito mais alto para ganho marginal de detecção.




Figura 3: Esquerda: falso alerta do melhor trial de cada modelo. Direita: distribuição de FP considerando todos os 42 trials de cada modelo – o **iforest** tem mais configurações de baixo FP disponíveis, não só o ponto ótimo isolado.

Candidato prático escolhido: **iforest (p99.9/debounce=6)** – reproduzido de forma independente numa segunda run isolada, com métricas e hiperparâmetros idênticos, confirmando reprodutibilidade.

7 Resultado obtido

Categoria	Qtd.	% dos 40 alarmes
Preditivo (antecedência real)	26	65,0%
Reativo (só depois/simultâneo)	4	10,0%
Sem detecção	10	25,0%

Tabela 3: $\text{hit_rate}=75,0\%$ (30/40); $\text{normal_alert_rate}=0,06\%$; mediana de antecedência (dos 26 preditivos) = 12,4h.

Alarmes previstos com antecedência real (n=26) -- TC382_03_A, iforest p99.9/debounce=6




Figura 4: Os 26 casos com antecedência real, da maior para a menor antecedência. Vários mostram um padrão em “escada” – quedas ou subidas sucessivas de temperatura, já sinalizadas como anomalia horas antes do alarme.

Alarmes detectados só depois (reacao, n=4)




Figura 5: Os 4 casos em que a detecção só veio depois do alarme.

Alarmes sem detecção dentro de $\pm 24h$ (n=10)




Figura 6: Os 10 alarmes sem nenhuma detecção em $\pm 24h$ – a maioria não mostra excursão visível na própria série de temperatura plotada. Estes 10 casos, junto com os 4 reativos acima, são exatamente o alvo do EXP7 (Parte II).

Dois pontos fracos claros ao final do EXP6: 4 alarmes detectados só depois do fato (reação, não previsão) e 10 sem detecção alguma dentro de $\pm 24h$. É exatamente daqui que o EXP7 parte.

Parte II

EXP7: fechando os pontos fracos do EXP6

8 Visão geral e plano de ataque

Antes de qualquer mudança de código, investigamos o estado da arte em manutenção preditiva especificamente para os dois problemas do EXP6 – falta de antecedência (reativo) e ausência total de sinal (sem detecção). Cinco direções foram priorizadas, da mais barata/baixo-risco à mais custosa:

1. **Features multi-escala** – as features do EXP6 só olham uma janela de 6 min, curta demais para um precursor que se desenvolve ao longo de horas.
2. **Features de textura do sinal** – kurtosis, skewness, crest factor capturam mudança de *forma* do sinal de vibração, não só nível ou tendência.
3. **Detecção de mudança de regime** (CUSUM/z-score de linha de base local) – complementar ao threshold por percentil global, que pode ser cego a um drift lento que nunca fica “extremo”.
4. **Reformulação supervisionada** – treinar direto “vai alarmar nas próximas N horas?” usando os alarmes como rótulo.
5. **RUL/sobrevivência** – aspiracional, requer mais eventos rotulados.

Este relatório cobre os itens 1–3 (a linha de raciocínio contínua de engenharia de features sobre o mesmo modelo não supervisionado). Os itens 4–5 foram tentados à parte (classificador supervisionado: resultado negativo, dominado pelo AutoML em todo o grid testado; sobrevivência exploratória: achado de hazard decrescente/rajadas de alarme, mas não é modelo operacional) e não alteraram o candidato de referência – documentados em `docs/analise_automl_exp8.md`.

Mesma base de dados, mesmo grupo de sensores, mesma janela temporal do EXP6 em todos os itens a seguir – muda exclusivamente a engenharia de features.

9 Item 1 — Features multi-escala

9.1 Onde paramos

Ao final do EXP6 (Seção 7): 26 preditivos, 4 reativos, **10 sem detecção** (Figura 6). Hipótese de causa raiz: a única janela de 6 min é cega a um precursor que se desenvolve em escala de horas – a tendência lenta nunca gera um `delta_1` grande o suficiente, e o valor em si pode nunca cruzar o percentil global mesmo já tendo saído da linha de base recente daquele trecho.

9.2 O que muda: quatro janelas em vez de uma

Antes (EXP6): uma única janela de 12 amostras (6 min). Agora (`DERIVED_ROLLING_WINDOWS=[12, 120, 480, 2880]`): quatro janelas simultâneas – 6 min, 1h, 4h e 24h. Para cada sensor e cada janela: média móvel, desvio móvel e `trend_w` (valor atual menos o valor de `w` passos atrás). 48 → 168 features de entrada.




Figura 7: Esquema do mecanismo: a mesma amostra no tempo (linha vertical tracejada = alarme) passa a ter contexto de 4 escalas diferentes ao mesmo tempo. A janela de 6 min captura só a inclinação final abrupta; as janelas de 4h/24h enxergam o platô e o início da subida lenta que a janela curta não via.

9.3 Configuração de treinamento

Idêntica ao EXP6 (Seção 2), exceto `DERIVED_ROLLING_WINDOWS=[12, 120, 480, 2880]` no lugar da janela única – sem mudança em máscaras, split OOS, grid de threshold/debounce ou `eval_sensors`.

9.4 Resultado: mais cobertura, mais falso alerta

Métrica	EXP6 (janela única)	Item 1 (multi-escala)
Melhor modelo	iforest p99,9/db6	ocsvm p99,5/db6
hit_rate	75,0% (30/40)	87,5% (35/40)
Preditivo	26	28
Reativo	4	7
Sem detecção	10	5
FP (normal_alert_rate)	0,06%	2,21%
Mediana de antecedência	12,4h	15,0h

Tabela 4: Ganho: sem detecção cai pela metade (10→5), antecedência mediana melhora. Perda: falso alerta $\sim 37\times$ maior – uma troca real, não um upgrade de graça.




Figura 8: Evolução do número de alarmes em cada categoria – esta figura acompanha as três etapas do EXP7 (item 1, item 1+2, e o item 1+2+3 da Seção 11) e será referenciada de novo adiante. Sem detecção cai de 10 para 3 ao longo da série; preditivo sobe de 26 para 29.




Figura 9: hit_rate, falso alerta e mediana de antecedência por etapa – gráfico de referência para acompanhar a diminuição/aumento de falso alerta ao longo de toda a série EXP6→EXP7. Note que o FP do EXP6 (0,06%) é proporcionalmente muito menor que os do EXP7 – a troca de cobertura por falso alerta é real e está sendo mostrada, não escondida.

9.5 Desvio: o candidato de baixo FP que parecia bom mas não era

No mesmo grid multi-escala, o melhor trial de `iforest` com FP mínimo e $\text{hit_rate} \geq 70\%$ (p99,0/debounce=12: 70% hit / 0,38% FP) parecia, pelos números agregados, uma alternativa mais conservadora. Isolamos esse trial numa run dedicada para abrir o detalhamento:

Candidato	hit_rate / FP	Preditivo	Reativo
ocsvm multi-escala (escolhido)	87,5% / 2,21%	28	7
iforest “baixo FP” (mesma etapa)	70,0% / 0,38%	13	15

Tabela 5: Apesar do FP baixo, esse candidato é o **pior em antecedência real** – só 13 das 28 detecções são preditivas, o resto é reação tardia (debounce=12, o dobro do padrão, atrasa o ponto que “conta” como detecção).

Lição: `hit_rate/normal_alert_rate` agregados enganam – é preciso sempre abrir o detalhamento preditivo/reativo/sem detecção antes de escolher um candidato pelo score agregado. Esta é a mesma disciplina que será aplicada de novo no EXP10 (fragmentação em episódios em vez de confiar em taxas agregadas).

Candidato de referência após o item 1: `ocsvm` multi-escala (p99,5/db6).

10 Item 2 — Textura do sinal (kurtosis, skewness, crest factor)

10.1 Onde paramos

Ao final do item 1: 28 preditivos, 7 reativos, 5 sem detecção, FP de 2,21%. O ganho de cobertura veio a um custo real de falso alerta – o item 2 testa se dá para melhorar cobertura *sem* pagar mais esse preço.

10.2 O que muda: forma do sinal, não só nível

Para as janelas $\geq 1h$ (a de 6 min não tem amostra suficiente para esses estimadores serem estáveis), três features adicionais por sensor: kurtosis móvel, skewness móvel e crest factor móvel (pico $\div$ RMS dentro da janela). 168 $\rightarrow$ 276 features de entrada.




Figura 10: Esquema do mecanismo: dois sinais com a mesma média e desvio padrão aproximados podem ter kurtosis/skewness/crest factor muito diferentes. O sinal “com textura” (direita) tem picos esporádicos – kurtosis 7,7 vs 0,25 do sinal normal – que média/desvio sozinhos não capturam, mas que são o padrão de degradação incipiente de mancal em condition monitoring.

10.3 Configuração de treinamento

Idêntica ao item 1, com a adição das 3 features de textura por sensor nas janelas de 1h/4h/24h – sem mudança em máscaras, split OOS, grid ou `eval_sensors`.

10.4 Resultado: ganho limpo em todos os eixos ao mesmo tempo

Métrica	Item 1 (multi-escala)	Item 1+2 (+ textura)
Melhor modelo	ocsvm p99,5/db6	ocsvm p99,9/db1
hit_rate	87,5% (35/40)	92,5% (37/40)
Preditivo	28	29
Reativo	7	8
Sem detecção	5	3
FP (normal_alert_rate)	2,21%	1,94%
Mediana de antecedência	15,0h	14,7h

Tabela 6: Ao contrário do item 1 (trocou FP por cobertura), o item 2 melhora hit_rate, FP e a divisão preditivo/sem-deteção ao mesmo tempo – indício de que kurtosis/skewness/crest factor capturam sinal genuíno de vibração ficando “mais irregular” antes do evento, não só reclassificam detecções reativas ao acaso.

Já mostrado na Figura 8: sem detecção cai de 10 (EXP6) para 5 (item 1) para 3 (item 1+2) – a curva de melhoria contínua ao longo dos testes, sem retrocesso em nenhuma etapa.

10.5 Gráficos do que acertamos e do que não acertamos

Candidato final desta etapa: ocsvm (percentil 99,9, debounce=1) sobre o grupo com 276 features de entrada. As Figuras 11–13 mostram **todos os 40 alarmes** da avaliação, agrupados por categoria – o sensor-alvo plotado em cada miniatura é o mesmo que gerou aquele alarme específico.




Figura 11: Os 29 casos com antecedência real, da maior (23,3h) para a menor antecedência (poucos segundos). Mediana de 14,7h.




Figura 12: Os 8 casos em que a detecção só veio depois (ou praticamente junto) do alarme.




Figura 13: Os 3 alarmes restantes sem detecção – caíram de 10 (EXP6) para 3. Investigados em detalhe na Seção 12.

Candidato de referência após o item 2 (inalterado até o EXP10): `ocsvm (p99,9/debounce=1)` sobre `TC382_T5_vibracao_mancais` com features multi-escala + textura.

11 Item 3 — Detecção de mudança de regime (CUSUM + z-score local)

11.1 Onde paramos

Ao final do item 2: 29 preditivos, 8 reativos, **3 sem detecção**. Restam 3 casos sem nenhum sinal em $\pm 24h$ – o item 3 foi escolhido especificamente para atacar esses residuais: em vez de exigir que o valor cruze um limiar histórico fixo, detectar quando o trecho já é estatisticamente diferente da sua *linha de base local* recente.

11.2 O que muda: linha de base local em vez de limiar global

Duas features causais novas por sensor: `localz_{1h}_{24h}` (z-score da média de curto prazo em relação à linha de base de 24h) e `cusum_pos/cusum_neg` (CUSUM causal de Page, acumula evidência de desvio sustentado da média móvel de 24h, com folga de 0,5 desvio-padrão local). 276 → 312 features de entrada.




Figura 14: Esquema do mecanismo: um drift lento (painel superior) nunca cruza o limiar global do percentil (linha vermelha pontilhada) porque a linha de base (tracejada cinza) sobe junto – mas tanto o z-score local (painel do meio) quanto o CUSUM (painel inferior) acumulam evidência do desvio sustentado, mesmo sem nenhum valor “extremo” isolado.

11.3 Configuração de treinamento

Idêntica ao item 1+2, com a adição das 2 features de mudança de regime por sensor – sem mudança em máscaras, split OOS, grid ou `eval_sensors`.

11.4 Resultado: nenhum ganho adicional

Métrica	Item 1+2 (textura)	Item 1+2+3 (+ regime)
hit_rate	92,5%	92,5%
FP	1,94%	1,93%
Preditivo	29	29
Reativo	8	8
Sem detecção	3	3 (os mesmos 3 casos)
Mediana de antecedência	14,7h	14,7h (idêntico)

Tabela 7: Os números batem exatamente – o `threshold` do `ocsvm` vencedor mudou de 14,88 para 16,07 (as novas features entraram no ajuste do modelo), mas isso não mudou a classificação final nos 3 casos residuais.

Item 3 (mudança de regime): resultado nulo -- threshold do ocsvm mudou (14,88 → 16,07) mas a classificação final não, nos mesmos 3 casos residuais




Figura 15: Resultado nulo do item 3: breakdown preditivo/reativo/sem detecção idêntico, e variação de FP/hit_rate desprezível.

Interpretação: os 3 alarmes residuais provavelmente não têm nenhum precursor detectável nos sensores disponíveis (temperatura + vibração) – nem em nível, nem em tendência, nem em mudança de regime local. É possível que tenham causa externa ao que monitoramos (ação de operador, trip por outro sistema) que não deixa rastro nesses canais especificamente. **Não vale insistir nessa direção com os dados atuais** – confirmado com mais detalhe na investigação caso a caso da Seção 12.4.

12 Aprofundamento: qualidade dos alarmes

Depois de fechar os itens 1–3, investigamos os 40 alarmes da avaliação OOS um a um: de qual sensor, em qual condição, e – o ponto central desta seção – **quais são eventos físicos reais e quais são artefato de falha de sensor/comunicação**.

12.1 Os 40 alarmes não são homogêneos

Sensor	Alarmes	%	Condição	Qtd.
TC382_03_A	35	87,5%	HI	18
T5_AVG_A	5	12,5%	HIHI	14
			UNDER	8

Condição	Preditivo	Reativo	Sem detecção	Taxa preditiva
HI	16	2	0	88,9%
HIHI	13	1	0	92,9%
UNDER	0	5	3	0%

Tabela 8: Antecedência quase perfeita para HI/HIHI; **zero** antecedência para UNDER.




Figura 16: Detecção por condição de alarme.

12.2 UNDER é falha de sensor, não evento físico

Os 8 alarmes UNDER disparam com valor entre -18 e -22 – fisicamente implausível (operação normal $\sim 600\text{--}800$, mesmo em idle/frio $\sim 25\text{--}40$). Verificação direta na série bruta, para cada um dos 5 instantes distintos:

Alarme	Evidência
08/08/2025 15:31	9 de 12 pontos NaN em TC382_03_A; RUNNING_A=1 o tempo todo – gap de dado.
17/01/2026 00:59	RUNNING_A=Comm Fail/Out of Serv – falha de comunicação explícita.
29/11/2025 07:52	RUNNING_A=0 – equipamento já desligado.
24/07/2025 16:14	Transição RUNNING_A 1→0 – parada em andamento.
14/01/2026 16:18	Mistura de Out of Serv/transição.

Tabela 9: Nenhum dos 5 casos é queda física real de temperatura em operação normal.




Figura 17: Dois dos cinco casos: TC382_03_A numa faixa perfeitamente normal exatamente no instante em que o sistema de alarme registrou $-21/-20$ – a leitura que disparou o alarme nunca chegou ao pipeline como valor de processo real.

Não existe precursor de sensor para prever a própria falha de comunicação do sensor. Excluir UNDER não é viés de seleção – é remover alvos estruturalmente impossíveis de prever com os dados de temperatura/vibração disponíveis.

12.3 Métricas corrigidas: o que de fato conta como alarme real

Métrica	Com UNDER (40)	Sem UNDER (32, real)
hit_rate	92,5%	100%
Antecedência real (preditivo)	72,5% (29/40)	90,6% (29/32)
Reativo	8	3
Sem detecção	3	0

Tabela 10: Sobre os 32 alarmes genuínos, o candidato detecta 100% deles com 90,6% de antecedência real – os 3 “sem detecção” eram exatamente os 3 UNDER mais problemáticos.

Impacto de excluir alarmes UNDER (falha de comunicação/sensor)




Figura 18: Antes e depois de excluir UNDER – zero casos sem detecção à direita.

12.4 Os 3 alarmes reativos remanescentes

Sobre os 32 alarmes genuínos, 3 continuam sendo detectados só depois do alarme – correspondem a apenas **2 eventos físicos distintos**.

Data/hora	Condição	Atraso até 1ª detecção	Evento
20/10/2025 16:18–16:20	HI/HHI	~4h	trip/religamento
24/02/2026 11:01	HI	0min (simultâneo)	início tipo degrau

Evento 1 (trip/religamento): o estado operacional sai de "on" **antes** do próprio alarme e oscila entre "transiente"/"off_curto" por quase 5h – a pipeline zera `is_anom_point` por design nesses estados. A 1ª detecção só aparece quando o estado volta a "on" estável – não é coincidência, é a mecânica exata da máscara operacional.




Figura 19: TC382_03_A ao redor do trip de 20/10/2025. Áreas sombreadas = estado $\neq$ "on"; a detecção (ponto verde) só ocorre quando o estado volta a "on".

Evento 2 (início tipo degrau): `operational_state="on"` o tempo todo. TC382_03_A fica estável por $\geq 6h$ antes do alarme, sem sinal gradual, e salta abruptamente – sem precursor visível em nenhuma das 4 escalas de tempo capturadas.




Figura 20: Patamar estável por 6h, depois salto abrupto coincidente com o próprio alarme – a 1ª detecção ocorre no mesmo intervalo do alarme, o mais rápido possível dado o grid de debounce.

Síntese: nenhum dos 3 casos reativos indica falha de engenharia de features a corrigir – um é limite estrutural de escopo (transiente de partida/parada excluído por design), o outro é evento genuinamente sem antecedência física possível.

Parte III

EXP10: do candidato final de temperatura ao falso alerta residual

13 Ponto de partida

Candidato de referência ao final do EXP7: `ocsvm` (p99,9/debounce=1), multiescala + textura – **92,5% hit_rate**, **1,94% de falso alerta** (base de 40 alarmes, consistente com a Parte II). O EXP10 **não mexe no modelo**: investiga a *estrutura* do falso alerta residual em vez de tratá-lo como ruído agregado, e ataca 3 causas distintas, uma de cada vez – sem perder nenhum dos 37 alarmes já detectados em nenhuma etapa.

Método: fragmentação da série `is_anom_point` em episódios contínuos ($\text{gap} \leq 5$ min), cruzados com dados brutos e com o catálogo completo de 47 tags de alarme. Achado estrutural: 72,5% dos 12.782 pontos de falso alerta (OOS) se concentram em apenas 10 dos 295 episódios.

14 Achado 1 (EXP10): desligamento real que a máscara não via

Os 5 maiores episódios (19–24/08/2025) coincidem com TC382_03_A caindo de $\sim 478^\circ\text{C}$ para $\sim 28\text{--}32^\circ\text{C}$ por 3,5 dias, enquanto `RUNNING_A` permanece $\sim 0,96\text{--}1,0$ o tempo todo – a máscara nunca excluía esse período. Confirmado como desligamento real via alarmes de pressão/partida a gás do catálogo completo, disparando exatamente nas bordas do período.




Figura 21: O episódio de 19–24/08/2025: temperatura caindo para a faixa de desligamento enquanto `RUNNING_A` permanece perto de 1.

Correção: `build_operational_state` (`src/cnn1d_ae/scoring.py`) ganhou `secondary_series/secondary_off_abs_threshold` – o próprio sensor-alvo do grupo caindo abaixo de um piso físico (`OFF_TARGET_ABS_THRESHOLD`, 150°C) também conta como “off”, unido por OR ao critério de `OPERATIONAL_REF_SENSOR`, antes da classificação `off_curto/off_longo/transiente` já existente.

Como a máscara operacional funciona, ponto a ponto (19-24/08/2025)




Figura 22: Esquema do mecanismo: quando o sensor-alvo cai abaixo do piso físico (linha tracejada), o novo critério classifica o período como “off” mesmo que o sensor de referência primário não tenha capturado a mudança – suprimindo o falso alerta desse trecho.

Resultado (EXP10): hit_rate idêntico (92,5%, 37/40); FP 1,94%→0,67%. Seed-sweep: desvio-padrão de 0,019pp.

Caminho testado e descartado: debounce

Simulação offline da grade de debounce (1 a 60) mostrou ganho de FP pequeno até debounce=10 (1,94%→1,66%, já custando 3 preditivos) e perda de alarmes reais inteiros além disso. Causa: a duração mediana dos episódios de FP residual (6 pontos/2,5min) se sobrepõe à dos episódios mais curtos que ainda precedem um alarme real (25º percentil = 6min). Debounce não separa os dois.




Figura 23: Grade de debounce: o ganho de FP não compensa a perda de predictivos além de $\text{debounce} \approx 10$.

15 Achado 2 (EXP10b): rampas de carga reais

Dos 4.441 pontos de FP residual (287 episódios), a variabilidade local de TC382_03_A é $5\text{--}9\times$ maior que em pontos normais (nível idêntico – não é viés de faixa). Investigação individual dos 10 maiores episódios: 8 de 10 mostram TC382_03_A/T5_AVG_A variando dezenas de graus em $\sim 1\text{h}$, com desvio-padrão de vibração $3\text{--}6\times$ mais alto – manobra de carga real, sem alarme, sem falha.




Figura 24: Exemplo de rampa de carga legítima: variação de dezenas de graus em $\sim 1h$, sem alarme correspondente.

Correção: `ENABLE_LOAD_GATE/apply_load_gate` já existia para o CNN1D-AE (pipeline sequencial, produção) mas nunca fora portado ao AutoML – portado aqui. Parâmetros default do CNN1D-AE (`halflife=120min/janela=360min`) custavam até 6 casos preditivos – uma rampa de falha real e uma rampa de carga legítima têm a mesma assinatura de taxa de variação numa janela longa. Janela curta (`halflife=15min/ janela=30min`) + `ramp_max=100 $^{\circ}C/h$` preservam 29/29 preditivos.

Como o portão de rampa funciona, ponto a ponto (29/01/2026)




Figura 25: Esquema: quando a taxa de variação suavizada do proxy de carga ultrapassa o limiar, `is_anom_point` é suprimido durante a manobra – janela curta o bastante para não confundir com uma rampa de falha real.




Figura 26: Sensibilidade ao parâmetro `ramp_max`: ponto escolhido preserva todos os preditivos.

Resultado (EXP10b): hit_rate idêntico (92,5%, 37/40); FP 0,67%→0,48%. Seed-sweep: desvio-padrão de 0,016pp.

16 Achado 3 (EXP10c): volatilidade que persiste, não que sobe

O portão de rampa reage bem a variação de *nível*, mas o padrão de vibração do Achado 2 é diferente: o desvio-padrão sobe e **permanece** elevado por 1–2h, não é só um pico na subida.

Tentativa 1 (falhou): alimentar `apply_load_gate` com um índice de volatilidade de vibração no lugar do proxy de temperatura, mantendo o mecanismo de taxa de variação – reduzia o FP de 0,480% para apenas 0,477%: taxa de variação não distingue início de rampa real de início de escalada de falha, mesmo problema do portão original, causa relacionada mas distinta (métrica errada, não janela errada).

Tentativa 2 (funcionou): `compute_volatility_index/ apply_volatility_gate` – desvio-padrão móvel causal (`VOLATILITY_GATE_WINDOW_MINUTES=60min`) de cada um dos 10 canais de vibração, reduzido pela média entre canais, bloqueando quando o **nível** (não a taxa) ultrapassa `VOLATILITY_GATE_THRESHOLD`. Simulação offline encontrou `threshold=0,39` como ponto de custo zero: preserva 29/29 preditivos com FP caindo 27% relativo.

Como o portão de volatilidade funciona, ponto a ponto (31/08/2025)




Figura 27: Esquema: o índice de volatilidade (média entre os 10 canais de vibração) permanece elevado por toda a manobra, não só no início – o portão bloqueia enquanto o nível estiver acima do limiar, não só na subida.




Figura 28: Comparação do índice de volatilidade antes/depois do portão – episódios de falso alerta residual coincidem com volatilidade sustentada acima do limiar.

Resultado (EXP10c): hit_rate idêntico (92,5%, 37/40); FP 0,48%→0,35%. Seed-sweep: desvio-padrão de 0,011pp.

17 Resultado consolidado: o sensor-alvo, antes e depois

Etapa	hit_rate	FP
EXP7 item1+2 (base)	92,5% (37/40)	1,94%
EXP10 (+ máscara operacional)	92,5% (37/40)	0,67%
EXP10b (+ portão de rampa)	92,5% (37/40)	0,48%
EXP10c (+ portão de volatilidade)	92,5% (37/40)	0,35%

Tabela 11: Redução total de falso alerta: 1,94%→0,35% (**82% relativo**), com **zero** custo de detecção em qualquer etapa.

A Figura 29 mostra o **sensor-alvo** diretamente: um trecho da série completa onde havia falso alerta antes das 3 correções, e a mesma janela depois – os pontos de FP desaparecem sem que nenhum ponto de detecção real seja afetado.




Figura 29: Série completa de TC382_03_A, antes (topo) e depois (embaixo) dos 3 filtros – os episódios de falso alerta concentrados em 2025-08 e outras janelas somem; os alarmes reais (linhas verdes) continuam todos detectados.




Figura 30: Zoom num episódio específico (29/01/2026): 41 de 41 pontos de falso alerta removidos pelos filtros, sem afetar nenhuma detecção real próxima.

Evolução da série de detecção ao longo dos 4 experimentos, período OOS completo (2025-07 a 2026-04)




Figura 31: Evolução do falso alerta ao longo das 4 etapas (base, EXP10, EXP10b, EXP10c) – queda monotônica, sem retrocesso.




Figura 32: Visão consolidada: detecção (constante) e falso alerta (decrecente) lado a lado ao longo de toda a série EXP10.

O que ainda resta (não endereçado nesta parte)

- ~9,7% do FP original coincide com outro alarme real do catálogo completo (pressão/partida a gás) – fora do escopo de avaliação de 2 sensores, não é falso alerta genuíno, mas não foi corrigido.
- Resíduo de falha de sensor pontual (~2,1%) que contamina a feature de tendência de 24h – nenhuma das três correções mira esse mecanismo.

Parte IV

Conclusão: a escada completa

18 A jornada em uma figura




Figura 33: As sete etapas, do EXP6 ao EXP10c, num só gráfico. Painel superior: cobertura de alarmes (preditivo/reativo/sem detecção) – melhora na fase EXP7 e se estabiliza na fase EXP10. Painel inferior: falso alerta sobe na fase de cobertura (engenharia de features aumentando o espaço de busca) e cai na fase de filtragem (mecanismos de supressão pós-modelo) – sem custo de detecção na segunda fase.

19 Contexto geral vs. sensor-alvo

Duas leituras complementares desta jornada:

- **Contexto geral (métricas agregadas):** hit_rate subiu de 75,0% para 92,5% (65,0%→90,6% olhando só alarmes fisicamente genuínos, sem os UNDER); falso alerta teve uma curva em U – subiu de 0,06% para 2,21% na fase de cobertura (EXP7), e caiu de 1,94% para 0,35% na fase de filtragem (EXP10), *sem nunca sacrificar* nenhum dos 37 alarmes já capturados.
- **Sensor-alvo (casos individuais):** os painéis de preditivo/reativo/sem-deteção (Figuras 11 e seguintes) e as séries antes/depois do EXP10 (Figura 29) mostram a mesma história em nível de evento – alarmes específicos que passam de “sem detecção” para “preditivo” conforme a engenharia de features evolui, e episódios de falso alerta específicos que desaparecem da série do sensor-alvo conforme os filtros de pós-processamento entram, sem apagar nenhum ponto vermelho legítimo.

20 Onde isso deixa o detector

Etapas	hit_rate	FP	Antecedência mediana
EXP6 (baseline, janela única)	75,0%	0,06%	12,4h
EXP7 item1 (multi-escala)	87,5%	2,21%	15,0h
EXP7 item1+2 (+ textura)	92,5%	1,94%	14,7h
EXP7 item1+2+3 (+ regime)	92,5%	1,93%	14,7h
EXP10 (+ máscara secundária)	92,5%	0,67%	14,7h
EXP10b (+ portão de rampa)	92,5%	0,48%	14,7h
EXP10c (+ portão de volatilidade)	92,5%	0,35%	14,7h

Tabela 12: A escada completa. Sobre os 32 alarmes fisicamente genuínos (excluindo UNDER, Seção 12), a cobertura real é de 90,6% (29/32) desde o item 1+2 em diante – as etapas seguintes (item 3, EXP10/10b/10c) preservam esse número e atacam exclusivamente o falso alerta.

O que foi tentado depois e não trouxe ganho adicional (fora do escopo temporal deste relatório, ver docs/analise_automl_exp10.md seção EXP12): re-otimizar o par percentil/debounce por cima dos 3 filtros do EXP10c não encontrou margem real – o piso de FP atual está nos dois mecanismos ainda não endereçados (alarme cross-sensor fora do escopo de avaliação, resíduo de sensor pontual), não no threshold do modelo.