

# Predição de Trip de Óleo Lubrificante na Turbina A

Metodologia, modelo vencedor (EXP16) e por que 2 dos 3 casos conhecidos não têm sinal antecipado disponível

Pipeline `cnn1d_ae` (AutoML) — projeto **TesteMLCab** (Cabiunas/Petrobras)

Agosto de 2026

## Resumo

Este relatório documenta o EXP16: uma nova frente de detecção de anomalias, independente da linha de trabalho da temperatura T5, focada em prever o alarme de trip por baixa pressão de óleo lubrificante do compressor (PALL\_6240309, sensor 954005\_624\_PI\_0308). Um grid amplo de AutoML (840 combinações de modelo/threshold/debounce, EXP16a) selecionou o **IsolationForest** como modelo vencedor, operando sobre um grupo multivariado simples (o próprio sensor-alvo mais os 10 canais de vibração da turbina). O candidato final (EXP16b) atinge **hit\_rate de 100% (2/2) no período de teste** com falso alerta de apenas **0,143%** e variância de semente nula. Uma investigação mais cuidadosa da *antecedência real* de cada detecção, no entanto, revelou que apenas **1 dos 3 eventos genuínos conhecidos** do histórico (2024-03-07, 2025-11-04, 2026-02-26) tem de fato um precursor mensurável – o episódio de 2025-11-04, detectado com **~14,3 horas de antecedência**. Os outros dois eventos foram investigados a fundo, inclusive com duas hipóteses concretas de sinal precursor levantadas e testadas (declínio de temperatura do óleo/mancais e elevação da pressão diferencial de vazamento de gás de selagem, PDIT\_0305) – **ambas refutadas** com evidência quantitativa. A conclusão é que, com a instrumentação disponível hoje, a cobertura genuinamente preditiva desse alarme está limitada a ~1 em 3 casos, um limite de informação física e não de modelagem.

## Sumário

|          |                                                                              |          |
|----------|------------------------------------------------------------------------------|----------|
| <b>1</b> | <b>Introdução e contexto</b>                                                 | <b>1</b> |
| 1.1      | Por que este alvo, e não os outros dois trips de óleo . . . . .              | 1        |
| <b>2</b> | <b>Metodologia</b>                                                           | <b>2</b> |
| 2.1      | Dados . . . . .                                                              | 2        |
| 2.2      | Grupo multivariado e correlação . . . . .                                    | 2        |
| 2.3      | Split treino/teste (OOS) . . . . .                                           | 2        |
| <b>3</b> | <b>Modelo vencedor e como foi configurado</b>                                | <b>2</b> |
| 3.1      | EXP16a: grid amplo de AutoML . . . . .                                       | 2        |
| 3.2      | Configuração final do modelo (EXP16b) . . . . .                              | 3        |
| 3.3      | Sanity-check: o resultado é real, não artefato do conjunto pequeno . . . . . | 5        |
| <b>4</b> | <b>Resultados</b>                                                            | <b>5</b> |
| 4.1      | Métricas do candidato final . . . . .                                        | 5        |
| 4.2      | Gráfico do acerto: o caso genuinamente preditivo . . . . .                   | 5        |
| 4.3      | O que não foi previsto, e por quê . . . . .                                  | 6        |
| 4.3.1    | Duas hipóteses de precursor levantadas e refutadas . . . . .                 | 7        |
| <b>5</b> | <b>Discussão</b>                                                             | <b>9</b> |
| 5.1      | Este modelo prediz <i>todas</i> as falhas desse tipo? . . . . .              | 9        |
| 5.2      | Prontidão para produção . . . . .                                            | 9        |
| 5.3      | Limitações e pendências . . . . .                                            | 9        |

## 1 Introdução e contexto

O projeto de detecção de anomalias da Turbina A concentrou seus primeiros experimentos (EXP1–EXP15) no sensor de temperatura T5 (TC382\_03\_A), alcançando um candidato AutoML de referência com 92,5% de cobertura de alarme (EXP10c) e um candidato CNN1D-Autoencoder consolidado com 77,5% (EXP15b). Este relatório abre uma frente nova, **independente**: em vez de temperatura, o alvo é o circuito de óleo lubrificante do compressor, motivado pela pergunta “conseguimos prever também os alarmes de *trip* (desligamento por proteção), não só os de alta temperatura?”

### 1.1 Por que este alvo, e não os outros dois trips de óleo

A planilha de alarmes da Turbina A tem 3 tags com “TRIP” na descrição, todos do circuito de óleo lubrificante:

| Tag do alarme | Descrição                                    | Situação como alvo |
|---------------|----------------------------------------------|--------------------|
| PALL_6240340  | Pressão baixa óleo header (proteção turbina) | descartado         |
| TALL_6240325  | Temperatura baixa tanque óleo                | descartado         |
| PALL_6240309  | Pressão baixa óleo header compressor         | <b>escolhido</b>   |

Cruzando cada um dos 13 eventos históricos desses 3 alarmes com o estado operacional da turbina (RUNNING\_A) no instante exato do disparo, verificou-se que PALL\_6240340 e TALL\_6240325 dispararam em 99–100% dos casos com a turbina **já parada** – ou seja, o sensor já havia colapsado para o valor de desligamento antes do alarme soar. São consequência do desligamento, não uma falha incipiente a prever. Já PALL\_6240309 tem 3 de 7 eventos (dentro do período com dado de sensor disponível, 2024–2026) ocorrendo com a turbina genuinamente em operação – por isso foi o único escolhido como alvo de predição.

## 2 Metodologia

### 2.1 Dados

- **Sensores:** dataset ClearML Cabiunas full 2024–2026 30s (id a97ba56ba14840fbb1125c2a82f883c9), granularidade de 30 segundos, cobrindo 2024-01-01 a 2026-04-30 (~2,45 milhões de pontos).
- **Alarmes:** catálogo alarmes\_selecionados\_turbina\_a.csv, 2022–2026, filtrado para eventos ACT (ativação) do tag PALL\_6240309.
- **Ampliar a janela para antes de 2024?** Investigado e descartado: existe um dataset mais amplo (Cabiunas consolidado 2022–2026) mas o ano de 2023 – que teria os 6 eventos adicionais do alarme – está com **zero linhas de dado de sensor** nesse dataset. 2022 tem ótima cobertura, mas nenhum evento do alarme ocorreu naquele ano. Ampliar a janela não resolveria o gargalo de eventos genuínos de teste.

### 2.2 Grupo multivariado e correlação

Testou-se se sensores adicionais do mesmo circuito de óleo ajudariam a explicar o comportamento do alvo. Por correlação (em estado “on”,  $n \approx 1,65\text{M}$  pontos):

| Sensor                                             | Correlação com PI_0308 |
|----------------------------------------------------|------------------------|
| 954005_624_PI_0340 (outra pressão do header)       | 0,898                  |
| 954005_624_PI_0339 (terceira pressão do óleo lub.) | 0,895                  |
| 954005_624_TI_0325 (temp. tanque óleo)             | 0,531                  |
| 954005_624_TI_0301/0303/0305/0307 (temp. mancais)  | 0,44–0,65              |
| TV_35X_A (10 canais de vibração)                   | 0,12–0,51              |

Dois grupos foram comparados de ponta a ponta: um grupo *controle* (alvo + os 10 canais de vibração) e um grupo *multivariado completo* (+ as pressões/temperaturas do óleo listadas acima). O resultado, detalhado na Seção 3, mostrou que **o grupo completo não supera o grupo simples** – por isso o candidato final usa apenas alvo + vibração.

### 2.3 Split treino/teste (OOS)

Split temporal em 2025-07-01: o modelo só aprende “normal” com dados anteriores a essa data (excluindo também  $\pm 24h$  ao redor de qualquer alarme e períodos fora do estado “on”); a avaliação de *hit\_rate*/falso-alerta só considera o período posterior, nunca visto pelo modelo. Isso deixa exatamente **2 alarmes genuínos** no conjunto de teste (2025-11-04 e 2026-02-26) – um terceiro evento genuíno conhecido (2024-03-07) cai no período de treino e nunca é avaliado formalmente, mas foi investigado à parte na Seção 4.3.

## 3 Modelo vencedor e como foi configurado

### 3.1 EXP16a: grid amplo de AutoML

Espelhando a metodologia já validada para a T5 (EXP5→EXP7), rodou-se primeiro um grid amplo em vez de partir direto para um modelo específico:

| Parâmetro                      | Valores testados                                                                    |
|--------------------------------|-------------------------------------------------------------------------------------|
| Modelos                        | <b>dense</b> (autoencoder), <b>ocsvm</b> , <b>iforest</b>                           |
| Grade <b>ocsvm</b>             | $\nu \in \{0,01, 0,03, 0,05, 0,1\} \times \gamma \in \{\text{scale}, \text{auto}\}$ |
| Percentis de threshold         | 90; 93; 95; 97; 99; 99,5; 99,9                                                      |
| Debounce (pontos consecutivos) | 1; 2; 3; 6; 12; 24                                                                  |
| Grupos de sensores             | controle (alvo+vibração) vs. multivariado completo                                  |
| <b>Total</b>                   | <b>840 trials</b> (20 treinos reais de modelo)                                      |

### EXP16a — comparação dos 3 modelos do grid AutoML (grupo controle)




Figura 1: Comparação dos 3 modelos no grupo controle: apesar de **dense** e **ocsvm** também atingirem `hit_rate` médio de 100% entre todos os 420 trials (contra 92,9% do **iforest**), o **iforest** entrega o menor falso alerta no seu melhor trial – 0,143%, contra 0,285% do **ocsvm** e 0,907% do **dense**, mais de 6× pior.

**Vencedor: IsolationForest**, com percentil 99,5 e debounce de 24 pontos (12 minutos), no grupo *controle* (alvo + vibração) – ver Figura 1. O grupo multivariado completo produziu resultado praticamente idêntico (FP 0,144% vs. 0,143%), confirmando que as pressões/temperaturas extras do óleo não agregam poder discriminante sobre o que a vibração já entrega.

### 3.2 Configuração final do modelo (EXP16b)

| Hiperparâmetro                  | Valor                                                           |
|---------------------------------|-----------------------------------------------------------------|
| Modelo                          | <code>sklearn.ensemble.IsolationForest</code>                   |
| <code>n_estimators</code>       | 200                                                             |
| <code>contamination</code>      | 0,05                                                            |
| Sensores de entrada             | PI_0308 + 10 canais TV_35[1-5][X/Y]_A                           |
| Features derivadas              | médias/desvios móveis em 4 escalas (6min, 1h, 4h, 24h)          |
| Normalização                    | z-score, estatísticas calculadas só no período de treino        |
| Threshold                       | percentil 99,5 do score de anomalia em treino                   |
| Regra de confirmação (debounce) | 24 pontos consecutivos acima do limiar (12 min)                 |
| Máscara operacional             | zera anomalia fora do estado “on” ( <code>RUNNING_A</code> )    |
| Portões de rampa/volatilidade   | <b>nenhum</b> (decisão deliberada, ver abaixo)                  |
| Semente                         | <code>RANDOM_SEED=42</code> ; seed-sweep com 5 sementes (42–46) |

**Por que nenhum portão de pós-processamento?** Os experimentos de T5 usam portões de rampa e de volatilidade para suprimir falsos alertas durante manobras de carga legítimas, já que ali a vibração é só ruído de contexto. Aqui a lógica se inverte: o sanity-check da Seção 3.3 mostrou que é *a vibração* que permite ao **iforest** separar os eventos genuínos do ruído normal – suprimir anomalias durante vibração elevada arriscaria descartar exatamente o sinal que faz o modelo funcionar. Como o falso alerta já está baixo (0,143%, partindo do zero, sem nenhum portão – bem diferente do ponto de partida de 1,94% que motivou os portões na T5), a decisão foi não adicionar essa camada de risco sem benefício comprovado.

## Pipeline EXP16 — do dado bruto ao ponto anômalo avaliado




Figura 2: Esquema completo do pipeline EXP16, do dado bruto ao ponto anômalo avaliado. Os blocos verdes marcam decisões específicas deste experimento (escolha do alvo, grid de exploração, modelo vencedor); os azuis são etapas padrão do framework AutoML já usado nos experimentos de T5.

### 3.3 Sanity-check: o resultado é real, não artefato do conjunto pequeno

Com apenas 2 alarmes no conjunto de teste, um hit\_rate de 100% poderia ser um artefato — qualquer modelo acertaria por acaso. Simulou-se então um detector ingênuo: threshold direto sobre o valor bruto de PI\_0308, sem nenhum modelo, na mesma metodologia de avaliação.

| Abordagem                              | Threshold           | hit_rate    | Falso alerta     |
|----------------------------------------|---------------------|-------------|------------------|
| <b>iforest</b> multivariado (vencedor) | percentil 99,5      | <b>100%</b> | <b>0,143%</b>    |
| Ingênuo (só PI_0308)                   | mesmo corte (p99,5) | 0%          | 1,28%            |
| Ingênuo (só PI_0308)                   | mais frouxo (p90)   | 100%        | 10,3% (72× pior) |

No mesmo corte que o **iforest** usa, um threshold ingênuo erra os 2 alarmes; para acertar os 2, precisa afrouxar até um falso alerta 72× maior. Isso confirma que o **iforest** está usando o contexto conjunto de vibração + alvo para separar os eventos com muito mais precisão do que o valor do sensor sozinho permitiria – o resultado é real.

## 4 Resultados

### 4.1 Métricas do candidato final

| Métrica                                   | Seed 42 (principal) | Média (5 sementes) | Desvio-padrão |
|-------------------------------------------|---------------------|--------------------|---------------|
| <b>hit_rate</b>                           | 100% (2/2)          | <b>100%</b>        | <b>0,0pp</b>  |
| Falso alerta ( <b>normal_alert_rate</b> ) | 0,143%              | 0,138%             | ±0,004pp      |

O seed-sweep (5 sementes, 42–46) confirma **variância de semente nula** – os 2 alarmes são detectados em todas as 5 sementes, com o falso alerta variando só entre 0,133% e 0,143%. É um resultado bem mais estável do que o CNN1D-AE jamais foi para a T5 (que tinha **hit\_rate\_std** de vários pontos percentuais entre sementes).




Figura 3: Série completa de PI\_0308 (2024–2026) com os pontos sinalizados como anômalos pelo modelo final (pontos vermelhos) e os 3 eventos genuínos conhecidos do alarme PALL\_6240309 marcados. Os grandes trechos em torno de  $-0,25$  a  $-1,0$  correspondem a períodos com a turbina desligada (o sensor cai ao piso físico de leitura), excluídos da avaliação pela máscara operacional.

### 4.2 Gráfico do acerto: o caso genuinamente preditivo

A métrica de avaliação padrão (**eval\_alarm\_hit\_rate**) conta como “acerto” qualquer ponto anômalo dentro de  $\pm 24h$  do alarme, **antes ou depois** – o que pode mascarar detecção puramente reativa (útil só para registro, não para alerta antecipado). Verificou-se então, ponto a ponto, a antecedência *real* de cada um dos 2 alarmes do conjunto de teste.




Figura 4: Episódio de 2025-11-04: a turbina entra em operação às ~13h50 do dia anterior; o iforest sinaliza uma janela de anomalia (pontos vermelhos) já entre 16h04 e 17h07 desse mesmo dia – ~14,3 horas antes do trip (linha vermelha), pouco depois da partida. É um episódio (*burst*) concentrado logo após a partida, não uma tendência crescente ao longo de toda a janela; ainda assim, cai inteiramente antes do trip, contando como antecedência real – diferente do padrão reativo descrito abaixo para os casos sem sinal.

**Resultado: apenas 1 dos 2 alarmes do conjunto de teste é genuinamente preditivo.** O episódio de 2025-11-04 tem os 126 pontos anômalos da sua janela *todos antes* do trip (antecedência de 13,3 a 14,3 horas). Já o episódio de 2026-02-26 tem seus 26 pontos anômalos *todos depois* do trip (6,7 a 6,9 horas de atraso) – um padrão puramente reativo que, na prática, coincide com ruído de acomodação da partida seguinte, sem valor de alerta antecipado algum.

### 4.3 O que não foi previsto, e por quê

Checando também o terceiro evento genuíno conhecido (2024-03-07, que cai no período de treino e nunca foi formalmente avaliado), a contagem real de cobertura preditiva é **1 em 3 (~33%)**, não 1 em 2:

| Evento     | Antecedência real | Classificação                    |
|------------|-------------------|----------------------------------|
| 2024-03-07 | — (sem sinal)     | sem precursor                    |
| 2025-11-04 | ~14,3h antes      | <b>preditivo genuíno</b>         |
| 2026-02-26 | –6,7h (depois)    | sem precursor (reativo residual) |

### Casos sem sinal detectável — a pressão não se afasta do normal antes do trip




Figura 5: Os dois eventos sem sinal detectável. Em ambos os casos, PI\_0308 permanece completamente estável dentro da faixa normal até o instante exato (ou muito próximo) do trip – não há degradação gradual visível em nenhum sensor disponível. No evento de 2024-03-07, o alarme dispara às 13h55 mas a queda física real só ocorre ~2h depois (15h56), um detalhe curioso da sequência de proteção que não muda a conclusão: não há aviso prévio detectável em nenhum dos dois casos.

#### 4.3.1 Duas hipóteses de precursor levantadas e refutadas

Motivados a não aceitar “sem sinal” sem investigar, varreu-se ~36 sensores brutos disponíveis (pressões, temperaturas, deltas de pressão) em busca de qualquer sinal diferencial nas 24h antes dos 2 casos sem detecção, comparado contra o caso preditivo (2025-11-04) como controle. Dois candidatos surgiram – **e os dois foram refutados** com evidência quantitativa, não apenas descartados por inspeção visual.



## Duas hipóteses de precursor testadas e refutadas (EXP16c)




Figura 6: As duas hipóteses testadas, mostradas na linha do tempo completa. A Hipótese 1 (declínio de temperatura) ocorre com tanta frequência que é essencialmente ruído operacional. A Hipótese 2 (PDIT\_0305) é rara e por isso mais promissora à primeira vista, mas ao ser incorporada de fato ao modelo (não apenas observada isoladamente), não mudou o resultado.

**Hipótese 1 – declínio de temperatura do óleo/mancais.** Nas  $\sim 20$ h antes do evento de 2024-03-07, as 5 temperaturas do sistema de lubrificação (TI\_0301, TI\_0303, TI\_0305, TI\_0307, TI\_0325) caem de forma coerente entre si ( $\sim 1,5\text{--}2^\circ\text{C}$ ). À primeira vista, parece um resfriamento real do sistema. Uma checagem de **taxa-base** sobre todo o histórico, porém, mostrou que esse padrão de queda simultânea ocorre em **387 episódios distintos, 32,5% de todo o tempo operacional** – e só 0,8% desses episódios são seguidos de um trip. É variação normal (provavelmente ligada a ciclo diário/carga), não um precursor. Confirmou-se ainda que o modelo multivariado já treinado (que já incluía essas 5 temperaturas como feature) não sinalizou absolutamente nada nessa janela específica – **refutada**.

**Hipótese 2 – elevação de PDIT\_0305 (pressão diferencial de vazamento de gás de selagem).** Um segundo candidato pareceu bem mais específico: o valor de PDIT\_0305 cruza 0,3 em apenas **16 episódios em 2,3 anos (0,036% do tempo)**, dos quais **2 precedem diretamente** o evento de 2026-02-26 (um  $\sim 20$ h antes, outro  $\sim 4,5$ h antes) – uma taxa de conversão de 12,5%, ordens de grandeza mais específica que a Hipótese 1. Motivado por esse achado, o EXP16c treinou o modelo real adicionando PDIT\_0305 ao grupo de sensores e comparou o resultado ponto a ponto contra o modelo sem essa feature:

|                                      | Sem PDIT_0305               | Com PDIT_0305               |
|--------------------------------------|-----------------------------|-----------------------------|
| Primeiro ponto anômalo em 2026-02-26 | 22h17 (6,7h <i>depois</i> ) | 22h17 (6,7h <i>depois</i> ) |
| Pontos anômalos na janela            | 26                          | 32                          |

O resultado não mudou – a antecedência continua idêntica (nenhuma, o ponto ainda aparece só depois do trip). O sinal correto na análise de taxa-base não sobreviveu ao score conjunto do **IsolationForest** com os outros 11 sensores, provavelmente diluído pela mesma dinâmica que descartou a Hipótese 1. **Também refutada**, mas de forma mais rigorosa: não só por taxa-base, mas confirmada diretamente no modelo real.

**Conclusão desta investigação.** Duas hipóteses concretas, levantadas a partir de uma varredura sistemática de  $\sim 36$  sensores e testadas com o rigor de (a) checagem de taxa-base contra todo o histórico e (b) confirmação no modelo real treinado, foram refutadas. Isso fecha, por ora, o ciclo de busca por precursores baratos para os 2 casos sem sinal – mesma categoria de achado negativo já documentada para a série de experimentos da T5 (EXP13). Não há evidência de que mais tempo de busca nos sensores já disponíveis destrave esses 2 casos.

## 5 Discussão

### 5.1 Este modelo prediz *todas* as falhas desse tipo?

Não. Mesmo supondo uma engenharia de deploy perfeita (dado em tempo real, retreino contínuo, alerta operacional funcionando), este modelo, com este conjunto de sensores, teria previsto historicamente **1 dos 3 trips genuínos conhecidos ( $\sim 33\%$ )**. Não é uma limitação de engenharia – é um limite de informação: nos outros 2 casos, a pressão fica completamente estável até o instante em que o problema já aconteceu. É plausível que esse tipo de trip tenha duas causas físicas distintas – uma degradação lenta e detectável, e um evento abrupto/mecânico sem aviso –, e o modelo só consegue captar a primeira com a instrumentação atual.

### 5.2 Prontidão para produção

O pipeline atual é retrospectivo/batch, não um serviço de inferência contínua. Faltam, no mínimo: conexão viva com o historian de processo, job de scoring agendado, integração com alerta operacional, e uma rotina de retreino periódico (o modelo aprendeu “normal” só até jun/2025, sem atualização desde então). Some-se a isso a base de validação pequena ( $n=2-3$ ), e o resultado deste relatório deve ser lido como uma **prova de conceito que confirma sinal real** (o caso de 14h de antecedência), não como um sistema pronto para proteger a operação.

### 5.3 Limitações e pendências

- Amostra de avaliação muito pequena ( $n=2$  no teste,  $n=3$  no total conhecido) – qualquer taxa de acerto carrega incerteza estatística grande.
- Não foi encontrada fonte de dado para ampliar a janela histórica (2023 está ausente nos datasets ClearML disponíveis).
- 16 episódios de falso alerta residual (0,143%) foram caracterizados: mistura de manobras de carga reais, 1 glitch de sensor confirmado, e o restante sem causa identificada com os sinais checados.
- Um config de referência em CNN1D-Autoencoder foi preparado mas não chegou a ser necessário, dado o desempenho já forte do AutoML/*iforest*.

## 6 Conclusão

O EXP16 estabeleceu, pela primeira vez, uma pipeline de detecção para o alarme de trip de óleo lubrificante do compressor, independente da linha de trabalho da T5. O modelo vencedor – *IsolationForest* sobre o alvo mais os 10 canais de vibração, sem nenhum portão de pós-processamento – atinge falso alerta baixo (0,143%) e variância de semente nula, e demonstrou capacidade preditiva real em pelo menos um episódio histórico (14,3 horas de antecedência). A investigação foi além da métrica agregada: verificou a antecedência real ponto a ponto, testou e refutou duas hipóteses concretas de precursor para os casos sem detecção, e chegou a uma conclusão honesta sobre os limites do que a instrumentação atual permite prever –  $\sim 1$  em 3 casos, não a totalidade dos trips deste tipo.

## 7 Tasks ClearML referenciadas

- 15833383325746c999e8b866dda4b5e9 – EXP16a, grid amplo de AutoML (840 trials), vencedor iforest identificado.
- fc787faca377406890fed0309cd95b3c – EXP16b, config final travado + seed-sweep (5 sementes, variância zero).
- 640251258fcc471bb8f25bf8fe3ffac8 e 3f679264f5cb4c2081f658bdb2fa154b – EXP16c, teste da hipótese PDIT\_0305 (refutada).